

Proyek Pengenal Pola

Anggota

1. Cikal Wahyuning Bachtiar (24060123140175)
2. Evia Auamara Unsa Nasyta (24060123140111)
3. Aisha (24060123120029)
4. Assyifa Haqqi Dusanto (24060123130084)
5. Athiqotuz Zulaiva (24060123140201)



Overview

- 01 _____ Masalah & Data
- 02 _____ Tujuan
- 03 _____ Pattern Recognition Design Cycle
- 04 _____ Feature Selection & Extraction
- 05 _____ Normalisasi
- 06 _____ Visualisasi Feature
- 07 _____ Distribusi
- 08 _____ Training Model
- 09 _____ Evaluasi
- 10 _____ Decision Boundary
- 11 _____ Evaluasi Model

Link Colab

<https://colab.research.google.com/drive/18UVgsYHOyD5XYsjVuSgwTqoWXB56eOZZ?usp=sharing>

Masalah

Dataset terdiri dari ± 110 file audio .ogg yang terbagi ke dalam 5 kelas, di mana setiap audio memiliki karakteristik suara yang berbeda. Namun, data audio masih dalam bentuk mentah (waveform) sehingga tidak dapat langsung digunakan untuk klasifikasi. Sinyal audio memiliki struktur yang kompleks karena mengandung informasi frekuensi, amplitudo, dan perubahan terhadap waktu, serta dipengaruhi oleh noise dan variasi durasi. Hal ini membuat perbedaan antar kelas tidak mudah dikenali secara langsung. Oleh karena itu, diperlukan proses untuk mengubah audio menjadi representasi numerik (fitur) yang dapat dipahami oleh mesin, sehingga model dapat mengenali pola dan mengklasifikasikan audio ke dalam kelas yang sesuai.

Data

- **Tipe Data**

Data awal:

File audio .ogg dalam bentuk waveform (time-series) yang tidak terstruktur. Dan akan diubah ke representasi numerik via ekstraksi fitur akustik

- **Karakteristik Data**

- Total data: ± 110 audio
- Jumlah kelas: 5 kelas
- Distribusi: ± 22 data per kelas (relatif seimbang)
- Ukuran dataset kecil $\rightarrow$ berpotensi overfitting

Tujuan

- *Mengubah data audio menjadi representasi numerik berupa fitur akustik yang relevan*
- *Melatih model klasifikasi menggunakan pendekatan supervised learning dengan data berlabel*
- *Mengklasifikasikan audio ke dalam 5 kelas, yaitu: 0_tr, 1_tr, 2_tr, 3_tr, 4_tr*
- *Menghasilkan model yang mampu melakukan prediksi terhadap data audio baru*

Pattern Recognition Design Cycle

Data Acquisition

Pengambilan dataset audio menggunakan mount drive

Preprocessing

Membaca file audio (load audio) dan melakukan normalisasi amplitudo sinyal

Feature Extraction

Mengubah sinyal audio menjadi representasi numerik melalui ekstraksi fitur akustik

Visualization

Melakukan visualisasi fitur (misalnya 3D visualization) untuk memahami pola data

Model Training

Melatih model klasifikasi menggunakan data training (supervised learning)

Evaluation

Mengukur performa model menggunakan metrik evaluasi seperti accuracy dan F1-score, F1-Weighted, ROC - AUC MACRO

MFCC — Mean koefisien pertama (MFCC1_mean)

Mel-Frequency Cepstral Coefficients merepresentasikan timbre atau warna suara sesuai persepsi pendengaran manusia. MFCC adalah fitur paling standar di seluruh literatur speech recognition dan audio classification, karena merangkum distribusi energi spektral per frame secara ringkas namun diskriminatif. Koefisien pertama (MFCC1) merepresentasikan energi keseluruhan sinyal.

Spectral Centroid


Mengukur "pusat massa" spektrum frekuensi — nilai tinggi berarti suara terdengar cerah/tajam, nilai rendah berarti gelap/dalam. Kelas audio yang berbeda umumnya memiliki distribusi energi frekuensi yang berbeda, sehingga centroid menjadi fitur yang cepat dihitung sekaligus diskriminatif.

Zero Crossing Rate (ZCR)

Menghitung seberapa sering sinyal melewati nilai nol per frame — merupakan proxy untuk membedakan suara perkusif/berisik (ZCR tinggi) versus suara tonal/nada murni (ZCR rendah). ZCR melengkapi MFCC dan Spectral Centroid karena mengukur dimensi yang berbeda dan tidak redundan.


Feature Selection & Extraction

File .ogg → librosa.load() → array float32 @ 22.050 Hz, 5 detik (di-pad nol jika kurang, dipotong jika lebih) → dihitung MFCC per frame lalu diambil mean → dihitung Spectral Centroid mean (Hz) → dihitung ZCR mean (fraksi) → vektor 3 fitur siap digunakan. Selain 3 fitur utama, diekstrak pula 80 fitur tambahan (Chroma, Spectral Contrast, Rolloff, Delta MFCC, RMS Energy) untuk eksperimen model dengan fitur lengkap (total 83 fitur).



Normalisasi

Sebelum masuk ke model, ketiga fitur memiliki skala yang sangat berbeda: MFCC1_mean bernilai sekitar -500 hingga 0, Spectral Centroid dalam satuan Hz (ribuan), dan ZCR antara 0,01-0,5. Perbedaan skala ini akan membuat model bias ke fitur berskala besar dan menyebabkan gradien tidak stabil.



Solusi: StandardScaler (z-score normalization)

Formula: $z = (x - \mu_{\text{train}}) / \sigma_{\text{train}}$

Scaler di-fit hanya pada data training, lalu hasilnya di-transform ke data test — ini mencegah data leakage, yaitu kondisi di mana informasi dari test set bocor ke proses training dan membuat evaluasi menjadi terlalu optimis.

Setelah normalisasi, setiap fitur memiliki mean ≈ 0 dan standar deviasi ≈ 1 . Tiga fitur yang sebelumnya tidak sebanding kini berada dalam ruang yang adil dan setara bobotnya, sehingga model dapat belajar pola yang sebenarnya.


Histogram distribusi tiap fitur per kelas sebelum (atas) dan sesudah normalisasi (bawah). Setelah normalisasi, skala seragam dan distribusi antar kelas lebih mudah dibandingkan.

Visualisasi Feature Space 3D


Gambar pertama menampilkan feature space 3 dimensi dari tiga fitur akustik (MFCC1, Spectral Centroid, ZCR) setelah normalisasi. Setiap titik adalah sampel audio dengan warna/symbol berbeda untuk tiap kelas. Pemisahan cluster menunjukkan kemampuan fitur dalam membedakan kelas; jika masih overlap, diperlukan model non-linear atau fitur yang lebih kompleks.

Gambar kedua menampilkan proyeksi PCA 3 dimensi dari seluruh 83 fitur. PCA merangkum variansi terbesar ke dalam PC1, PC2, dan PC3, sehingga memberikan representasi yang lebih komprehensif. Total variansi yang dipertahankan menunjukkan seberapa banyak informasi dari data asli yang masih terwakili.

**3 fitur akustik
terpilih
(interpretable,
domain-
specific)**




**PCA dari 83
fitur →
merangkum
40.6% total
variansi**




Distribusi Data Hasil Proyeksi PCA


Scree plot menunjukkan variansi tiap komponen (bar biru) dan variansi kumulatif (garis merah). Garis 90% membantu menentukan jumlah komponen minimum agar sebagian besar informasi tetap terjaga. Sedangkan gambar proyeksi PCA menampilkan distribusi data pada PC1 vs PC2 dan PC1 vs PC3. Warna dan marker menunjukkan kelas, serta persentase di sumbu menunjukkan kontribusi variansi. Jika masih ada overlap antar cluster, berarti pemisahan belum linear dan model non-linear diperlukan.



Scree Plot PCA (83 fitur)



Proyeksi PCA: PC1 vs PC2



Proyeksi PCA: PC1 vs PC3

Training Model

Proses training model dilakukan dengan menggunakan lima model klasifikasi, yaitu Gaussian Naive Bayes, LDA, KNN (k=5), SVM RBF, dan Random Forest, yang mewakili spektrum pendekatan dari metode Bayesian hingga machine learning modern. Masing-masing model dilatih menggunakan dua skenario fitur, yaitu 3 fitur utama (fitur sederhana dan interpretable) serta 83 fitur lengkap (fitur yang lebih kompleks dan komprehensif). Tujuan dari dua skenario ini adalah untuk menganalisis bagaimana jumlah dan kompleksitas fitur memengaruhi kemampuan model dalam mempelajari pola data.

Hasil training dengan menggunakan 3 fitur utama:


- **Gaussian NB (Bayesian)** CV=0.522±0.092 Test=0.409
- **LDA** CV=0.477±0.073 Test=0.455
- **KNN (k=5)** CV=0.442±0.056 Test=0.409
- **SVM RBF** CV=0.306±0.105 Test=0.409
- **Random Forest** CV=0.454±0.096 Test=0.318

Hasil training dengan menggunakan 83 fitur:

- **Gaussian NB (Bayesian)** CV=0.615±0.103 Test=0.636
- **LDA** CV=0.343±0.124 Test=0.318
- **KNN (k=5)** CV=0.671±0.073 Test=0.591
- **SVM RBF** CV=0.670±0.112 Test=0.682
- **Random Forest** CV=0.706±0.060 Test=0.591

Evaluasi

Evaluasi model dilakukan menggunakan 5-Fold Stratified Cross-Validation pada data training untuk menjaga keseimbangan distribusi kelas dan mendapatkan performa yang lebih stabil, kemudian dilanjutkan dengan pengujian pada test set yang belum pernah dilihat model untuk mengukur kemampuan generalisasi. Berdasarkan hasil evaluasi, model terbaik pada skenario 83 fitur adalah Random Forest dengan rata-rata akurasi cross-validation sebesar 0.7059 ± 0.0595 , namun akurasi pada data test sebesar 0.5909 menunjukkan adanya penurunan performa yang mengindikasikan kemungkinan overfitting.



Visualisasi Decision Boundary

Decision boundary ditampilkan dalam proyeksi 2D menggunakan dua fitur utama (MFCC1_mean dan Spectral Centroid), sementara ZCR di terapkan pada nilai rata-ratanya. Warna latar menunjukkan region keputusan tiap model, sedangkan titik-titik merepresentasikan data asli.

Gaussian Naive Bayes

- Batas keputusan berbentuk eliptikal/kurva
- Mencerminkan asumsi distribusi Gaussian per kelas yang dapat memiliki kovarians berbeda

KNN

- Batas keputusan tidak teratur dan mengikuti data lokal.
- Dapat membentuk are kecil seperti pulau dari suatu kelas di antara kelas lain.
- Rentan terhadap overfitting, terutama pada dataset berukuran kecil.

LDA


- Batas keputusan bersifat linear
- Tegak lurus terhadap pusat massa antar kelas
- Kurang optimal jika data tidak linearly separabl

SVM RBF

- Batas keputusan bersifat non-linear dan halus (kernel trick).
- Mampu memisahkan cluster yang overlap dengan baik.

Random Forest

- Batas keputusan berbentuk kotak bertingkat (step function).
- Hasil dari proses split ortogonal pada decision tree.



Decision boundary tiap model dalam proyeksi 2D. Bentuk boundary mencerminkan karakteristik masing- masing model: linear (LDA), eliptikal (GNB), non-linear halus (SVM), stepped (RF), dan lokal (KNN).


Evaluasi Model

Confusion Matrix

Confusion Matrix digunakan untuk melihat performa klasifikasi setiap kelas, setiap baris merepresentasikan kelas aktual dan setiap kolom menunjukkan kelas prediksi. Nilai pada diagonal utama menunjukkan prediksi yang benar, sedangkan nilai di luar diagonal merupakan kesalahan klasifikasi. Persentase dalam kurung dihitung per baris (per kelas aktual), sehingga dapat diketahui kelas mana yang paling sering salah diklasifikasikan dan kecenderungan kesalahannya.

F1 Score

F1-Score digunakan karena lebih representatif dibanding akurasi pada dataset kecil dan berpotensi tidak seimbang. F1 merupakan harmonic mean dari Precision dan Recall, sehingga model yang hanya unggul pada satu aspek tidak akan memperoleh nilai tinggi. Nilai F1 dilaporkan dalam dua bentuk, yaitu macro (rata-rata tanpa bobot antar kelas) dan weighted (mempertimbangkan jumlah sampel per kelas).



Evaluasi Model


ROC - AUC

ROC-AUC menggambarkan hubungan antara True Positive Rate (TPR/Recall) dan False Positive Rate (FPR) pada berbagai threshold. Pada kasus multi-kelas digunakan pendekatan One-vs-Rest, di mana setiap kelas dibandingkan dengan kelas lainnya. Nilai AUC yang mendekati 1,0 menunjukkan performa model yang sangat baik, sedangkan nilai 0,5 setara dengan tebakan acak. Selain itu, perbandingan metrik menampilkan F1 Macro, F1 Weighted, dan ROC-AUC untuk seluruh model, sehingga model terbaik dapat ditentukan berdasarkan konsistensi performa pada ketiga metrik tersebut.


Hasil Perbandingan

Berdasarkan hasil evaluasi, MFCC menjadi fitur paling informatif karena mampu merangkum karakteristik timbre suara secara kompak. Model non-linear seperti SVM RBF dan Random Forest umumnya menunjukkan performa lebih baik dibanding model linear, karena feature space audio bersifat non-linear, serta ROC-AUC lebih stabil dibanding akurasi pada dataset kecil. Namun, pipeline ini memiliki keterbatasan, seperti ukuran dataset yang kecil (~22 sampel per kelas), tidak adanya augmentasi data, serta potensi bias akibat padding pada audio berdurasi pendek. Selain itu, visualisasi decision boundary hanya merupakan proyeksi 2D dan tidak dilakukan hyperparameter tuning yang dapat meningkatkan performa model.

ROC



Perbandingan Metriks Evaluasi



Thank You.
