



KLASIFIKASI AUDIO BURUNG 5 KELAS MENGUNAKAN HYBRID FEATURE ANALYSIS DAN TRANSFER LEARNING PADA MEL SPECTROGRAM





Anggota Kelompok

Bagus Athallah

24060123120002

Shopia Mudjahidah


24060123120010


Axel Natakesuma

24060123130058

Dimas A Albanna Zain

24060123130080





Latar Belakang





- Pentingnya identifikasi spesies burung berbasis audio untuk monitoring biodiversitas.
- Proses identifikasi manual membutuhkan keahlian bioakustik dan waktu tinggi.
- Machine Learning memungkinkan otomatisasi klasifikasi suara burung secara efisien.
- **Tantangan utama** : Noise lingkungan, Variasi recording, dan Kemiripan pola vokalisasi antar spesies.

Keadaan data



- Dataset kecil (110 audio)
 - Class imbalance
 - Overlap karakteristik suara antar kelas
- 


Tujuan

- Mengembangkan model klasifikasi audio burung 5 kelas
 - Menganalisis fitur paling informatif
 - Mengevaluasi performa model secara lengkap
- 
- 




Pipeline






Dataset Preparation

- Struktur folder digunakan sebagai label kelas:
0_tr, 1_tr, 2_tr, 3_tr, 4_tr
- Dilakukan indexing seluruh file audio ke metadata dataset.
- **Total dataset** : 110 audio
- **Output** : Dataframe metadata berisi filepath dan label.






Dataset Distribution Analysis

- Analisis distribusi jumlah sampel per kelas.
- Ditemukan ketidakseimbangan distribusi antar kelas.

Dampak :

- Model berpotensi bias ke kelas mayoritas.
- Diperlukan strategi balancing pada tahap augmentation.




Audio Preprocessing


Tujuan

Menyeragamkan seluruh file audio mentah menjadi representasi yang siap diproses oleh model deep learning.

Tahapan Utama:

- Memuat file audio (.ogg) → menggunakan `librosa.load()` dengan resampling ke 16 kHz, diubah ke mono.
- Menghilangkan bagian hening (`trim_silence`) dengan threshold 20 dB agar hanya suara burung yang tersisa.
- **Pad atau potong** (`pad/truncate`) sinyal menjadi durasi tetap 5 detik → input berukuran sama untuk model.





Heavy Augmentation

pada Data Training



Mengapa augmentasi?

- Dataset hanya 110 file (sangat kecil).
- Kelas tidak seimbang → dilakukan oversampling dengan mengulang file pada kelas minoritas (hingga 4x).


Oversampling Kelas Minoritas

Tujuan: Menyeimbangkan distribusi kelas.

Metode: Jumlah augmentasi per kelas proporsional terhadap inverse frequency.

Jenis augmentasi yang diterapkan (probabilistik):

- **Time Shift:** menggeser sinyal secara acak (maks 20% panjang).
- **Pitch Shift:** mengubah pitch hingga ± 2 semitone.
- **Time Stretch:** memperlambat/mempercepat tempo (0.8–1.25x).
- **Gaussian Noise:** menambahkan derau putih (level 0.005).
- **Background Noise:** mencampurkan potongan audio lain sebagai noise latar.



Heavy Augmentation pada Data Training

Alasan Pemilihan:


Karakter suara burung di alam:


- terjadi pada waktu berbeda,
- pitch bervariasi antar individu,
- durasi bervariasi,
- banyak noise lingkungan.

Augmentasi ini mensimulasikan kondisi nyata recording lapangan.

Output:

Waveform augmented yang lebih beragam.






Transformasi ke Mel Spectrogram


→ **CNN Input**


- Audio tidak bisa langsung masuk CNN → perlu diubah menjadi citra 2D.
- **Mel spectrogram:** representasi frekuensi dalam skala Mel, lebih sesuai dengan persepsi pendengaran manusia.



Langkah:

1. Hitung Mel spectrogram (`librosa.feature.melspectrogram, n_mels=128`).
2. Konversi ke skala decibel (dB).
3. Normalisasi ke $[0,1]$.
4. Ubah ukuran ke 224×224 piksel dengan TensorFlow.
5. Duplikat channel 1 → 3 agar bisa dipakai di model pretrained (e.g. EfficientNetB0).






Feature Engineering


× × ×

Tiap wavelength yang berasal dari proses augmentasi akan dicari fiturnya dari berbagai cara dengan tujuan mencari karakteristik terukur apa yang dapat membedakan tiap kelas.

× × ×

- MFCC (Mel-Frequency Cepstral Coefficients) → Timbre
- Spectral Centroid → “Center of Mass.”
- Spectral Bandwidth → Pendek, Panjang. How it spread out
- Spectral Rolloff → Mencari Sebagian besar Bulk boundary
- Zero Crossing Rate → Berapa kali menyentuh zero ampli.
- RMS Energy → Loudness
- Chroma Features → Distribusi pitch-class





Feature Selection

Metode seleksi fitur:

- **ANOVA F-Score**


Mengukur separasi antar kelas, semakin beda, F-score semakin tinggi


- **Random Forest Feature Importance**

Mengukur kontribusi fitur terhadap klasifikasi, membantu bagaimana Tree dapat di-split.

Pendekatan:

- Ranking fitur berdasarkan kombinasi kedua metode dengan consensus ranking







Feature Selection



3 fitur terbaik hasil seleksi fitur: mfcc7_std, mfcc5_mean, mfcc3_std

	feature	f_score	rf_importance	rank_f	rank_rf	rank_mean
13	mfcc7_std	39.729214	0.095300	1.0	1.0	1.0
8	mfcc5_mean	22.923946	0.066658	2.0	3.0	2.5
5	mfcc3_std	16.142391	0.047366	3.0	5.0	4.0
26	spectral_centroid_mean	12.396833	0.047581	7.0	4.0	5.5
21	mfcc11_std	15.383435	0.036224	4.0	8.0	6.0
16	mfcc9_mean	13.548192	0.035400	5.0	9.0	7.0
30	rolloff_mean	11.523569	0.037053	9.0	7.0	8.0
23	mfcc12_std	11.709780	0.028144	8.0	11.0	9.5
1	mfcc1_std	5.153636	0.071607	18.0	2.0	10.0
32	zcr_mean	10.856959	0.031992	10.0	10.0	10.0






Feature Selection





3 fitur terbaik hasil seleksi fitur: mfcc7_std, mfcc5_mean, mfcc3_std



Alasan:

- Memiliki ANOVA F-Score tertinggi, **menunjukkan separasi antar kelas paling kuat.**
- Memiliki Random Forest Importance tertinggi, menunjukkan **kontribusi besar terhadap klasifikasi.**
- Ketiganya menangkap kombinasi karakteristik spektral statis + dinamika temporal yang sangat relevan pada bioacoustic burung.
- Lebih diskriminatif dibanding fitur energi/global lainnya





Deep Learning

Training

Model Transfer Learning:

- Backbone:
 - EfficientNetB0
 - MobileNetV2 (fallback)
- Input:
 - Mel Spectrogram $224 \times 224 \times 3$

Arsitektur:

- CNN Backbone
- Global Average Pooling
- Dense 128
- Dropout 0.4
- Softmax 5 kelas





Training Strategy

- Stratified 5-Fold Cross Validation
- EarlyStopping
- ReduceLROnPlateau
- ModelCheckpoint

Tujuan:

- Robust evaluation pada dataset kecil
- Mencegah overfitting





Strategi Evaluasi

01

Evaluasi dilakukan menggunakan Stratified 5-Fold Cross Validation

02

Distribusi kelas dijaga tetap proporsional pada setiap fold

03

Metrik dihitung pada setiap fold, kemudian dirata-ratakan

Metrik Evaluasi Model

Metrik yang Digunakan:



- Accuracy
- Precision
- Recall
- F1-Score
- Confusion Matrix
- ROC Curve / AUC

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$



$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$



Hasil Evaluasi dan Analisis Kesalahan



Hasil Rata-rata 5-Fold Cross Validation :

Accuracy = 82,73%

Precision Macro = 80,59%

Recall Macro = 80,60%

F1-Score Macro = 79,75%

Precision Weighted = 84,84%

Recall Weighted = 82,73%

F1-Score Weighted = 82,97%

ROC-AUC OvR = 95,70%


ROC-AUC OvO = 95,70%

Temuan Utama :

- Model mencapai accuracy rata-rata 82,73%
- Weighted F1-score sebesar 82,97%
- ROC-AUC sebesar 95,70%
- Kelas dengan performa terbaik: 3_tr dan 4_tr
- Kelas tersulit diprediksi: 2_tr

Analisis Kesalahan :

- Terjadi kemungkinan overlap spektral antara kelas 2_tr dengan kelas lain
- Jumlah data pada kelas tertentu masih terbatas
- Variasi suara burung dalam satu kelas cukup tinggi
- Noise lingkungan dapat memengaruhi pola Mel Spectrogram



Kesimpulan dan Pengembangan Selanjutnya

Keterbatasan Pipeline :


- Dataset masih kecil, yaitu 110 audio untuk 5 kelas
- Mel Spectrogram tidak menyimpan informasi fase sinyal audio
- Backbone EfficientNetB0 / MobileNetV2 berasal dari domain citra, bukan model khusus audio
- Augmentasi berlebihan dapat menghasilkan pola akustik yang kurang realistis
- Kelas 2_tr masih sulit diklasifikasikan secara konsisten


Kedepannya :

- Menambah jumlah data asli, terutama untuk kelas 2_tr
- Menggunakan model pretrained khusus audio seperti YAMNet, PANNs, AST, atau BEATs
- Menambahkan SpecAugment pada Mel Spectrogram
- Melakukan Grad-CAM untuk analisis explainability
- Melakukan fine-tuning backbone secara bertahap

Kesimpulan :

- Pipeline berhasil mengintegrasikan handcrafted feature analysis dan deep learning
- Transfer learning pada Mel Spectrogram efektif untuk klasifikasi audio burung dengan dataset kecil
- Augmentasi audio membantu meningkatkan variasi data latih dan generalisasi model
- Model menunjukkan performa cukup baik dengan accuracy 82,73%, weighted F1-score 82,97%, dan ROC-AUC 95,70%





TERIMA KASIH

