

KLASIFIKASI SUARA BURUNG





Pengenalan Pola

KELOMPOK:

**PENGARUH
EKSTRAK KULIT
MANGGIS**

Nadia Syifa Khairunnisa	24060123120023
Muhammad Yoga Aminuddin	24060123130106
Nindya Kirana	24060123130067
Dewi Larasati Mumpuni	24060123140045





DEFINISI MASALAH, TIPE DATA, TUJUAN

PERMASALAHAN

Bagaimana mengklasifikasikan jenis burung berdasarkan suara

TIPE DATA

- Data berupa file audio
- Termasuk sinyal time-series (berbasis waktu)
- Terdapat 110 data training
- Perlu direpresentasikan dalam bentuk fitur numerik sebelum diproses oleh model

TUJUAN

- Mengklasifikasikan suara ke dalam kelas spesies burung
- Model mampu mengenali data baru (tidak mengalami overfitting)
- Menghasilkan performa yang baik berdasarkan hasil evaluasi

FITUR YANG DIANALISIS

MFCC (Mel-Frequency Cepstral Coefficients)

Apa yang diwakili:

Bentuk selubung spektrum suara dalam skala frekuensi Mel (non-linear, mendekati persepsi pendengaran manusia/hewan).

Alasan:

- Setiap spesies burung memiliki kualitas timbre yang khas (misal: suara "bass" khas burung gagak vs "treble" khas burung kenari).
- MFCC menangkap karakteristik ini dengan sangat baik.
- Cukup 3 koefisien pertama karena koefisien tinggi (detail halus) cenderung berisi noise pada data terbatas.

Spectral Centroid

Apa yang diwakili:

"Pusat massa" dari spektrum frekuensi – nilai tengah frekuensi tertimbang amplitudo.

Alasan:

- Burung dengan suara nada tinggi (misal: jalak) → centroid tinggi (~4000–7000 Hz)
- Burung dengan suara nada rendah (misal: burung hantu) → centroid rendah (~1000–2500 Hz)
- Mudah dihitung, stabil terhadap noise amplitudo.


ZCR (Zero Crossing Rate)

Apa yang diwakili:

Laju perubahan tanda sinyal per detik. Menunjukkan "kekasaran" atau "kebisingan" suara.

Alasan:

- Suara burung yang nyaring/melengking (banyak transisi cepat) maka ZCR tinggi
- Suara dengungan rendah atau nada murni maka ZCR rendah
- ZCR juga tahan terhadap variasi amplitudo dan tidak memerlukan deteksi pitch yang rumit.



PROSES EKSTRAKSI FITUR

INPUT DATA MENTAH

- File audio (.ogg)
- Sampling rate : 22.050 Hz
- Sinyal audio diubah menjadi array 1D

NORMALISASI DURASI

- Durasi diseragamkan menjadi 5 detik
- Jika < 5 detik : Padding
- Jika > 5 detik : Mengambil segmen terbaik berdasarkan skor tertinggi dari Energi (RMS) dan Kejernihan (1-ZCR)

Tujuannya :


- Menyamakan panjang data
- Menghindari bias panjang

TRANSFORMASI MFCC

- Menghitung 13 koefisien MFCC, lalu mengambil nilai rata-rata tiap koefisien terhadap waktu.
- Hanya mengambil 3 koefisien pertama untuk merepresentasikan karakter warna suara (timbre) burung.

Output:

[mfcc1, mfcc2, mfcc3]



PROSES EKSTRAKSI FITUR

EKSTRAKSI FITUR TAMBAHAN

- **Spectral Centroid**
 - Ubah sinyal ke domain frekuensi (STFT)
 - Menghitung rata-rata tertimbang frekuensi
 - Output: 1 nilai (Hz) → menunjukkan tinggi/rendahnya nada
- **Zero Crossing Rate (ZCR)**
 - Hitung perubahan tanda sinyal (+/-)
 - Output: 0 - 1 → menunjukkan tingkat kekasaran suara

VEKTOR FITUR DAN NORMALISASI

- **Vektor 5D:**
 - [MFCC1, MFCC2, MFCC3, Centroid, ZCR]
- **StandardScaler:**
 - Menyeragamkan skala fitur agar siap untuk Machine Learning (Mean=0, StdDev=1).

CONTOH OUTPUT

- **MFCC:** -393.6, -121.0, -40.6
- **Centroid:** 5029.38 Hz
- **ZCR:** 0.42

VEKTOR (SEBELUM NORMALISASI)

- [-393.6, -121.0, -40.6, 5029.38, 0.42]
- Data memiliki rentang nilai yang sangat jauh berbeda (satuan Hz vs Desimal).


VEKTOR (SETELAH NORMALISASI)

- [-0.6295, -2.1612, -0.6470, 1.0539, 0.9984]
- Skala seragam di sekitar 0. Model lebih mudah mengenali pola tanpa bias besaran nilai.

VISUALISASI FEATURE SPACE 3D

Interpretasi Visual:

- Grafik menampilkan sebaran 110 data training dalam ruang 3 dimensi menggunakan fitur utama : MFCC-1, Spectral Centroid, dan ZCR yang telah dinormalisasi.
- **Pola Pengelompokan (Clustering)**
 - Sebaran data dari masing-masing kelas menunjukkan kecenderungan tertentu, namun tidak membentuk klaster yang terpisah secara absolut.
 - Beberapa kelas memiliki konsentrasi di area spesifik, tetapi secara umum distribusi data masih saling bersinggungan.
- **Interaksi Antar Kelas:**
 - Terdapat overlap yang cukup signifikan antar kelas pada ruang fitur 3D ini.
 - Kondisi ini menunjukkan bahwa ketiga fitur tersebut belum cukup untuk memisahkan kelas secara optimal dalam ruang 3 dimensi.





MODEL KLASIFIKASI

PEMILIHAN MODEL KLASIFIKASI

Pendekatan yang digunakan adalah Supervised Machine Learning

Tiga model dipilih dan dibandingkan untuk mendapatkan performa terbaik, yaitu:

- Gaussian Naive Bayes sebagai model probabilistik berbasis Bayesian Decision
- Random Forest sebagai model ensemble berbasis decision tree
- Support Vector Machine (SVM) dengan kernel RBF sebagai model non-linear

WHY?

Pemilihan ini didasarkan pada karakteristik data:

- Dataset relatif kecil (110 data)
- Fitur berbentuk numerik berdimensi rendah (5 fitur)
- Membutuhkan model yang efisien namun tetap mampu menangkap pola non-linear

MEKANISME TRAINING MODEL

Setiap model memiliki mekanisme pembelajaran yang berbeda:

1


Pada Gaussian Naive Bayes, model mempelajari distribusi probabilitas tiap fitur untuk setiap kelas, kemudian menggunakan prinsip probabilitas posterior untuk klasifikasi

2


Pada Random Forest, model membangun banyak decision tree dari subset data, kemudian hasil prediksi ditentukan berdasarkan voting mayoritas dari seluruh tree.

3

Pada SVM, model mencari hyperplane optimal yang memisahkan kelas dalam ruang fitur, dengan kernel RBF untuk menangani pola non-linear.



TRAINING & INFERENCE



Gaussian Naive Bayes

Training

Pada tahap ini model Menghitung prior tiap kelas (`class_prior_`) dan Menghitung mean dan variansi tiap fitur untuk setiap kelas

Inferensi

- Proses: Hitung probabilitas posterior untuk tiap kelas, kemudian membandingkan semua probabilitas
- Output: Probabilitas tiap kelas (`predict_proba`) kemudian dipilih Prediksi akhir (`predict`) = probabilitas terbesar

Random Forest

Training

Data diambil secara acak (bootstrap), Setiap tree belajar aturan split fitur yang berbeda Model menyimpan struktur tree dan feature importance

Inferensi

- Proses: Data masuk ke semua tree Setiap tree memberikan prediksi
- Output: Voting mayoritas → prediksi akhir, Probabilitas dihitung dari proporsi voting (`predict_proba`)

Support vector Machine


Training

Model mencari hyperplane optimal Menggunakan kernel RBF untuk memetakan data ke ruang non-linear

Inferensi

- Proses: Hitung posisi data terhadap hyperplane, kemudian Tentukan kelas berdasarkan sisi margin
- Output: Prediksi kelas (`predict`) dan sebuah nilai Probabilitas (`predict_proba`)

DECISION REGION DAN FEATURES SPACE



- Visualisasi ini menunjukkan bagaimana model Random Forest membedakan kelas dalam ruang fitur.
 - Data berdimensi 5 direduksi menjadi 2 dimensi menggunakan PCA, sehingga dapat divisualisasikan.
- Sumbu:

- PC1 menjelaskan 57.0% variasi data
- PC2 menjelaskan 22.7% variasi data

Dari visualisasi ini terlihat bahwa:

- Beberapa kelas tidak terpisah dengan jelas
- Banyak titik dari kelas berbeda berada dalam region yang sama
- Terjadi overlap antar kelas di feature space


Akibatnya:

- Model sering salah klasifikasi
- Hal ini sesuai dengan hasil evaluasi, di mana beberapa kelas memiliki F1-score = 0

EVALUASI PERFORMA MODEL



Confussion Matrix



0_TR

TP (True Positive) = 0
FP (False Positive) = 1
FN (False Negative) = 6
TN (True Negative) = 23

$$\begin{aligned}\text{PRECISION} &= \text{TP} / (\text{TP} + \text{FP}) \\ &= 0 / (0 + 1) \\ &= 0 / 1 \\ &= 0.0000\end{aligned}$$

$$\begin{aligned}\text{RECALL} &= \text{TP} / (\text{TP} + \text{FN}) \\ &= 0 / (0 + 6) \\ &= 0 / 6 \\ &= 0.0000\end{aligned}$$

$$\begin{aligned}\text{F1-SCORE} &= 2 \times \text{PRECISION} \times \text{RECALL} / (\text{PRECISION} + \text{RECALL}) \\ &= 2 \times 0.0000 \times 0.0000 / (0.0000 + 0.0000) \\ &= 0.0000 / 0.0000 \\ &= 0.0000\end{aligned}$$

0_tr	
0	1
TP	FP
0	1
6	23
FN	TN

1_TR

TP (True Positive) = 4
FP (False Positive) = 10
FN (False Negative) = 2
TN (True Negative) = 14

$$\begin{aligned}\text{PRECISION} &= \text{TP} / (\text{TP} + \text{FP}) \\ &= 4 / (4 + 10) \\ &= 4 / 14 \\ &= 0.2857\end{aligned}$$

$$\begin{aligned}\text{RECALL} &= \text{TP} / (\text{TP} + \text{FN}) \\ &= 4 / (4 + 2) \\ &= 4 / 6 \\ &= 0.6667\end{aligned}$$

$$\begin{aligned}\text{F1-SCORE} &= 2 \times \text{PRECISION} \times \text{RECALL} / (\text{PRECISION} + \text{RECALL}) \\ &= 2 \times 0.2857 \times 0.6667 / (0.2857 + 0.6667) \\ &= 0.3810 / 0.9524 \\ &= 0.4000\end{aligned}$$

1_tr	
0	1
TP	FP
4	10
2	14
FN	TN

2_TR

TP (True Positive) = 0
FP (False Positive) = 2
FN (False Negative) = 6
TN (True Negative) = 22

2_tr	
0 TP	2 FP
6 FN	22 TN

$$\text{PRECISION} = \text{TP} / (\text{TP} + \text{FP}) = 0 / (0 + 2) = 0 / 2 = 0.0000$$

$$\text{RECALL} = \text{TP} / (\text{TP} + \text{FN}) = 0 / (0 + 6) = 0 / 6 = 0.0000$$

$$\begin{aligned}\text{F1-SCORE} &= 2 \times \text{PRECISION} \times \text{RECALL} / (\text{PRECISION} + \text{RECALL}) \\ &= 2 \times 0.0000 \times 0.0000 / (0.0000 + 0.0000) \\ &= 0.0000 / 0.0000 \\ &= 0.0000\end{aligned}$$

3_TR

TP (True Positive) = 0
FP (False Positive) = 0
FN (False Negative) = 6
TN (True Negative) = 24

3_tr	
0 TP	0 FP
6 FN	24 TN

$$\text{PRECISION} = \text{TP} / (\text{TP} + \text{FP}) = 0 / (0 + 0) = 0 / 0 = 0.0000$$

$$\text{RECALL} = \text{TP} / (\text{TP} + \text{FN}) = 0 / (0 + 6) = 0 / 6 = 0.0000$$

$$\begin{aligned}\text{F1-SCORE} &= 2 \times \text{PRECISION} \times \text{RECALL} / (\text{PRECISION} + \text{RECALL}) \\ &= 2 \times 0.0000 \times 0.0000 / (0.0000 + 0.0000) \\ &= 0.0000 / 0.0000 \\ &= 0.0000\end{aligned}$$

4_TR

TP (True Positive) = 5

FP (False Positive) = 8

FN (False Negative) = 1

TN (True Negative) = 16

$$\begin{aligned}\text{PRECISION} &= \text{TP} / (\text{TP} + \text{FP}) \\ &= 5 / (5 + 8) \\ &= 5 / 13 \\ &= 0.3846\end{aligned}$$

$$\begin{aligned}\text{RECALL} &= \text{TP} / (\text{TP} + \text{FN}) \\ &= 5 / (5 + 1) \\ &= 5 / 6 \\ &= 0.8333\end{aligned}$$

$$\begin{aligned}\text{F1-SCORE} &= 2 \times \text{PRECISION} \times \text{RECALL} / (\text{PRECISION} + \text{RECALL}) \\ &= 2 \times 0.3846 \times 0.8333 / (0.3846 + 0.8333) \\ &= 0.6410 / 1.2179 \\ &= 0.5263\end{aligned}$$

4_tr	
5 TP	8 FP
1 FN	16 TN

EVALUASI PERFORMA MODEL



F1-Score

MICRO F1 (agregat semua kelas)
MACRO F1 (rata-rata tidak berbobot)

MICRO F1

Net TP = jumlah TP semua kelas = 9

Net FP = jumlah FP semua kelas = 21

Net FN = jumlah FN semua kelas = 21

Micro Precision = $\text{Net TP} / (\text{Net TP} + \text{Net FP})$
= $9 / (9 + 21)$
= 0.3000

Micro Recall = $\text{Net TP} / (\text{Net TP} + \text{Net FN})$
= $9 / (9 + 21)$
= 0.3000

Micro F1 = $2 \times 0.3000 \times 0.3000 / (0.3000 + 0.3000)$
= $0.1800 / 0.6000$
= 0.3000


Micro F1 sklearn = 0.3000 (harus sama)

MACRO F1

Macro F1 = $(0.0000 + 0.4000 + 0.0000 + 0.0000 + 0.5263) / 5$
= $0.9263 / 5$
= 0.1853

Macro F1 = 0.1853 <- harus sama sklearn

EVALUASI PERFORMA MODEL



ROC-AUC

Metode : One-vs-Rest (OVR)

Rumus : $TPR = TP / (TP + FN)$, $FPR = FP / (FP + TN)$

AUC : luas kurva ROC (metode trapezoid)

$$AUC = \sum ((FPR[i+1] - FPR[i]) * (TPR[i] + TPR[i+1])) / 2$$

0_TR

No	Threshold	FPR	TPR
0	inf	0.0000	0.0000
3	0.2200	0.2500	0.1667
6	0.1900	0.4583	0.3333
9	0.1400	0.6250	0.6667
12	0.0900	0.7917	1.0000
15	0.0500	1.0000	1.0000

Perhitungan AUC

metode trapezoid, contoh 3 langkah pertama

$$\text{AUC} = \text{sum}((\text{FPR}[i+1] - \text{FPR}[i]) \times (\text{TPR}[i] + \text{TPR}[i+1]) / 2)$$

$$\begin{aligned} \text{Langkah 1} &: (0.0417 - 0.0000) \times (0.0000 + 0.0000) / 2 \\ &= 0.0417 \times 0.0000 = 0.000000 \end{aligned}$$

$$\begin{aligned} \text{Langkah 2} &: (0.2083 - 0.0417) \times (0.0000 + 0.0000) / 2 \\ &= 0.1667 \times 0.0000 = 0.000000 \end{aligned}$$

$$\begin{aligned} \text{Langkah 3} &: (0.2500 - 0.2083) \times (0.0000 + 0.1667) / 2 \\ &= 0.0417 \times 0.0833 = 0.003472 \end{aligned}$$

$$\text{AUC manual} = 0.4549$$

$$\text{AUC sklearn} = 0.4549$$

1_TR

No	Threshold	FPR	TPR
0	inf	0.0000	0.0000
3	0.5500	0.0000	0.6667
7	0.4400	0.2500	0.6667
10	0.2700	0.5000	0.8333
14	0.1600	0.7083	1.0000
18	0.0000	1.0000	1.0000

Perhitungan AUC

metode trapezoid, contoh 3 langkah pertama

$$\text{AUC} = \text{sum}((\text{FPR}[i+1] - \text{FPR}[i]) \times (\text{TPR}[i] + \text{TPR}[i+1]) / 2)$$

$$\begin{aligned} \text{Langkah 1} &: (0.0000 - 0.0000) \times (0.0000 + 0.1667) / 2 \\ &= 0.0000 \times 0.0833 = 0.000000 \end{aligned}$$

$$\begin{aligned} \text{Langkah 2} &: (0.0000 - 0.0000) \times (0.1667 + 0.3333) / 2 \\ &= 0.0000 \times 0.2500 = 0.000000 \end{aligned}$$

$$\begin{aligned} \text{Langkah 3} &: (0.0000 - 0.0000) \times (0.3333 + 0.6667) / 2 \\ &= 0.0000 \times 0.5000 = 0.000000 \end{aligned}$$

$$\text{AUC manual} = 0.8403$$

$$\text{AUC sklearn} = 0.8403$$

2_TR

No	Threshold	FPR	TPR
0	inf	0.0000	0.0000
2	0.3700	0.0833	0.0000
5	0.1700	0.3750	0.1667
7	0.1100	0.4583	0.3333
10	0.0700	0.7500	0.8333
13	0.0100	1.0000	1.0000

Perhitungan AUC

metode trapezoid, contoh 3 langkah pertama

$$\text{AUC} = \text{sum}((\text{FPR}[i+1] - \text{FPR}[i]) \times (\text{TPR}[i] + \text{TPR}[i+1]) / 2)$$

$$\begin{aligned} \text{Langkah 1} &: (0.0417 - 0.0000) \times (0.0000 + 0.0000) / 2 \\ &= 0.0417 \times 0.0000 = 0.000000 \end{aligned}$$

$$\begin{aligned} \text{Langkah 2} &: (0.0833 - 0.0417) \times (0.0000 + 0.0000) / 2 \\ &= 0.0417 \times 0.0000 = 0.000000 \end{aligned}$$

$$\begin{aligned} \text{Langkah 3} &: (0.1250 - 0.2083) \times (0.0000 + 0.1667) / 2 \\ &= 0.0417 \times 0.0833 = 0.003472 \end{aligned}$$

$$\text{AUC manual} = 0.4688$$

$$\text{AUC sklearn} = 0.4688$$

3_TR

No	Threshold	FPR	TPR
0	inf	0.0000	0.0000
1	0.1900	0.0417	0.0000
2	0.0600	0.2083	0.0000
3	0.0300	0.3333	0.0000
4	0.0200	0.4583	0.3333
6	0.0000	1.0000	1.0000

Perhitungan AUC

metode trapezoid, contoh 3 langkah pertama

$$\text{AUC} = \text{sum}((\text{FPR}[i+1] - \text{FPR}[i]) \times (\text{TPR}[i] + \text{TPR}[i+1]) / 2)$$

$$\begin{aligned} \text{Langkah 1} &: (0.0417 - 0.0000) \times (0.0000 + 0.1667) / 2 \\ &= 0.0417 \times 0.0000 = 0.000000 \end{aligned}$$

$$\begin{aligned} \text{Langkah 2} &: (0.2083 - 0.0417) \times (0.0000 + 0.0000) / 2 \\ &= 0.1667 \times 0.0000 = 0.000000 \end{aligned}$$

$$\begin{aligned} \text{Langkah 3} &: (0.3333 - 0.2083) \times (0.0000 + 0.0000) / 2 \\ &= 0.1250 \times 0.0000 = 0.000000 \end{aligned}$$

$$\text{AUC manual} = 0.3854$$

$$\text{AUC sklearn} = 0.3854$$

4_TR

No	Threshold	FPR	TPR
0	inf	0.0000	0.0000
2	0.7200	0.0417	0.3333
5	0.5800	0.1667	0.5000
7	0.5400	0.2083	0.8333
10	0.0700	0.7083	1.0000
13	0.0100	1.0000	1.0000

Perhitungan AUC

metode trapezoid, contoh 3 langkah pertama

$$\text{AUC} = \sum ((\text{FPR}[i+1] - \text{FPR}[i]) \times (\text{TPR}[i] + \text{TPR}[i+1]) / 2)$$

Langkah 1 : $(0.0417 - 0.0000) \times (0.0000 + 0.0000)/2$
 $= 0.0417 \times 0.0000 = 0.000000$

Langkah 2 : $(0.0417 - 0.0417) \times (0.0000 + 0.3333)/2$
 $= 0.0000 \times 0.1667 = 0.000000$

Langkah 3 : $(0.1250 - 0.0417) \times (0.3333 + 0.3333)/2$
 $= 0.0833 \times 0.3333 = 0.027778$

AUC manual = 0.8090

AUC sklearn = 0.8090

Macro ROC-AUC

rata-rata AUC semua kelas

$$= 0.4549 + 0.8403 + 0.4688 + 0.3854 + 0.8090$$

dibagi 5

$$= 2.9583 / 5$$

$$= 0.5917$$

Macro ROC-AUC: 0.5917

F1 Weighted : 0.1853

ROC-AUC : 0.5917

Terimakasih.

