

Segmentasi Tumor Otak Menggunakan TransUNet pada Dataset Brain Tumor Segmentation MRI

Deskripsi Task

Model menerima citra MRI otak sebagai input, kemudian menghasilkan output berupa mask segmentasi tumor. Mask ini menunjukkan lokasi tumor secara piksel-per-piksel, sehingga setiap piksel pada citra diklasifikasikan menjadi dua kelas, yaitu background/non-tumor dan area tumor. Dengan demikian, model tidak hanya menentukan apakah citra mengandung tumor, tetapi juga menunjukkan letak dan bentuk tumor pada citra MRI.

Tantangan segmentasi tumor yaitu tumor dapat memiliki bentuk, ukuran, lokasi, dan intensitas yang berbeda-beda pada setiap pasien. Beberapa penelitian yang sudah ada menunjukkan bahwa kombinasi CNN, U-Net, dan Transformer cocok untuk permasalahan ini, karena CNN/U-Net kuat dalam menangkap detail lokal, sedangkan Transformer mampu menangkap konteks global melalui mekanisme attention. Kedepannya juga ada modifikasi hybrid seperti TransUNet, CrossTransUnet, Neuro-TransUNet, dan MWG-UNet++ untuk meningkatkan akurasi segmentasi medis, terutama pada citra MRI dengan struktur anatomi yang kompleks.

Ukuran dan Bentuk Data

Pada laporan digunakan 1.000 pasangan citra MRI dan mask tumor. Seluruh citra dan mask diubah ukurannya menjadi 256×256 piksel.

Komponen	Keterangan
Jumlah data	1.000 citra MRI + 1.000 mask tumor
Ukuran input	256×256 piksel
Channel input	1 channel grayscale
Ukuran mask	256×256 piksel
Channel mask	1 channel binary
Bentuk tensor input	$1000 \times 256 \times 256 \times 1$
Bentuk tensor mask	$1000 \times 256 \times 256 \times 1$
Kelas mask	0 = background, 1 = tumor

Table 1 Komponen Data


Arsitektur Deep Learning

TransUNet merupakan arsitektur deep learning hybrid yang menggabungkan keunggulan CNN/U-Net dan Transformer untuk task segmentasi citra medis. Pada arsitektur ini, CNN berperan sebagai ekstraktor fitur lokal untuk menangkap detail penting pada citra, seperti tepi, tekstur, dan bentuk tumor. Sementara itu, Transformer digunakan untuk menangkap konteks global dan hubungan jarak jauh antarwilayah pada citra melalui mekanisme self-attention. Kombinasi ini penting karena segmentasi tumor otak membutuhkan kemampuan untuk mengenali detail kecil sekaligus memahami struktur anatomi otak secara menyeluruh.

1. **Input dan Preprocessing** : Tahap pertama adalah memasukkan citra MRI otak berukuran $256 \times 256 \times 1$ ke dalam model. Citra ini berbentuk grayscale, sehingga hanya memiliki satu channel intensitas. Input MRI menjadi data utama yang akan dianalisis oleh model untuk mengenali area tumor berdasarkan pola intensitas, tekstur jaringan, dan bentuk abnormal pada otak.
2. **Preprocessing** : Sebelum masuk ke jaringan, citra MRI melalui tahap preprocessing berupa resize ke 256×256 , normalisasi intensitas piksel ke rentang 0–1, serta augmentasi seperti rotasi, flip, zoom, dan perubahan brightness. Tahap ini bertujuan membuat data lebih seragam, memperbaiki kestabilan training, serta meningkatkan kemampuan generalisasi model terhadap variasi bentuk dan posisi tumor.
3. **CNN Encoder / Contracting Path** : Pada tahap encoder, citra diproses menggunakan beberapa blok Conv 3×3 , Batch Normalization, ReLU, dan MaxPooling 2×2 . Encoder berfungsi mengekstraksi fitur lokal seperti tepi tumor, tekstur jaringan, pola intensitas, dan bentuk tumor. Semakin dalam lapisan encoder, ukuran feature map semakin kecil, tetapi jumlah channel semakin besar sehingga informasi yang diperoleh menjadi lebih abstrak dan semantik.
4. **Patch Embedding / Tokenization** : Feature map hasil encoder kemudian diubah menjadi sekumpulan patch kecil melalui proses patch embedding. Setiap patch diubah menjadi token menggunakan linear projection, lalu ditambahkan positional embedding agar informasi posisi spasial tetap dipertahankan. Tahap ini diperlukan karena Transformer tidak memproses citra sebagai grid piksel, melainkan sebagai urutan token.
5. **Transformer Encoder** : Token hasil patch embedding diproses oleh Transformer encoder yang terdiri dari LayerNorm, Multi-Head Self-Attention, residual connection, dan MLP. Fungsi utama tahap ini adalah menangkap hubungan global antarwilayah citra MRI. Dengan self-attention, model dapat memahami konteks jarak jauh, misalnya hubungan antara area tumor, jaringan sekitar, dan struktur otak secara keseluruhan.

6. Feature Reshaping : Setelah diproses oleh Transformer, token yang sudah mengandung informasi global diubah kembali menjadi feature map 2D melalui tahap feature reshaping. Tahap ini penting agar hasil Transformer dapat diproses oleh decoder. Feature map yang dihasilkan membawa gabungan informasi lokal dari CNN dan konteks global dari Transformer.
7. Decoder / Expansive Path : Decoder bertugas mengembalikan resolusi feature map secara bertahap melalui proses upsampling atau transposed convolution. Pada setiap tahap decoder, feature map digabungkan dengan fitur dari encoder melalui skip connection, lalu diproses kembali menggunakan convolution. Proses ini membantu model membangun kembali detail spasial dan memperjelas batas tumor pada output segmentasi.
8. Segmentation Head : Setelah decoder menghasilkan feature map beresolusi tinggi, tahap berikutnya adalah segmentation head. Bagian ini menggunakan Conv 1×1 untuk mengubah feature map menjadi satu channel output, kemudian menggunakan aktivasi sigmoid untuk menghasilkan probabilitas setiap piksel termasuk tumor atau background.
9. Output Mask Tumor :Output akhir dari model adalah mask tumor berukuran 256×256×1. Mask ini berisi nilai biner, yaitu 0 untuk background dan 1 untuk area tumor. Dengan demikian, TransUNet menghasilkan prediksi lokasi tumor secara piksel-per-piksel, sehingga bentuk, ukuran, dan posisi tumor pada citra MRI dapat terlihat dengan jelas.

Diagram Breakdown Arsitektur



Gambar 1 Arsitektur TransUNet

Link Canva : <https://canva.link/xg3ybg8qm6dity4>

Fungsi Tiap Komponen

Komponen	Penjelasan
Input MRI	Menerima citra MRI otak berukuran 256×256×1 sebagai data masukan model.
Preprocessing	Menyamakan ukuran citra, menormalkan intensitas piksel, dan menambah variasi data melalui augmentasi.
CNN Encoder / Contracting Path	Mengekstraksi fitur lokal seperti tepi tumor, tekstur jaringan, pola intensitas, dan bentuk tumor.
Convolution Block	Memproses citra menggunakan operasi convolution untuk mengambil pola visual penting dari citra MRI.
Batch Normalization	Menstabilkan proses training dan membantu model belajar lebih cepat.
ReLU Activation	Menambahkan non-linearitas agar model mampu mempelajari pola tumor yang kompleks.
MaxPooling	Mengecilkan ukuran feature map untuk mengurangi kompleksitas dan menangkap fitur yang lebih abstrak.
Bottleneck Feature	Menyimpan representasi fitur terdalam yang berisi informasi semantik tingkat tinggi dari citra MRI.
Patch Embedding / Tokenization	Mengubah feature map CNN menjadi urutan token agar dapat diproses oleh Transformer.

Komponen	Penjelasan
Positional Encoding	Menambahkan informasi posisi agar Transformer tetap memahami letak spasial setiap patch citra.
Transformer Encoder	Menangkap konteks global dan hubungan jarak jauh antarbagian citra MRI menggunakan self-attention.
Multi-Head Self-Attention	Membantu model memperhatikan beberapa area penting pada citra secara bersamaan, termasuk area tumor dan jaringan sekitarnya.
MLP / Feed Forward	Memproses token hasil attention untuk memperkaya representasi fitur.
Residual Connection	Menjaga aliran informasi antar-layer agar training lebih stabil dan mengurangi risiko hilangnya fitur penting.
Feature Reshaping	Mengubah token hasil Transformer kembali menjadi feature map 2D agar bisa diproses oleh decoder.
Decoder / Expansive Path	Mengembalikan resolusi feature map secara bertahap hingga mendekati ukuran citra asli.
Upsampling / Transposed Convolution	Menaikkan ukuran feature map agar output segmentasi dapat kembali ke resolusi 256×256.
Skip Connection	Menggabungkan fitur detail dari encoder dengan fitur decoder agar batas tumor lebih presisi.
Segmentation Head	Mengubah feature map akhir menjadi peta probabilitas tumor menggunakan Conv 1×1 dan sigmoid.
Output Mask Tumor	Menghasilkan mask biner berukuran 256×256×1, dengan nilai 0 = background dan 1 = tumor.

Table 2 Fungsi Komponen

Alasan Pemilihan Arsitektur

Arsitektur TransUNet dipilih karena sesuai untuk segmentasi tumor otak pada citra MRI yang membutuhkan ketelitian tinggi dalam mengenali bentuk dan batas tumor. TransUNet menggabungkan keunggulan CNN/U-Net dan Transformer, di mana CNN berfungsi menangkap fitur lokal seperti tepi, tekstur, dan pola intensitas tumor, sedangkan Transformer membantu memahami konteks global serta hubungan antarwilayah pada citra MRI. Kombinasi ini penting karena tumor otak dapat memiliki ukuran, bentuk, lokasi, dan batas yang bervariasi pada setiap pasien. Selain itu, adanya decoder dan skip connection membantu mengembalikan resolusi spasial sehingga hasil mask segmentasi lebih presisi. Dengan demikian, TransUNet merupakan arsitektur yang tepat untuk menghasilkan segmentasi tumor otak secara piksel-per-piksel karena mampu mempertahankan detail lokal sekaligus memahami struktur citra secara menyeluruh.

Referensi

- Anaya-Isaza, A., Mera-Jiménez, L., & Fernandez-Quilez, A. (2023). *CrossTransUnet: A new computationally inexpensive tumor segmentation model for brain MRI*. *IEEE Access*, 11, 27066–27085. <https://doi.org/10.1109/ACCESS.2023.3257767>
- Yang, S., Li, X., Mei, J., Chen, J., Xie, C., & Zhou, Y. (2024). *3D-TransUNet for brain metastases segmentation in the BraTS2023 challenge*. arXiv preprint arXiv:2403.15735.
- Nouman, M., Mabrok, M., & Rashed, E. A. (2024). *Neuro-TransUNet: Segmentation of stroke lesion in MRI using transformers*. arXiv preprint arXiv:2406.06017.
- Lyu, Y., & Tian, X. (2025). *MWG-UNet++: Hybrid Transformer U-Net model for brain tumor segmentation in MRI scans*. *Bioengineering*, 12(2), 140. <https://doi.org/10.3390/bioengineering12020140>
- Chen, J., Lu, Y., Yu, Q., Luo, X., Adeli, E., Wang, Y., Lu, L., Yuille, A. L., & Zhou, Y. (2021). *TransUNet: Transformers make strong encoders for medical image segmentation*. arXiv preprint arXiv:2102.04306.
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2020). *An image is worth 16×16 words: Transformers for image recognition at scale*. arXiv preprint arXiv:2010.11929.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). *U-Net: Convolutional networks for biomedical image segmentation*. arXiv preprint arXiv:1505.04597