

Segmentasi Tumor Otak pada Citra MRI

Menggunakan Arsitektur *Attention U-Net*

Athiqotuz Zulaiva / 24060123140201 / Pengenalan Pola

A. Deskripsi Task

Segmentasi tumor otak pada citra MRI dilakukan menggunakan metode deep learning untuk membedakan area tumor dan yang bukan tumor pada gambar MRI otak secara otomatis. Setiap piksel diklasifikasikan ke dalam dua kelas yaitu tumor atau bukan tumor, dan hasilnya berupa mask biner yang menunjukkan lokasi tumor pada citra.


B. Ukuran dan Bentuk Data

Dataset diasumsikan terdiri dari 1.000 citra MRI otak dengan label atau mask tumor sebagai acuan untuk proses pelatihan model. Setiap citra input memiliki ukuran 256 x 256 piksel dalam bentuk grayscale dengan 1 channel, dan labelnya berupa mask biner di mana nilai 0 berarti bukan tumor dan nilai 1 berarti tumor. Data direpresentasikan dalam bentuk tensor berukuran (N, 1, 256, 256) untuk menghasilkan prediksi segmentasi pada setiap piksel citra.

C. Arsitektur Deep Learning yang Digunakan

Arsitektur yang dipakai adalah Attention U-Net, yaitu pengembangan dari U-Net dengan tambahan Attention Gate di bagian skip connection. Attention Gate berfungsi untuk menyeleksi fitur yang masuk dari encoder agar model tidak memproses semua informasi secara rata, tetapi lebih fokus ke area yang kemungkinan adalah tumor. Secara umum arsitektur ini mempunyai 3 komponen utama yaitu encoder, bottleneck, dan decoder.

D. Diagram Breakdown Arsitektur



Gambar 1. Diagram Arsitektur Attention U-Net untuk Segmentasi Tumor Otak MRI

E. Penjelasan Fungsi Setiap Komponen

a. Encoder

Encoder pada arsitektur ini mempunyai 3 level yang setiap levelnya melakukan Conv 3x3 dan ELU untuk mengenali pola pada citra seperti tepi, tekstur, dan bentuk tumor. Setelah itu menggunakan MaxPooling 2x2 yang membuat ukuran feature map semakin kecil dari 256^2 sampai 32^2 , sementara jumlah filternya terus naik dari 16, 64, 128, sampai 512.

b. Conv 3x3 + ELU

Conv 3x3 digunakan untuk mendeteksi pola pada citra MRI menggunakan filter yang dipelajari sendiri oleh model. Setelah konvolusi selesai, fungsi aktivasi ELU digunakan agar model bisa belajar lebih baik dan proses training menjadi lebih stabil.

c. MaxPooling 2x2

MaxPooling 2x2 digunakan untuk mengambil nilai terbesar dari setiap area 2x2 piksel lalu dijadikan satu nilai, jadi ukuran feature map berkurang setengahnya. Hal ini untuk mengurangi beban komputasi sekaligus tetap menjaga fitur yang paling penting.

d. Bottleneck

Bottleneck adalah bagian paling dalam dari arsitektur ini, letaknya di dimensi 32^2 dengan 128 filter. Di bagian ini representasi fitur yang paling abstrak dan kompleks dari seluruh citra disimpan sebelum nantinya diteruskan ke decoder.

e. Decoder

Decoder digunakan untuk membesarkan kembali ukuran feature map dari 32^2 sampai kembali ke 256^2 menggunakan Up-Conv 2x2. Fitur dari encoder yang sudah difilter Attention Gate digabungkan terlebih dahulu dengan fitur decoder, kemudian diproses kembali menggunakan Conv 3x3.

f. Attention Gate

Attention Gate membantu menyeleksi fitur dari encoder sebelum dikirim ke decoder. Cara kerjanya yaitu dengan menghitung bobot kepentingan setiap piksel, piksel kemungkinan tumor mendapatkan bobot yang tinggi dan background dapat bobot yang rendah, jadi model lebih fokus ke area yang penting atau diperlukan.

g. Skip Connection

Skip connection menghubungkan encoder dan decoder di level yang sama agar informasi detail dari citra tidak hilang selama proses segmentasi berlangsung.

h. Conv 1x1 + Sigmoid

Conv 1x1 digunakan untuk mereduksi jumlah channel menjadi 1, lalu Sigmoid mengubah setiap nilainya menjadi angka antara 0 dan 1. Jika nilainya mendekati 1 berarti piksel itu dianggap tumor, jika mendekati 0 berarti bukan tumor.

F. Alasan Pemilihan Arsitektur Attention U-Net

Attention U-Net dipilih karena arsitektur ini masih bisa bekerja dengan baik walaupun datanya tidak terlalu banyak, dalam kasus ini hanya menggunakan 1.000 data citra MRI. Ramalakshmi & Krishna Kumari (2025) sudah membuktikan bahwa U-Net dengan mekanisme attention bisa menghasilkan segmentasi yang baik di citra medis. Selain itu, keberadaan Attention Gate sangat membantu model untuk tidak terganggu oleh background dan lebih fokus ke area tumor. Oktay et al. (2018) menjelaskan bahwa Attention Gate dapat membantu model dalam memilih fitur yang lebih relevan pada proses segmentasi. Hal ini juga didukung oleh penelitian Gupta & Kaur (2025) yang membuktikan bahwa arsitektur Attention U-Net menghasilkan segmentasi tumor otak yang lebih akurat pada citra MRI. Skip connection pada Attention U-Net juga membantu untuk menjaga detail citra sehingga hasil segmentasi tumor terlihat lebih jelas. Oleh karena itu, Attention U-Net dipilih karena mampu menghasilkan segmentasi tumor yang lebih fokus dan detail pada citra MRI.

G. Referensi

Gupta K, S. H., & Kaur, S. (2025). Leveraging Attention ResUNET for Accurate Brain Tumor Segmentation. *Proceedings of 8th International Conference on Computing Methodologies and Communication, ICCMC 2025*, 969–974. <https://doi.org/10.1109/ICCMC65190.2025.11140708>

Oktay, O., Schlemper, J., Folgoc, L. Le, Lee, M., Heinrich, M., Misawa, K., Mori, K., McDonagh, S., Hammerla, N. Y., Kainz, B., Glocker, B., & Rueckert, D. (2018). *Attention U-Net: Learning Where to Look for the Pancreas. Medl*. <http://arxiv.org/abs/1804.03999>

Ramalakshmi, K., & Krishna Kumari, L. (2025). U-Net-based architecture with attention mechanisms and Bayesian Optimization for brain tumor segmentation using MR images. *Computers in Biology and Medicine*, 195(February), 110677. <https://doi.org/10.1016/j.compbimed.2025.110677>