

Segmentasi Tumor Otak pada Citra MRI Menggunakan Attention U-Net

Nama : Christiano Bryan Budiman

NIM : 24060123130079

Kelas : Pengenalan Pola

A. Deskripsi

Projek yang dibuat adalah segmentasi pixel pada citra MRI otak. Setiap pixel dalam citra diklasifikasikan ke dalam satu dari dua kelas, yaitu : tumor (1) atau jaringan normal (0). Model deep learning menerima citra MRI grayscale sebagai input dan menghasilkan probability map dengan dimensi yang identik, yang kemudian dithreshold untuk memperoleh mask segmentasi biner akhir.

B. Ukuran dan Bentuk Data

Atribut Data	Keterangan
Jumlah citra	1.000 pasang (input MRI + label mask)
Dimensi input	$256 \times 256 \times 1$ pixel (grayscale)
Dimensi mask	256×256 pixel, biner (0 = normal, 1 = tumor)
Format tensor	Input: (N, 256, 256, 1), Mask: (N, 256, 256, 1)
Pembagian dataset	Training 700, Validasi 150, Testing 150
Augmentasi	Rotasi 20° , secara horizontal


C. Arsitektur Deep learning

Attention U-Net dipilih sebagai arsitektur utama dalam tugas segmentasi tumor otak ini. Arsitektur ini merupakan pengembangan langsung dari U-Net standar yang menambahkan mekanisme soft attention gate pada setiap skip connection antara encoder dan decoder. Berbeda dengan U-Net standar yang meneruskan seluruh fitur spasial secara langsung, Attention U-Net memfilter fitur tersebut secara adaptif menggunakan koefisien perhatian $\alpha \in [0,1]$ per pixel yang dipelajari selama proses pelatihan, sehingga hanya fitur yang relevan secara semantik yang diteruskan ke jalur dekoder.

Arsitektur ini terbukti sangat efektif pada tugas segmentasi objek medis yang berukuran kecil, terbatas tidak tegas, dan bervariasi posisinya. Karakteristik yang tepat menggambarkan tumor otak pada citra MRI. Pada konteks dataset ini sendiri, pixel tumor jauh lebih sedikit dibandingkan pixel jaringan otak normal, menyebabkan imbalance, attention gate berperan penting dalam menekan respons model terhadap region yang tidak relevan tanpa membutuhkan anotasi supervisi tambahan. Maka dari

itu, model dapat memfokuskan kapasitas representasinya pada area yang benar-benar berpotensi mengandung tumor, sehingga mengurangi false positive secara signifikan dan meningkatkan akurasi segmentasi secara keseluruhan.

D. Diagram Arsitektur



E. Penjelasan Komponen

Komponen	Konfigurasi	Fungsi
Input MRI	256×256×1	Citra MRI otak grayscale yang telah dinormalisasi ke [0,1]
Encoder (×4 blok)	Konvolusi bertingkat, resolusi turun 0.5 tiap blok	Ekstraksi fitur hierarkis; setiap blok mengurangi resolusi ½ dan menggandakan channel
Bottleneck	16×16, kedalaman maksimal	Representasi konteks global paling abstrak dari seluruh citra MRI
Attention Gate (×4)	Bobot attention 0–1 per piksel	Menekan fitur tidak relevan pada skip connection; memfokuskan decoder ke region tumor
Decoder (×4 blok)	Resolusi naik bertahap, 4 tahap	Rekonstruksi resolusi spasial dengan menggabungkan fitur encoder yang telah difilter attention
Output layer	256×256, 1 saluran	Menghasilkan probabilitas per pixel [0,1], dengan threshold 0.5, dan mask biner tumor/non-tumor

F. Konfigurasi Training

Parameter	Nilai
Loss function	Dice Loss dan BCE
Batch size	8
Split data	700 / 150 / 150
Optimizer	Adam
Epochs	100 + early stopping
Metrik utama	Dice dan IoU

G. Alasan memilih Arsitektur

- Cocok untuk dataset medis berukuran kecil. Dengan hanya 1.000 citra, U-Net dirancang khusus untuk domain medis dimana data berlabel sangat terbatas. Arsitektur ini tidak memerlukan dataset besar berkat mekanisme skip connection yang efisien dalam memanfaatkan fitur spasial dari setiap level resolusi.
- Skip connection mempertahankan detail batas tumor. Batas tumor pada MRI seringkali tidak tegas dan membutuhkan informasi resolusi tinggi. Skip connection menghubungkan fitur encoder langsung ke decoder, sehingga detail tepi dan tekstur halus yang hilang akibat downsampling dapat dipulihkan kembali.
- Attention gate mengatasi false positive jaringan normal. Tumor otak umumnya hanya menempati sebagian kecil dari keseluruhan citra MRI, sehingga model rentan mengabaikan region tumor atau salah mengklasifikasikan jaringan normal. Attention gate secara adaptif menekan respons dari region yang tidak relevan tanpa memerlukan anotasi supervisi tambahan.
- Dice Loss mengatasi ketidakseimbangan kelas. Pixel tumor jauh lebih sedikit dibandingkan pixel normal (imbalance). Dice Loss mengoptimalkan overlap langsung antara prediksi dan ground truth sehingga model tidak hanya meminimalkan kesalahan pada kelas mayoritas.
- Kompatibilitas dengan citra medis 2D. Dataset berupa slice MRI 2D berukuran 256×256 , yang ideal untuk arsitektur U-Net 2D tanpa overhead komputasi model 3D yang membutuhkan memori GPU jauh lebih besar.

Referensi

O. Ronneberger, P. Fischer, dan T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," dalam *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Springer, 2015, hlm. 234–241.

O. Oktay et al., "Attention U-Net: Learning Where to Look for the Pancreas," dalam *Proceedings of the 1st Conference on Medical Imaging with Deep Learning (MIDL)*, 2018.

F. Milletari, N. Navab, dan S.-A. Ahmadi, "V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation," dalam *3D Vision (3DV)*, IEEE, 2016

