

Segmentasi Tumor Otak pada Citra MRI Menggunakan Arsitektur 3D U-Net

1. Deskripsi Tugas

Segmentasi tumor otak dari citra MRI bukan klasifikasi biasa. Output yang dibutuhkan bukan satu label per gambar, melainkan mask tiga dimensi di mana setiap *voxel* diberi label: apakah itu bagian dari tumor atau bukan. Ini yang disebut *voxel-wise classification* dan tingkat kesulitannya jauh lebih tinggi dari sekadar mendeteksi ada atau tidaknya tumor.

Beberapa tantangan yang langsung muncul di domain ini seperti, ukuran tumor bervariasi drastis antar pasien, batasnya sering kabur, dan distribusi kelas sangat tidak seimbang karena *voxel* latar belakang mendominasi volume. Di sisi data, MRI otak umumnya diambil dalam empat modalitas sekaligus, T1, T1ce, T2, dan FLAIR. Masing-masing memberikan informasi jaringan yang berbeda. Model yang baik harus bisa mengeksplorasi keempat modalitas itu sekaligus, bukan hanya satu.

2. Ukuran dan Bentuk Data

Dataset berisi 1.000 volume MRI otak berukuran 256×256 piksel per *slice*, dilengkapi label/*mask* tumor yang sesuai. Karena MRI otak adalah data volumetrik, setiap sampel sebenarnya adalah sebuah volume 3D, bukan gambar 2D tunggal. Untuk *training*, volume dipotong menjadi patch yang lebih kecil agar muat di memori GPU.

Aspek	Detail
Jumlah sampel	1.000 volume MRI
Resolusi per <i>slice</i>	256×256 piksel
<i>Patch training</i>	$128 \times 128 \times 128$ voxel
<i>Channel input</i>	4 (T1, T1ce, T2, FLAIR)
<i>Shape tensor input</i>	$Batch \times 4 \times 128 \times 128 \times 128$
<i>Shape tensor output</i>	$Batch \times 1 \times 128 \times 128 \times 128$
Label	0 = latar belakang, 1 = tumor

3. Arsitektur 3D U-Net

3.1. Baseline: U-Net


Pemahaman bagaimana arsitektur dasarnya bekerja. U-Net dirancang khusus untuk segmentasi citra biomedis dengan data terbatas [1]. Arsitekturnya berbentuk U karena terdiri dari dua jalur simetris: *contracting path (encoder)* di sisi kiri dan *expansive path (decoder)* di sisi kanan.

Encoder bekerja seperti CNN klasik: dua konvolusi 3×3 + ReLU diulang di setiap level, diikuti *max pooling* 2×2 untuk menurunkan resolusi. Setiap kali resolusi turun setengah, jumlah channel fitur digandakan, dari 64, 128, 256, 512, sampai 1024 di *bottleneck* [1]. *Decoder* membalik proses ini lewat *up-convolution* 2×2 yang menaikkan resolusi sambil mengurangi *channel*. Di setiap level *decoder*, *feature map* yang di *upsample* digabungkan (*concatenate*) dengan *feature map* dari *encoder* pada level resolusi yang sama, yang disebut *skip connection* [1]. Di layer paling akhir, konvolusi 1×1 memetakan tiap vektor fitur ke jumlah kelas, dengan total 23 *convolutional layer* [1].

3.2. Ekstensi ke 3D

Pada 3D U-Net, semua operasi 2D dari *baseline* diganti ke dimensi volumetrik penuh, konvolusi 3×3 menjadi $3 \times 3 \times 3$, *max pooling* 2×2 menjadi $2 \times 2 \times 2$, dan *up-convolution* juga bekerja di tiga dimensi. Input bukan lagi satu *slice* melainkan volume *patch* $4 \times 128 \times 128 \times 128$. Outputnya *mask* 3D $1 \times 128 \times 128 \times 128$, satu nilai probabilitas per *voxel*. Pola channel mengikuti *baseline*: $64 \rightarrow 128 \rightarrow 256$ di *encoder*, *bottleneck* 512, lalu $256 \rightarrow 128 \rightarrow 64$ di *decoder* [2]. *Skip connection* tetap ada di setiap level resolusi, kini menghubungkan *feature map* 3D.

4. Diagram Arsitektur



5. Penjelasan Setiap Komponen

5.1. Conv3D ($3 \times 3 \times 3$) + *Batch Normalization* + ReLU

Dua lapis konvolusi volumetrik di setiap blok mengekstrak fitur lokal dari tiga dimensi sekaligus [2]. *Batch Normalization* menstabilkan distribusi aktivasi antar-layer sehingga training lebih stabil dan konvergen lebih cepat. ReLU menghilangkan nilai negatif dan menambahkan non-linearitas.

5.2. MaxPool3D ($2 \times 2 \times 2$)

Menurunkan resolusi spasial menjadi setengahnya di ketiga dimensi. Akibatnya, *receptive field* bertambah luas, layer berikutnya "melihat" area yang lebih besar dari volume asli, sementara biaya komputasi berkurang [1].

5.3. Bottleneck (512 channel)

Level resolusi terendah, di mana representasi paling abstrak dipelajari [2]. Di sini jaringan tidak lagi peduli di mana persis voxelnya, melainkan apa yang ada di sana, tipe jaringan, anomali, bentuk umum tumor.

5.4. UpConv3D / *Transposed Convolution* ($2 \times 2 \times 2$)

Mengembalikan resolusi ke level sebelumnya sambil mengurangi jumlah *channel*. Berbeda dari upsampling bilinear yang bobotnya tetap, *transposed convolution* bobotnya dilatih sehingga proses rekonstruksi spasial ikut dioptimasi [1].

5.5. Skip Connection (*Concatenate*)

Menyambungkan *feature map* dari *encoder* ke *decoder* pada resolusi yang sama [1]. Ini satu-satunya cara *decoder* bisa mengakses kembali informasi tekstur dan lokasi resolusi tinggi yang sudah hilang akibat *pooling*. Tanpa *skip connection*, batas tumor di output cenderung melebar dan tidak presisi.

5.6. Conv3D ($1 \times 1 \times 1$) + Sigmoid (*Output Layer*)

Memetakan 64 channel ke 1 channel output. Sigmoid mengubah nilai menjadi probabilitas antara 0 dan 1, setiap *voxel* dengan nilai ≥ 0.5 dianggap tumor [3].

6. Pemilihan 3D U-Net untuk Kasus Segmentasi Tumor Otak

Terdapat 4 penjelasan mengapa 3D U-Net cocok untuk kasus ini. Pertama, tumor otak adalah objek 3D. Kalau model hanya melihat satu *slice* per satu *slice* (pendekatan 2D), model tidak pernah tahu bentuk tumor di arah aksial. Akibatnya segmentasi antar-*slice* tidak konsisten. 3D U-Net memproses volume sekaligus, jadi koneksi antar-*slice* tidak hilang dari awal. Terdapat penelitian yang secara eksplisit menunjukkan bahwa arsitektur berbasis 3D *convolution* lebih unggul menangkap korelasi antar-*slice* dibanding pendekatan 2D untuk segmentasi MRI otak [4].

Kedua, *skip connection* menjaga presisi batas tumor. Batas tumor di MRI sering kabur dan tidak tegas. Studi menunjukkan bahwa penambahan *deformable convolution* di atas 3D U-Net baseline meningkatkan akurasi segmentasi terutama di *region* dengan batas tidak jelas [5], dan itu hanya bisa bekerja karena *skip connection* sudah mempertahankan fitur resolusi tinggi dari *encoder*. Ketiga, *dataset* 1.000 sampel bukan angka yang besar untuk data medis. U-Net memang dirancang untuk situasi ini, para ahli mendemonstrasikan performa kompetitif dengan hanya puluhan gambar *training* [1]. Dengan augmentasi yang tepat seperti random flip, rotasi, dan *elastic deformation*, 1.000 sampel masih bisa dipakai secara efektif.

Keempat, rekam jejak di benchmark sejenis sudah jelas. Peneliti mencatat Dice Score 0.901 untuk *whole tumor* di BraTS2019 menggunakan varian 3D U-Net dengan *dense encoder* dan residual decoder [2]. MEASegNet mencapai Dice Score 0.925 di BraTS2021 dengan menambahkan mekanisme *attention* di atas 3D U-Net [3]. Semua varian ini berangkat dari baseline yang sama, artinya *baseline* nya sendiri sudah solid dan ada ruang besar untuk dikembangkan.

7. Konfigurasi Training

Training menggunakan optimizer Adam dengan learning rate $1e-4$ dan *loss function* gabungan *Dice Loss* + *Binary Cross-Entropy* untuk menangani ketidakseimbangan kelas. Data dibagi 70% *training*, 15% validasi, dan 15% *testing*, dengan augmentasi berupa random flip 3D, rotasi $\pm 15^\circ$, dan *Gaussian noise*. Performa model dievaluasi menggunakan Dice Score, IoU, dan *Sensitivity*.

8. Daftar Pustaka

- [1] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," May 2015, [Online]. Available: <http://arxiv.org/abs/1505.04597>
- [2] J. Tie, H. Peng, and J. Zhou, "MRI brain tumor segmentation using 3D U-net with dense encoder blocks and residual decoder blocks," *CMES - Computer Modeling in Engineering and Sciences*, vol. 128, no. 2, pp. 427–445, 2021, doi: 10.32604/cmes.2021.014107.
- [3] R. Zhang, P. Yang, C. Hu, and B. Guo, "MEASegNet: 3D U-Net with Multiple Efficient Attention for Segmentation of Brain Tumor Images," *Applied Sciences (Switzerland)*, vol. 15, no. 7, Apr. 2025, doi: 10.3390/app15073791.
- [4] M. N. Pavithra and B. R. Nayana, "Advanced 3D U-Net and Encoder-Decoder CNN Models for Brain Tumor Segmentation in MRI," in *International Conference on Communication, Computer and Information Technology, IC3IT 2025*, Institute of Electrical and Electronics Engineers Inc., 2025. doi: 10.1109/IC3IT66137.2025.11340824.
- [5] Y. He, T. Huang, Q. Yu, and W. Zhang, "Research on Brain Tumor Segmentation Using a 3D U-Net with Deformable Convolution," in *2024 5th International Conference on Information Science, Parallel and Distributed Systems, ISPDS 2024*, Institute of Electrical and Electronics Engineers Inc., 2024, pp. 27–33. doi: 10.1109/ISPDS62779.2024.10667576.