



LAPORAN ARSITEKTUR DEEP LEARNING

Breakdown Arsitektur U-Net untuk Segmentasi Tumor Otak pada Citra Magnetic Resonance Imaging (MRI)

Disusun untuk memenuhi tugas mata kuliah:

Pengenalan Polaa

Disusun oleh:

Dimas A Albanna Zain

24060123130080

**PROGRAM STUDI INFORMATIKA
FAKULTAS SAINS DAN MATEMATIKA
UNIVERSITAS DIPONEGORO
TAHUN 2026**

A. Deskripsi Task

Melakukan segmentasi citra medis secara otomatis menggunakan arsitektur *deep learning* untuk mendeteksi, mengidentifikasi, dan memisahkan wilayah tumor otak dari jaringan otak normal secara akurat. Model akan memproses citra input MRI dan mengekstrak fitur-fiturnya untuk melakukan prediksi di tingkat piksel. Model akan dilatih untuk mengenali karakteristik tumor dan membedakannya ke dalam beberapa ‘sub-wilayah’, seperti *Whole Tumor*, *Tumor Core*, dan *Enhancing Tumor*. Hasil akhir dari *task* ini adalah pemetaan lokasi, bentuk, ukuran, dan batas tumor berupa mask segmentasi yang memetakan label setiap piksel citra.

B. Ukuran dan Bentuk Data

Ketentuan tugas menyebutkan dataset berisi 1000 citra MRI berukuran 256×256 . Berdasarkan arsitektur segmentasi citra seperti U-Net, bentuk data ini memengaruhi dimensi input dan output model sebagai berikut:


- Ukuran Dataset: 1000 data dengan rasio training dan validation tertentu, dimana setiap data sampel terdiri dari citra MRI dan mask labelnya.
- Bentuk Input: Karena menggunakan CNN, model menerima citra dua dimensi 256×256 pixel dengan memiliki beberapa saluran (*channel*) yang mewakili modalitas MRI berbeda (seperti T1, T1c, T2, dan FLAIR) yang membantu memperjelas struktur tumor dan batas-batasnya.
- Bentuk Output: Sebuah tensor 256×256 pixel, di mana lapisan konvolusi 1×1 pada akhir jaringan akan memetakan *feature map* untuk memprediksi probabilitas label kelas (misalnya: latar belakang vs tumor) pada setiap koordinat piksel.

C. Arsitektur Deep Learning U-Net

Arsitektur U-Net dinamakan demikian karena bentuk jaringannya yang simetris menyerupai huruf "U". Jaringan ini terdiri dari 23 lapisan konvolusi secara total, yang terbagi menjadi tiga bagian utama:

- Encoder / Contracting Path: jalur bagian kiri ini berfungsi untuk mengekstrak fitur dan menangkap konteks dari citra input.
- Decoder / Expansive Path: jalur bagian kanan ini berfungsi untuk memulihkan resolusi citra dan memungkinkan lokalisasi letak objek (tumor) secara presisi.
- Layer Output

D. Diagram Breakdown Arsitektur



a. Contracting Path

- i. Terdiri dari 4 blok (*steps*). Setiap blok disusun atas penerapan berulang dua lapisan konvolusi 3x3 (*same padded*), yang masing-masing langsung diikuti oleh fungsi aktivasi ReLU untuk memberikan sifat non-linier.
- ii. Setelah konvolusi, dilakukan proses *downsampling* menggunakan lapisan *max pooling* 2x2 dengan *stride* 2.
- iii. Pada setiap langkah downsampling, resolusi citra akan berkurang setengah, tetapi jumlah saluran fitur (*feature channels*) akan digandakan (dari $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$) agar jaringan dapat mempelajari fitur yang lebih kompleks.

b. Bottleneck

- i. Terdiri dari dua lapisan konvolusi 3x3 yang diikuti oleh ReLU.
- ii. Pada titik ini (sesuai arsitektur asli U-Net), gambar berada pada resolusi terendahnya namun memiliki jumlah representasi fitur tertinggi, yakni 1024 *channels*.
- iii.

- c. Expansive Path
 - i. Setiap blok dimulai dengan operasi upsampling fitur yang diikuti oleh lapisan konvolusi 2×2 . Operasi ini memperbesar resolusi spasial dan secara bersamaan mengurangi separuh jumlah saluran fitur (misal dari $1024 \rightarrow 512 \rightarrow 256$, dst).
 - ii. Hasil upsampling ini kemudian digabungkan (disambungkan) dengan feature map dari sisi Encoder yang sejajar.
 - iii. Setelah digabungkan, fitur tersebut diproses kembali melewati dua lapisan konvolusi 3×3 yang masing-masing diikuti oleh aktivasi ReLU.
- d. Skip Connection
 - i. Mengirimkan informasi spasial lokal dengan resolusi tinggi langsung dari jalur Encoder (kiri) ke jalur Decoder (kanan). Hal ini krusial karena selama proses pooling di kiri, informasi letak piksel (spatial detail) banyak yang hilang. Tidak perlu adanya crop saat konkatenasi karena konvolusi 3×3 dilakukan dengan padding.
- e. Lapisan Output
 - i. Lapisan konvolusi berukuran 1×1
 - ii. Memetakan vektor fitur terakhir menjadi jumlah kelas keluaran yang diinginkan. Pada kasus segmentasi tumor (misalnya dengan 2 kelas: *background* vs tumor), konvolusi 1×1 ini akan menghasilkan resolusi akhir (256×256 piksel) dengan probabilitas klasifikasi di setiap pikselnya.

E. Alasan Mengapa Arsitektur tersebut sesuai untuk Segmentasi Tumor Otak

- a. Sangat Efisien pada Dataset Medis yang Terbatas: U-Net secara spesifik dirancang agar dapat dilatih secara end-to-end secara luar biasa baik dengan jumlah citra yang sangat sedikit yang kadang data asli terbatas.
- b. Prediksi Tingkat Piksel yang Presisi: Konfigurasi Arsitektur U-Net memungkinkan informasi konteks untuk dipropagasikan menuju lapisan yang beresolusi tinggi yang seringkali kabur dan menyatu dengan jaringan otak sehat.