

Brain Tumor MRI Segmentation Using DeepLabV3+ Architecture

Evia Auamara Unsa Nasya¹⁾ 

¹⁾Fakultas Sains dan Matematika, Universitas Diponegoro, Semarang, Indonesia

* Corresponding author : eviaauamaraunsanasya@students.undip.ac.id


1 Deskripsi Task

Perkembangan teknologi deep learning berdampak besar pada bidang medical image processing, khususnya dalam analisis citra MRI otak. Salah satu penerapannya pada segmentasi tumor otak, yaitu proses memisahkan area tumor dari jaringan otak normal pada citra medis. Segmentasi tumor memiliki peran penting dalam membantu proses diagnosis, pemantauan kondisi pasien, serta perencanaan tindakan medis (Abdelrahman & Viriri, 2022). Task yang dilakukan kali ini adalah semantic segmentation, yaitu proses proses klasifikasi setiap piksel pada citra secara individual untuk memisahkan area tumor dari jaringan otak normal pada citra MRI. Beda dengan deteksi objek yang hanya mengidentifikasi lokasi tumor secara bounding box, semantic segmentation ini menghasilkan output berupa mask piksel yang mempresentasikan batas dan area tumor secara presisi. Dalam konteks klinis, pendekatan ini sangat penting karena membantu proses diagnosis, pemantauan kondisi pasien, serta perencanaan tindakan medis yang lebih akurat. Oleh karena itu, pendekatan otomatis berbasis deep learning menjadi solusi yang lebih efisien dan konsisten.

2 Ukuran dan Bentuk Data

Segmentasi tumor otak merupakan salah satu penerapan deep learning pada bidang medical image processing yang bertujuan untuk memisahkan area tumor dari jaringan otak normal pada citra MRI. Pada tugas ini digunakan dataset yang diasumsikan terdiri dari 1.000 citra MRI otak berukuran 256×256 piksel yang terdiri dari citra input dan label atau mask tumor. Setiap citra input memiliki bentuk data $256 \times 256 \times 1$ karena menggunakan grayscale image, sedangkan output berupa mask segmentasi dengan ukuran yang sama yaitu $256 \times 256 \times 1$. Mask digunakan sebagai penanda area tumor sehingga model dapat mempelajari pola visual antara jaringan normal dan jaringan abnormal pada otak.

Perlu dicatat bahwa dalam skenario penelitian nyata seperti pada dataset BraTS yang banyak digunakan sebagai benchmark segmentasi tumor otak, setiap kasus umumnya mencakup empat modalitas MRI sekaligus, yaitu T1, T2, T1c, dan Flair, sehingga bentuk input data menjadi $256 \times 256 \times 4$ atau dalam kasus 3D menjadi $128 \times 128 \times 128 \times 4$. Setiap modalitas memberikan informasi visual yang berbeda dan saling melengkapi dalam mengidentifikasi subregion tumor seperti Enhanced Tumor (ET), Tumor Core (TC), dan Whole Tumor (WT). Penggunaan satu kanal grayscale pada tugas ini merupakan penyederhanaan yang dilakukan untuk menyesuaikan dengan cakupan dan sumber daya yang tersedia, namun secara prinsip pipeline arsitektur DeepLabV3+ yang digunakan tetap dapat diperluas untuk mengakomodasi input multi-kanal dengan penyesuaian pada lapisan pertama encoder.



Gambar 1. Example of Brain Tumor Segmentation Results on Multimodal MRI Images (Tian et al., 2023)

Gambar tersebut merupakan contoh dari citra MRI multimodal (seperti T1, T2, T1c, dan Flair) yang digunakan untuk proses segmentasi tumor otak. Setiap modality mempunyai karakteristik visual yang berbeda-beda sehingga model dapat mengenali area tumor lebih jelas. Ground truth pada gambar menunjukkan label tumor asli yang sudah dibuat sebelumnya, sedangkan hasil segmentasi memperlihatkan area tumor yang berhasil diprediksi oleh model. Perbedaan intensitas dan tekstur pada citra MRI menjadi salah satu informasi penting dalam proses segmentasi tumor.

3 Arsitektur Deep Learning


Arsitektur yang dipilih untuk mendeteksi area tumor pada citra MRI otak adalah DeepLabV3+. Prosesnya dimulai dari tahap preprocessing yang kemudian diproses menggunakan encoder untuk mengekstraksi fitur penting dari MRI. Feature map yang dihasilkan diteruskan ke modul ASPP untuk menangkap informasi pada berbagai skala yang kemudian diproses oleh decoder untuk menghasilkan segmentasi yang lebih detail. Nantinya, output akhir berupa mask segmentasi tumor yang menunjukkan area abnormal pada citra MRI. DeepLabV3+ memiliki kemampuan semantic segmentation yang cukup baik pada citra medis, khususnya untuk mendeteksi objek dengan bentuk tidak beraturan seperti tumor otak. Dengan menggunakan kombinasi encoder, Atrous Spatial Pyramid Pooling (ASPP), dan decoder untuk menghasilkan segmentasi piksel secara detail, model bekerja dengan cara mengekstraksi fitur penting dari citra MRI, mempelajari informasi multi-skala, kemudian menghasilkan output berupa mask segmentasi tumor.

Received: dd month yyyy ; Revised: dd month yyyy; Accepted: dd month yyyy; Published: dd month yyyy

Copyright (c) 2026 The authors. Published by Department of Informatics, Universitas Diponegoro

This is an open access article under the [CC-BY-SA](https://creativecommons.org/licenses/by-sa/4.0/) license.

4 Diagram Breakdown Arsitektur



Gambar 2. DeepLabV3+ Architecture for Brain Tumor MRI Segmentation


5 Penjelasan Diagram Arsitektur

Diagram tersebut menunjukkan arsitektur model DeepLabV3+ dengan backbone ResNet50 yang digunakan untuk segmentasi tumor otak pada citra MRI. Adapun prosesnya dimulai dari input citra MRI berukuran $256 \times 256 \times 1$, di sini angka 1 menunjukkan bahwa citra bersifat grayscale. Sebelum diproses oleh model, citra yang masuk terlebih dahulu melewati tahap preprocessing untuk meningkatkan kualitas dari citra yang terdiri dari normalisasi intensitas menggunakan metode z-score, resizing untuk menyeragamkan ukuran gambar, reduksi noise menggunakan gaussian filter, serta peningkatan kontras menggunakan metode CLAHE (Contrast Limited Adaptive Histogram Equalization).

Setelah melewati tahap preprocessing, citra masuk ke bagian encoder backbone yang menggunakan arsitektur ResNet50. Encoder tersebut berfungsi untuk mengekstraksi fitur-fitur penting dari citra MRI melalui beberapa lapisan convolution dan pooling. Pada tahap ini, ukuran feature map secara bertahap diperkecil, sedangkan jumlah channel fitur meningkat untuk memperoleh representasi citra yang lebih mendalam. ResNet50 menggunakan residual connection yang memungkinkan jaringan lebih mudah dilatih meskipun memiliki banyak lapisan, sehingga mampu menghasilkan ekstraksi fitur yang lebih optimal.

Fitur hasil ekstraksi dari encoder kemudian diproses oleh modul ASPP (Atrous Spatial Pyramid Pooling) yang merupakan komponen utama pada DeepLabV3+ yang berfungsi menangkap informasi objek pada berbagai skala. ASPP menggunakan beberapa atrous convolution dengan dilation rate yang berbeda, seperti rat2 1, 6, 12, dan 18 sehingga model dapat memahami konteks lokal maupun global dari area tumor. Selain itu, terdapat global average pooling yang membantu model memperoleh informasi keseluruhan citra. Seluruh hasil fitur dari ASPP kemudian digabungkan melalui proses concatenation untuk menghasilkan representasi fitur yang lebih bernilai.

Tahap berikutnya adalah decoder yang bertugas mengembalikan detail spasial citra agar hasil segmentasi menjadi lebih akurat. Decoder melakukan proses upsampling untuk memperbesar ukuran feature map, kemudian menggabungkannya dengan low-level feature dari encoder. Penggabungan ini penting karena low-level feature masih menyimpan detail tepi dan bentuk objek. Setelah dilakukan beberapa convolution untuk refinement, feature map diperbesar kembali hingga mencapai ukuran asli citra, yaitu 256×256 . Pada tahap akhir digunakan lapisan 1×1 convolution dan fungsi aktivasi sigmoid untuk menghasilkan mask segmentasi tumor berupa citra biner, di mana area putih menunjukkan tumor dan area hitam menunjukkan jaringan non-tumor.



Gambar 3. Example Segmentation Results on the BraTS 2019 Dataset (Ladkat et al., 2022)

Gambar tersebut memperlihatkan contoh hasil segmentasi tumor otak pada dataset BraTS 2019. Beberapa modality MRI digunakan sebagai input model untuk membantu proses identifikasi area tumor secara lebih akurat. Ground truth menunjukkan area tumor asli, sedangkan hasil segmentasi menunjukkan kemampuan model dalam mendeteksi lokasi tumor

pada citra MRI. Hasil segmentasi memperlihatkan bahwa DeepLabV3+ mampu menghasilkan segmentasi piksel yang cukup detail dan dapat mempertahankan bentuk area tumor meskipun memiliki struktur yang tidak beraturan.

6 Alasan Pemilihan Arsitektur

DeepLabV3+ dipilih karena arsitektur ini sesuai untuk tugas semantic segmentation yang membutuhkan prediksi pada setiap piksel citra. Kombinasi encoder, ASPP, dan decoder membantu model mempelajari informasi spasial dan konteks citra secara lebih efektif. Penggunaan ASPP membuat model mampu menangkap informasi multi-skala sehingga area tumor dengan ukuran berbeda tetap dapat dikenali. Decoder juga membantu menghasilkan batas segmentasi yang lebih halus dan detail pada output mask. Karakteristik tersebut membuat DeepLabV3+ cocok digunakan untuk segmentasi tumor otak pada citra MRI karena mampu menghasilkan segmentasi yang cukup akurat pada objek medis dengan bentuk kompleks.

Dibandingkan dengan arsitektur U-Net yang paling umum digunakan dalam segmentasi medis, DeepLabV3+ memiliki keunggulan spesifik pada modul ASPP yang memungkinkan penangkapan konteks multi-skala secara eksplisit melalui atrous convolution dengan berbagai dilation rate. Pada U-Net standar, informasi multi-skala diperoleh melalui hierarki encoder-decoder dengan skip connection, namun setiap level hanya menangkap satu skala receptive field. Sebaliknya, ASPP pada DeepLabV3+ memproses feature map yang sama secara paralel dengan beberapa dilation rate sekaligus, sehingga model dapat mengenali tumor berukuran kecil maupun besar dalam satu tahap pemrosesan. Hal ini menjadikan DeepLabV3+ lebih adaptif terhadap variasi ukuran tumor yang tidak dapat diprediksi sebelumnya, sebuah kondisi yang sangat umum ditemukan dalam dataset klinis nyata.

7 Conclusion

Berdasarkan pembahasan yang telah dilakukan, arsitektur DeepLabV3+ dapat digunakan untuk segmentasi tumor otak pada citra MRI karena mampu menghasilkan segmentasi piksel yang cukup detail dan akurat. Kombinasi encoder, Atrous Spatial Pyramid Pooling (ASPP), dan decoder membantu model mengekstraksi fitur penting, menangkap informasi multi-skala, serta memperbaiki detail batas area tumor pada hasil segmentasi. Penggunaan citra MRI berukuran 256×256 piksel beserta mask tumor memungkinkan model mempelajari perbedaan antara jaringan normal dan area abnormal pada otak. DeepLabV3+ juga sesuai untuk tugas semantic segmentation karena mampu menghasilkan output berupa mask segmentasi dengan ukuran yang sama seperti citra input sehingga lokasi tumor dapat ditampilkan secara jelas pada citra MRI.

Meskipun demikian, pendekatan yang digunakan pada tugas ini masih memiliki beberapa keterbatasan yang perlu diperhatikan. Dataset diasumsikan hanya terdiri dari citra grayscale satu kanal, sehingga model belum memanfaatkan informasi komplementer yang tersedia pada data multimodal seperti T1, T2, T1c, dan Flair yang umumnya digunakan pada penelitian klinis. Selain itu, evaluasi performa model belum dilakukan secara kuantitatif menggunakan metrik standar seperti Dice Similarity Coefficient (DSC) dan Hausdorff Distance (HD) yang lazim digunakan sebagai tolok ukur pada benchmark BraTS. Untuk pengembangan ke depan, eksplorasi arsitektur tiga dimensi seperti 3D U-Net atau AABTS-Net yang mampu memproses data volumetrik secara langsung dapat menjadi langkah lanjutan yang signifikan, mengingat citra MRI otak pada dasarnya adalah data 3D yang jika diproses secara slice-by-slice berpotensi kehilangan informasi konteks antar irisan.

Bibliography

- Abdelrahman, A., & Viriri, S. (2022). Kidney tumor semantic segmentation using deep learning: A survey of state-of-the-art. *Journal of Imaging*, 8(3), 55.
- Ladkat, A. S., Bangare, S. L., Jagota, V., Sanober, S., Beram, S. M., Rane, K., & Singh, B. K. (2022). Deep neural network-based novel mathematical model for 3D brain tumor segmentation. *Computational Intelligence and Neuroscience*, 2022, Article 4271711.
- Tian, W., Li, D., Lv, M., & Huang, P. (2023). Axial attention convolutional neural network for brain tumor segmentation with multi-modality MRI scans. *Brain Sciences*, 13(1), 12.