

Segmentasi Tumor Otak pada Citra MRI Menggunakan TransUNet: Hybrid Tranformer-CNN Architecture

Ferza Farrell Wibowo - 24060123140211
Program Studi Informatika, Universitas Diponegoro
Mata Kuliah: Pengenalan Pola

Abstrak. Laporan ini membahas penerapan arsitektur TransUNet untuk segmentasi tumor otak pada dataset citra MRI berukuran 256×256 piksel. TransUNet merupakan arsitektur hybrid yang menggabungkan kekuatan Convolutional Neural Network (CNN) berbasis ResNet50 sebagai feature extractor dengan Vision Transformer (ViT) sebagai global context encoder. Pendekatan ini mengatasi keterbatasan U-Net klasik dalam menangkap *long-range dependency* antar piksel pada citra MRI. Dengan input 1.000 citra MRI ($256 \times 256 \times 1$), arsitektur memproses citra melalui CNN encoder, patch tokenization, 12-layer Transformer encoder, kemudian decoder berbasis upsampling dengan *skip connection* hybrid, menghasilkan segmentation mask biner berukuran 256×256 .

Kata Kunci: TransUNet, Vision Transformer, Segmentasi Semantik, Tumor Otak, MRI, Deep Learning, Hybrid Architecture

I. Pendahuluan

Segmentasi tumor otak pada citra Magnetic Resonance Imaging (MRI) merupakan tahap penting dalam proses diagnosis, perencanaan terapi radiasi, dan evaluasi respons pengobatan. Secara manual, proses ini membutuhkan waktu yang lama dan sangat bergantung pada keahlian radiologis, sehingga otomatisasi berbasis *deep learning* menjadi sangat diperlukan.

Arsitektur U-Net (Ronneberger et al., 2015) menjadi standar utama untuk segmentasi citra medis karena memiliki struktur encoder-decoder simetris dengan *skip connection* yang mampu mempertahankan informasi spasial resolusi tinggi. Namun, U-Net berbasis CNN memiliki keterbatasan pada *receptive field* yang bersifat lokal sehingga sulit menangkap hubungan jarak jauh (*long-range dependency*) antar region pada citra MRI.

Untuk mengatasi keterbatasan tersebut, TransUNet (Chen et al., 2021) diperkenalkan sebagai arsitektur hybrid yang mengintegrasikan Vision Transformer (ViT) ke dalam framework U-Net. Transformer memungkinkan model mempelajari *global self-attention* antar seluruh patch citra secara simultan sehingga menghasilkan representasi konteks yang lebih kaya dibandingkan CNN konvensional.

II. Deskripsi Task

Task yang diselesaikan adalah *semantic segmentation* biner, yaitu setiap piksel pada citra MRI otak berukuran 256×256 diklasifikasikan ke salah satu dari dua kelas:

1. Tumor (1)
2. Non-tumor / background (0)

Output yang dihasilkan berupa *segmentation mask* dengan ukuran yang sama seperti citra input.

Tantangan utama pada task ini meliputi:

1. Variasi ukuran dan bentuk tumor yang sangat beragam antar pasien.
2. Batas tumor yang sering kali tidak tegas pada citra MRI.
3. Ketidakseimbangan kelas antara piksel tumor dan background.
4. Kebutuhan pemahaman konteks global untuk membedakan tumor dari struktur anatomi normal yang memiliki intensitas serupa.

III. Ukuran dan Bentuk Data

Komponen	Shape	Keterangan
Input (X)	(1000,256,256,1)	MRI grayscale, normalisasi [0,1]
Label (Y)	(1000,256,256,1)	Biner: 1=tumor, 0=background
Train	(800,256,256,1)	80%, + augmentasi
Validation	(100,256,256,1)	10%, early stopping
Test	(100,256,256,1)	10%, evaluasi final
Patch Size	16×16 piksel	196 patch per citra
Token Dimension	196 × 512	Input ke Transformer

Tabel 1. Ukuran dan bentuk data pada setiap tahap pipeline.

Citra MRI dikonversi menjadi grayscale single-channel karena MRI standar tidak mengandung informasi warna. Sebelum proses patch tokenization, dilakukan normalisasi Z-score per citra untuk meningkatkan stabilitas training pada Transformer.

IV. Arsitektur TransUNet

TransUNet terdiri dari tiga komponen utama yang bekerja secara hierarkis:

1. CNN Encoder berbasis ResNet50 untuk ekstraksi fitur lokal multi-skala.
2. Transformer Encoder untuk pemodelan konteks global menggunakan self-attention.
3. Cascaded Decoder dengan *skip connection* hybrid untuk rekonstruksi segmentation mask resolusi penuh.

A. CNN Encoder (ResNet50 Backbone)

ResNet50 digunakan sebagai *feature extractor* dengan empat stage konvolusi. Setiap stage menghasilkan feature map dengan resolusi yang semakin kecil namun jumlah channel yang semakin besar:

1. Stage 1 $\rightarrow 256 \times 256 \times 64$
2. Stage 2 $\rightarrow 128 \times 128 \times 128$
3. Stage 3 $\rightarrow 64 \times 64 \times 256$
4. Stage 4 $\rightarrow 32 \times 32 \times 512$


ResNet menggunakan residual connection untuk mengatasi masalah *vanishing gradient* pada jaringan yang dalam. Feature map dari Stage 1–3 disimpan sebagai *skip connection* untuk decoder.

B. Patch Embedding dan Tokenisasi

Feature map dari Stage 4 berukuran $32 \times 32 \times 512$ dibagi menjadi patch berukuran 16×16 piksel sehingga menghasilkan 196 token.

Setiap patch diproyeksikan ke embedding dimension 512 menggunakan linear projection. Selain itu, positional encoding ditambahkan agar informasi posisi spasial tetap dipertahankan setelah tokenisasi.

$$z_0 = [x_{1E}; x_{2E}; \dots; x_{NE}] + E_{pos}$$



C.

D. Transformer Encoder (12 Layers)

Transformer encoder terdiri dari 12 layer yang masing-masing memiliki:

1. Multi-Head Self-Attention (MSA)
2. Layer Normalization (LN)
3. Feed Forward Network (MLP)

Dengan 12 attention head, model mampu menangkap hubungan jarak jauh antar region tumor dan jaringan otak secara simultan, sesuatu yang sulit dilakukan CNN konvensional.

E. Cascaded Decoder dengan Skip Connection

Output Transformer berukuran 196×512 diubah kembali menjadi feature map $14 \times 14 \times 512$, kemudian dilakukan proses upsampling bertahap melalui empat Up-Block.

Setiap Up-Block terdiri dari:

1. Bilinear upsampling $2 \times$
2. Konkatenasi dengan skip connection dari CNN encoder
3. Dua konvolusi 3×3 + Batch Normalization + ReLU

Pendekatan hybrid CNN + Transformer memungkinkan model mempertahankan detail lokal sekaligus memahami konteks global citra.

TransUNet memiliki kemampuan memahami konteks global melalui Transformer sambil tetap mempertahankan detail spasial menggunakan CNN. Sebaliknya, U-Net murni hanya bergantung pada receptive field lokal konvolusi.

V. Kesesuaian Arsitektur Dengan Task

A. Global Context untuk Deteksi Tumor Ambigu. Tumor otak sering memiliki intensitas yang mirip dengan jaringan normal. Self-attention pada Transformer memungkinkan model mempertimbangkan seluruh konteks citra ketika melakukan klasifikasi piksel sehingga mengurangi false positive.

B. Multi-Scale Feature Fusion. Skip connection dari berbagai level CNN encoder membantu menggabungkan informasi detail tepi halus hingga bentuk tumor secara global.

C. Efektif pada Dataset Medis Kecil. Transfer learning dari ResNet50 dan ViT yang telah di-*pretrained* pada ImageNet memungkinkan model tetap belajar secara efektif walaupun jumlah data training terbatas.

D. Output Resolusi Identik dengan Input. Decoder bertingkat dengan empat tahap upsampling menghasilkan segmentation mask 256×256 yang sesuai dengan resolusi input MRI.

VI. Fungsi Loss dan Metrik Evaluasi

Karena terdapat ketidakseimbangan kelas antara tumor dan background, digunakan kombinasi Dice Loss dan Binary Cross-Entropy.

$$L_{total} = LBCE + \lambda LDice$$

$$L_{Dice} = 1 - (2|P \cap G| + \varepsilon) / (|P| + |G| + \varepsilon)$$

di mana P adalah prediksi model, G adalah ground truth mask, dan ε adalah nilai kecil untuk menghindari pembagian dengan nol. Hiperparameter: $\lambda=1$, optimizer AdamW (lr= 1×10^{-4} , weight decay= 1×10^{-4}), batch size=16, epoch=200 dengan early stopping (patience=20). Inisialisasi bobot menggunakan distribusi Gaussian dengan std= $\sqrt{(2/N)}$ sesuai rekomendasi He et al. [3].

Metrik evaluasi: Dice Coefficient, IoU/Jaccard Index, Precision, Recall/Sensitivity, dan Hausdorff Distance (HD95).

VII. Perbandingan Arsitektur

Arsitektur	Global Context	Parameter (M)	Dice Score (BraTS)
U-Net	Tidak	31	~0.82
Attention U-Net	Sebagian	34	~0.85
ResUNet	Tidak	37	~0.86
TransUNet	Ya (ViT)	105	~0.90

TransUNet menunjukkan performa terbaik karena kemampuan *global self-attention* yang dimiliki Transformer.

VIII. Kesimpulan

TransUNet dipilih sebagai arsitektur untuk segmentasi tumor otak MRI karena mampu menggabungkan kekuatan CNN dalam ekstraksi fitur lokal multi-skala dengan kemampuan Transformer dalam memahami konteks global citra.

Kemampuan global self-attention sangat penting pada task segmentasi tumor otak karena model perlu memahami hubungan antar region dalam keseluruhan citra untuk membedakan tumor dari jaringan normal.

Dengan pipeline yang mencakup patch tokenization, 12-layer Transformer encoder, serta cascaded decoder dengan hybrid skip connection, TransUNet mampu menghasilkan segmentation mask 256×256 yang presisi dari input MRI berukuran $256 \times 256 \times 1$.

Referensi

- [1] O. Ronneberger, P. Fischer, T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” *MICCAI, LNCS 9351*, pp. 234–241, 2015.
- [2] J. Chen, Y. Lu, Q. Yu, et al., “TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation,” *arXiv:2102.04306*, 2021.
- [3] A. Dosovitskiy, L. Beyer, A. Kolesnikov, et al., “An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale,” *ICLR 2021*.
- [4] O. Oktay, J. Schlemper, L. Le Folgoc, et al., “Attention U-Net: Learning Where to Look for the Pancreas,” *MIDL 2018*.
- [5] Z. Zhang, Q. Liu, Y. Wang, “Road Extraction by Deep Residual U-Net,” *IEEE Geoscience and Remote Sensing Letters*, 15(5), pp. 749–753, 2018.
- [6] S. Bakas, et al., “Identifying the Best Machine Learning Algorithms for Brain Tumor Segmentation,” *arXiv:1811.02629*, 2018.