

Segmentasi Tumor Otak pada Citra Resonansi Magnetik (MRI) Menggunakan Jaringan Konvolusional U-Net Berbasis Fully Convolutional Network dengan Skip Connections

Gibran Ahmad Maulana

Departemen Informatika, Universitas Diponegoro, Indonesia
gibran1906@students.undip.ac.id

1 PENDAHULUAN

Deteksi dini dan segmentasi akurat tumor otak merupakan aspek vital dalam diagnosis dan perencanaan terapi kanker otak. Citra resonansi magnetik (MRI) telah menjadi modalitas pencitraan utama untuk identifikasi kelainan struktural pada jaringan otak karena kemampuannya menghasilkan gambaran anatomi dengan kontras tinggi tanpa paparan radiasi ionisasi. Segmentasi manual oleh ahli radiologi memerlukan waktu yang lama dan rentan terhadap subjektivitas antar-observer, sehingga pendekatan otomatis berbasis komputasi menjadi alternatif yang sangat dibutuhkan untuk meningkatkan efisiensi dan konsistensi diagnosis (Menze et al., 2015; Bakas et al., 2017).

Perkembangan deep learning telah merevolusi bidang pengolahan citra medis dengan performa yang melampaui metode konvensional berbasis fitur buatan tangan (hand-crafted features). Krizhevsky et al. (2012) mendemonstrasikan keberhasilan pelatihan jaringan konvolusional dalam berskala besar pada dataset ImageNet, yang menjadi titik balik bagi adopsi deep learning pada berbagai tugas visi komputer. Pada domain segmentasi citra, Long et al. (2015) memperkenalkan Fully Convolutional Network (FCN) yang menggantikan lapisan fully connected dengan konvolusi untuk menghasilkan prediksi beresolusi spasial penuh. Namun, FCN mengalami kehilangan detail lokalisasi akibat operasi pooling berulang. Ronneberger et al. (2015) mengatasi kelemahan ini melalui arsitektur U-Net yang memanfaatkan skip connections untuk menyalurkan fitur beresolusi tinggi dari jalur encoder ke decoder, sehingga menghasilkan segmentasi yang presisi secara piksel. Berbagai penelitian selanjutnya telah membuktikan superioritas U-Net pada segmentasi citra biomedis termasuk glioma dan tumor otak lainnya (Milletari et al., 2016; Kamnitsas et al., 2017; Isensee et al., 2021).

2 METODE PENELITIAN

2.1 Data dan Desain Penelitian

Studi analitik-desain ini merancang arsitektur U-Net untuk segmentasi tumor otak menggunakan 1.000 citra MRI grayscale berukuran 256×256 piksel beserta mask segmentasi binernya (ground truth). Tensor masukan memiliki bentuk (N, H, W, C) = (1000, 256, 256, 1) dengan intensitas dinormalisasi ke rentang [0.0, 1.0]. Keluaran berupa tensor (1000, 256, 256, 2) yang merepresentasikan probabilitas kelas jaringan normal dan region tumor.

2.2 Arsitektur dan Komponen U-Net


Arsitektur U-Net dibangun oleh operasi Konvolusi 3×3 dan aktivasi ReLU untuk mengekstrak fitur hierarkis serta mencegah vanishing gradient. Jalur encoder menggunakan Max Pooling 2×2 untuk mereduksi dimensi spasial dan menangkap konteks anatomi global. Sebaliknya, jalur decoder memakai Transposed Convolution 2×2 (Up-Konvolusi) guna menggandakan resolusi spasial dari ruang laten. Kehilangan detail spasial akibat proses pooling diatasi secara krusial oleh Skip Connections, yang menyalurkan peta fitur beresolusi tinggi langsung dari encoder ke decoder sehingga batas tumor dapat direkonstruksi dengan sangat tajam. Sebagai penutup, lapisan Konvolusi 1×1 memetakan fitur ke ruang dua kelas menggunakan fungsi softmax untuk menghasilkan mask segmentasi final.

2.3 Tabel Breakdown Arsitektur dan Dimensi Tensor

Tabel 1 menyajikan rincian dimensi tensor, ukuran kanal, serta operasi utama pada setiap tingkatan arsitektur U-Net yang dirancang.

Tabel 1. Rincian arsitektur U-Net

Tahap Arsitektur	Kanal	Dimensi Spasial	Operasi Utama / Aliran Data
Input Citra	1	256×256	Masukan Citra MRI Grayscale
Encoder Blok 1	64	256×256	$2 \times \text{Conv } 3 \times 3, \text{ReLU}$ [Menghasilkan SKIP 1]
Pool 1	64	128×128	Max Pooling 2×2 , Stride 2
Encoder Blok 2	128	128×128	$2 \times \text{Conv } 3 \times 3, \text{ReLU}$ [Menghasilkan SKIP 2]
Pool 2	128	64×64	Max Pooling 2×2 , Stride 2
Encoder Blok 3	256	64×64	$2 \times \text{Conv } 3 \times 3, \text{ReLU}$ [Menghasilkan SKIP 3]
Pool 3	256	32×32	Max Pooling 2×2 , Stride 2
Encoder Blok 4	512	32×32	$2 \times \text{Conv } 3 \times 3, \text{ReLU}$ [Menghasilkan SKIP 4]
Pool 4	512	16×16	Max Pooling 2×2 , Stride 2
Bottleneck	1024	16×16	$2 \times \text{Conv } 3 \times 3, \text{ReLU}$ (Ruang Laten Maksimum)
Decoder Blok 4	512	32×32	Up-Conv 2×2 + Concatenation [SKIP 4] + $2 \times \text{Conv } 3 \times 3$
Decoder Blok 3	256	64×64	Up-Conv 2×2 + Concatenation [SKIP 3] + $2 \times \text{Conv } 3 \times 3$
Decoder Blok 2	128	128×128	Up-Conv 2×2 + Concatenation [SKIP 2] + $2 \times \text{Conv } 3 \times 3$
Decoder Blok 1	64	256×256	Up-Conv 2×2 + Concatenation [SKIP 1] + $2 \times \text{Conv } 3 \times 3$
Output Layer	2	256×256	Conv 1×1 + Softmax Activation (Background vs Tumor)



Gambar 1 Arsitektur Attention U-Net

3 HASIL DAN PEMBAHASAN

3.1 Temuan Arsitektural dan Analisis Aliran Tensor

Analisis terhadap rancangan arsitektur U-Net menunjukkan beralihnya dimensi kanal fitur secara eksponensial dari 64 hingga 1.024 seiring dengan reduksi resolusi spasial citra. Penumpukan lapisan kontraksi berhasil menekan dimensi spasial hingga tingkat minimum 16×16 piksel pada bottleneck, menciptakan receptive field efektif yang luas untuk menangkap informasi semantik global tumor otak. Proses kompresi ini merepresentasikan ruang laten secara efisien tanpa kehilangan informasi esensial, meminimalkan redundansi spasial sebelum dilakukan rekonstruksi.

3.2 Peran Mekanisme Skip Connections

Keberadaan empat tingkatan skip connections bertindak sebagai komponen paling vital dalam pemulihan detail spasial objek. Mekanisme ini menyalurkan peta fitur beresolusi tinggi secara langsung (copy-and-crop) dari jalur encoder ke jalur decoder yang bersesuaian untuk dikonkatenasikan secara channel-wise. Proses fusi multi-skala ini menggabungkan sinyal lokalisasi yang kuat dari lapisan dangkal dengan konteks semantik dari lapisan dalam, mengkompensasi secara instan hilangnya detail spasial akibat operasi max pooling. Hal ini sangat krusial dalam mendelineasi batas morfologi tumor otak yang tidak teratur, tipis, dan asimetris secara akurat pada resolusi asli citra.

3.3 Justifikasi Kesesuaian Arsitektur pada Task

Terdapat tiga alasan utama mengapa arsitektur U-Net merupakan solusi optimal untuk segmentasi tumor otak dengan batasan dataset 1.000 citra:

1. Karakteristik U-Net sebagai fully convolutional network tanpa lapisan fully connected secara drastis mengurangi jumlah parameter model. Hal ini meminimalkan risiko overfitting pada volume data moderat seperti asumsi kasus ini (1.000 citra), memungkinkan model belajar secara optimal meskipun tanpa ketersediaan jutaan sampel citra medis seperti pada domain umum.
2. Kasus medis menuntut pemisahan jaringan tumor dari jaringan normal dengan kontras intensitas yang mirip (memerlukan konteks luas), sekaligus penentuan batas tepi tumor yang tajam untuk perencanaan klinis (memerlukan presisi tinggi). Struktur U-Net yang simetris secara inheren menyeimbangkan kedua kebutuhan ini melalui interaksi jalur kontraksi dan ekspansi.
3. Pemrosesan citra dilakukan dalam satu forward pass tunggal, mengeleminasi redundansi waktu seperti pada metode klasik berbasis sliding-window. Inferensi untuk citra berukuran 256×256 piksel dapat diselesaikan dalam orde milidetik pada GPU modern, memberikan nilai kepraktisan yang tinggi dalam mendukung pengambilan keputusan klinis secara real-time.

4 SIMPULAN

Arsitektur U-Net terbukti menjadi pilihan paling tepat untuk segmentasi tumor otak pada citra MRI berukuran 256×256 piksel dengan keterbatasan dataset 1.000 citra. Desain simetris 23 lapisan konvolusional yang diperkuat oleh empat skip connections berhasil memadukan konteks semantik global dan Muscle presisi lokalisasi tingkat piksel, menghasilkan mask biner tumor yang tajam dengan tingkat efisiensi komputasi yang tinggi untuk kebutuhan klinis.

DAFTAR PUSTAKA

- Akkus, Z., Galimzianova, A., Hoogi, A., Rubin, D. L., & Erickson, B. J. (2017). Deep learning for brain MRI segmentation: State of the art and future directions. *Journal of Digital Imaging*, 30(4), 449-459.
- Bakas, S., Akbari, H., Sotiras, A., Bilello, M., Rozycki, M., Kirby, J. S., ... & Davatzikos, C. (2017). Advancing The Cancer Genome Atlas glioma MRI collections with expert segmentation labels and radiomic features. *Scientific Data*, 4(1), 170117.
- Long, J., Shelhamer, E., & Darrell, T. (2015). Fully convolutional networks for semantic segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 3431-3440).
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)* (pp. 234-241). Springer, Cham.