

Nama: Gusti Ayu Genta Bhuana Paramitha

NIM: 24060123130110

Kelas: Pengenalan Pola - A

Segmentasi Tumor Otak pada Citra MRI Menggunakan Arsitektur Attention U-Net

1. Deskripsi Task

Task yang diselesaikan adalah segmentasi semantik biner (*binary semantic segmentation*) pada citra MRI otak, yaitu mengidentifikasi dan melokalisasi piksel-piksel yang termasuk area tumor dari piksel latar belakang jaringan otak normal. Model menerima citra MRI otak *grayscale* sebagai input dan menghasilkan binary mask berukuran sama sebagai output, di mana nilai 1 menunjukkan piksel tumor dan nilai 0 menunjukkan area non-tumor. Task ini termasuk kategori *pixel-wise classification* yang membutuhkan pemahaman konteks global (letak tumor) sekaligus presisi lokal (batas tepi tumor yang tajam).

2. Ukuran dan Bentuk Data


Berdasarkan ketentuan tugas, asumsi ketersediaan data adalah 1.000 sampel data yang berisi pasangan citra MRI masukan dan label mask ground truth.

Parameter	Spesifikasi
Jumlah Total Citra	1000 pasang (input + mask)
Pembagian Dataset	Train: 700, Val: 150, Test: 150
Dimensi Input	$256 \times 256 \times 1$ piksel (grayscale, 1 channel)
Dimensi Label/Mask	$256 \times 256 \times 1$ piksel (binary mask: 0 atau 1, 1 channel)
Tensor Input per Batch	(B, 1, 256, 256); B = batch size
Tensor Output per Batch	(B, 1, 256, 256); nilai [0,1] (sigmoid)
Nilai Piksel Input	Dinormalisasi ke rentang [0,1]
Nilai Piksel Mask	0 = non-tumor, 1 = tumor
Augmentasi	Rotasi, flip, elastic deformation, brightness jitter
Normalisasi	Min-max scaling ke rentang [0, 1] per citra

3. Arsitektur Deep Learning yang Digunakan

Arsitektur yang dipilih adalah Attention U-net (Oktay et al., 2018), yakni pengembangan dari U-Net klasik (Ronneberger et al., 2015) dengan penambahan *Attention Gate* (AG) pada setiap *skip connection*. Attention U-Net memiliki tiga jalur utama: Encoder (contracting path), Bottleneck, dan Decoder (expansive path), yang saling terhubung melalui skip connection berperhatian (*attentive skip connection*). Total kedalaman jaringan adalah 4 level resolusi dengan 23+ lapisan konvolusi. AG secara otomatis menekan fitur-fitur yang tidak relevan dari encoder dan memperkuat fitur-fitur yang berkorelasi dengan target (wilayah tumor) sebelum digabungkan ke jalur decoder. Arsitektur ini dipilih karena secara khusus dirancang untuk segmentasi objek medis berukuran kecil hingga sedang pada citra beresolusi tinggi dengan jumlah data terbatas.

4. Diagram Breakdown Arsitektur (<https://s.id/DiagramBreakdownArsitektur>)



5. Penjelasan Singkat Fungsi Setiap Komponen

- **Input MRI ($1 \times 256 \times 256$)**
Citra MRI otak grayscale dinormalisasi ke $[0,1]$ dan diumpankan sebagai tensor $1 \times 256 \times 256$ ke encoder pertama.
- **Encoder - Contracting Path (Enc-1 s.d. Enc-4)**
Empat level Conv $3 \times 3 \rightarrow$ BN $\rightarrow$ ReLU diikuti MaxPool 2×2 . Filter digandakan tiap level ($64 \rightarrow 128 \rightarrow 256 \rightarrow 512$ ch) untuk mengekstrak fitur hierarkis dari tepi hingga bentuk tumor abstrak. Output tiap level diteruskan sebagai skip connection ke Attention Gate.
- **MaxPool 2×2 ($\times 4$)**
Mereduksi dimensi spasial setengahnya setelah tiap encoder block, memperluas receptive field dan menekan biaya komputasi.
- **Bottleneck - (Conv $3 \times 3 \times 2 \times 2$ + BN + ReLU + Dropout, 1024ch, 16×16)**
Lapisan terdalam yang menangkap representasi paling abstrak dan padat. Dropout ditambahkan sebagai regularisasi untuk mencegah overfitting pada dataset terbatas.

- Attention Gates (AG-1 s.d. AG-4)
Setiap gate menerima dua sinyal: fitur encoder dari skip connection (x) dan sinyal gating dari decoder (g), lalu menghitung bobot perhatian $\alpha \in [0,1]$ via $\sigma(W_g \cdot g + W_x \cdot x)$ dari sinyal encoder (x) dan decoder (g). Bobot α menekan fitur jaringan sehat dan mempertajam area tumor sebelum masuk ke decoder.
- UpConv 2×2 upsample $\times 2$ ($\times 4$)
Transposed convolution yang menggandakan resolusi spasial secara bertahap dari 16×16 kembali ke 256×256 .
- Decoder - Expansive Path (Dec-4 s.d. Dec-1)
Empat level UpConv $2 \times 2 \rightarrow$ Concat (fitur AG) $\rightarrow$ Conv $3 \times 3 \times 2 \rightarrow$ BN $\rightarrow$ ReLU. Filter dikurangi tiap level ($512 \rightarrow 256 \rightarrow 128 \rightarrow 64$ ch), memadukan konteks semantik decoder dengan detail spasial encoder.
- Output Layer (Conv 1×1 + Sigmoid, 1ch, 256×256)
Memetakan 64 channel ke satu channel probabilitas per piksel. Sigmoid mengubah nilai ke $[0,1]$; piksel $> 0,5$ diklasifikasikan sebagai tumor.
- Output Mask ($1 \times 256 \times 256$, binary tumor mask)
Hasil akhir berupa mask biner berukuran 256×256 di mana nilai 1 menunjukkan piksel tumor dan 0 menunjukkan jaringan normal, digunakan untuk evaluasi dengan metrik Dice Score dan IoU.

6. Alasan Pemilihan Arsitektur

- 1) Cocok untuk dataset kecil
U-Net dan variannya terbukti efektif dengan data terbatas. Ronneberger et al. (2015) menunjukkan U-Net mampu melampaui metode terbaik hanya dengan 30 gambar pelatihan, sehingga sangat sesuai untuk dataset 1.000 citra MRI ini.
- 2) Attention gate meningkatkan presisi segmentasi
Tumor otak memiliki batas yang tidak jelas dan ukuran bervariasi. Attention Gate secara adaptif menyaring fitur skip connection sehingga decoder hanya fokus pada area tumor, menekan false positive pada jaringan sehat di sekitarnya.
- 3) Arsitektur encoder - decoder preserves spatial resolution
Struktur encoder-decoder dengan skip connection mempertahankan informasi lokasi resolusi tinggi yang hilang akibat MaxPool, menghasilkan segmentasi yang presisi hingga level piksel tanpa perlu mempelajari ulang detail dari nol.
- 4) Efisien untuk citra medis berukuran tinggi
Tanpa fully connected layer, Attention U-Net dapat memproses citra berukuran apapun dan jauh lebih hemat memori dibanding arsitektur berbasis transformer untuk resolusi yang sama.
- 5) Lebih unggul dari arsitektur sejenis.
Dibanding vanilla U-Net (tanpa attention), SegNet (tanpa skip connection langsung), dan DeepLab (kurang cocok untuk dataset kecil), Attention U-Net memberikan keseimbangan terbaik antara akurasi, efisiensi, dan kesesuaian dengan karakteristik data medis berskala kecil.