

Breakdown Arsitektur Deep Learning U-NET untuk Segmentasi Tumor Otak pada Citra MRI

1. DESKRIPSI TASK DAN SPESIFIKASI DATA

1.1. DESKRIPSI TASK

Fokus utama yang dibahas adalah segmentasi semantik tumor otak pada citra medis. Proses segmentasi ini melibatkan klasifikasi tingkat piksel ke dalam dua kelas, yaitu latar belakang (background atau non-tumor) dan area tumor otak. Output berupa mask segmentasi dengan representasi one-hot berdimensi $[N, 2, 256, 256]$. Fungsi softmax diterapkan pada dimensi *channel* untuk menghasilkan nilai probabilitas pada setiap piksel. Dataset MRI glioma memiliki variasi morfologi dan intensitas yang tinggi, sesuai dengan koleksi TCGA [4]. Dengan demikian diperlukan arsitektur yang mampu menangkap detail spasial pada berbagai skala.

1.2. SPESIFIKASI DATASET


Parameter	Spesifikasi	Keterangan
Jumlah Citra	1.000 pasangan (input + mask)	Citra MRI + label segmentasi tumor
Resolusi	256×256 piksel	Sesuai instruksi pada penugasan
Mode Warna (input)	GreyScale (1 Channel)	Citra dari MRI biasanya 1 channel yaitu grey
Format label	Mask one hot (2 channel)	Channel 0: background, Channel 1: tumor
Split data	70%/15%/15%	Training/Validasi/Testing

2. ARSITEKTUR U-NET

2.1. ALASAN PEMILIHAN U-NET

U-Net dipilih sebagai arsitektur baseline karena dirancang untuk segmentasi citra biomedis oleh Ronneberger et al. (2015) [1]. Pengujian pada studi terbaru menunjukkan bahwa U-Net mencapai performa unggul dalam segmentasi tumor otak pada MRI dibandingkan arsitektur konvensional [3]. Arsitektur ini memiliki karakteristik fully convolutional tanpa fully connected layer, sehingga mendukung dimensi input variabel dan menghasilkan output segmen beresolusi penuh dalam satu forward pass. Dengan hanya 1.000 citra, U-Net optimal karena efisiensi parameter yang tinggi dan kemampuan bekerja pada dataset berukuran kecil hingga sedang melalui metode augmentasi elastis.

2.2. DIAGRAM ARSITEKTUR U-NET



Link draw io supaya detail:

<https://drive.google.com/file/d/1uqfAbDnYe4GBJHQEIbP9W11M56IqpX9/view?usp=sharing>

2.3. BREAKDOWN KOMPONEN ARSITEKTUR

a) EncoderContracting Path

Encoder terdiri dari 4 blok konvolusi dengan jumlah filter yang meningkat secara eksponensial: 64, 128, 256, dan 512. Setiap blok mengandung dua konvolusi 3×3 (stride=1, padding=1) yang menjaga dimensi spasial tetap dalam satu blok, diikuti Batch Normalization untuk menstabilkan distribusi aktivasi, dan fungsi aktivasi ReLU. Setelah setiap blok, MaxPooling 2×2 dengan stride=2 melakukan downsampling sehingga dimensi spasial berkurang setengah dari 256×256 hingga 16×16 .

b) Bottleneck

Bottleneck merupakan titik terdalam jaringan yang memproses representasi fitur paling abstrak dengan 1.024 filter pada dimensi spasial terkecil (16×16). Terdiri dari dua konvolusi 3×3 dan ditambahkan Dropout 0.5 untuk mencegah overfitting, yang krusial mengingat dataset medis umumnya terbatas.

c) Decoder (Expansive Path)

Decoder terdiri dari 4 blok yang simetris terhadap encoder. Setiap blok diawali Transposed Convolution 2×2 untuk menggandakan dimensi spasial, dilanjutkan konkatenasi dengan fitur encoder melalui skip connection, kemudian dua konvolusi 3×3 untuk merekonstruksi detail segmentasi. Jumlah filter berkurang secara simetris: 512, 256, 128, hingga 64.

d) Skip Connections

Skip connections menghubungkan output setiap blok encoder langsung ke decoder pada level yang bersesuaian melalui konkatenasi channel. Mekanisme ini memungkinkan decoder mengakses fitur spasial beresolusi tinggi dari encoder (tepi, tekstur) yang hilang akibat downsampling, sekaligus memfasilitasi aliran gradien selama backpropagation sehingga lapisan awal tetap ter-update secara efektif.

e) Output Layer

Konvolusi 1×1 dengan 2 filter memetakan feature map ke jumlah kelas (background dan tumor) tanpa mengubah dimensi spasial, menghasilkan tensor $[N, 2, 256, 256]$. Softmax diterapkan per piksel untuk menghasilkan probabilitas kelas, dan Argmax mengonversi probabilitas tersebut menjadi mask segmentasi final.

Komponen	Detail Teknis	Fungsi Utama
Encoder	Conv $3 \times 3 \times 2$ + BN + ReLU → MaxPool 2×2	Ekstraksi fitur + downsampling
Bottleneck	Conv $3 \times 3 \times 2$ (1024 filter) + Dropout 0.5	Representasi semantik padat, cegah overfitting
Decoder	Up-Conv 2×2 + Concat + Conv $3 \times 3 \times 2$ + BN + ReLU	Rekonstruksi spasial + upsampling
Skip Connections	Konkatenasi fitur encoder-decoder	Pertahankan detail spasial untuk presisi batas
Output Layer	Conv 1×1 (2 filter) + Softmax	Probabilitas per piksel untuk 2 kelas

2.4. ALUR DIMENSI TENSOR

Berikut perubahan bentuk (shape) tensor pada setiap tahap arsitektur untuk batch size N:

$[N, 1, 256, 256] \rightarrow$ Input (Citra MRI Grayscale)

$[N, 64, 256, 256] \rightarrow E1 \rightarrow [N, 64, 128, 128] \rightarrow P1$ (downsampling spasial $2 \times$)

$[N, 128, 128, 128] \rightarrow E2 \rightarrow [N, 128, 64, 64] \rightarrow P2$ (downsampling spasial $2 \times$)

$[N, 256, 64, 64] \rightarrow E3 \rightarrow [N, 256, 32, 32] \rightarrow P3$ (downsampling spasial $2 \times$)

$[N, 512, 32, 32] \rightarrow E4 \rightarrow [N, 512, 16, 16] \rightarrow P4$ (downsampling spasial $2 \times$)

[N, 1024, 16, 16] → Bottleneck (representasi terdalam)

[N, 1024, 32, 32] → U4 → [N, 512, 32, 32] → D4 (upsampling spasial 2×, concat skip E4)

[N, 512, 64, 64] → U3 → [N, 256, 64, 64] → D3 (upsampling spasial 2×, concat skip E3)

[N, 256, 128, 128] → U2 → [N, 128, 128, 128] → D2 (upsampling spasial 2×, concat skip E2)

[N, 128, 256, 256] → U1 → [N, 64, 256, 256] → D1 (upsampling spasial 2×, concat skip E1)

[N, 2, 256, 256] → Output (mask segmentasi, Background | Tumor)

2.5. ALASAN KESESUAIAN ARSITEKTUR UNTUK SEGMENTASI TUMOR OTAK

U-Net dipilih untuk segmentasi tumor otak pada MRI berdasarkan pertimbangan klinis dan teknis berikut:

a) Presisi batas irregular

Tumor glioma memiliki morfologi heterogen dengan batas tidak beraturan [4]. Skip connections mempertahankan detail spasial beresolusi tinggi dari encoder sehingga decoder mampu merekonstruksi tepi tumor secara akurat, mencegah hilangnya detail subtle akibat information bottleneck.

b) Efisiensi pada dataset terbatas

Dengan hanya 1.000 citra, U-Net unggul karena parameter yang efisien dan dukungan augmentasi elastis khusus biomedis [1]. V-Net [2] menawarkan ekstensi 3D untuk data volumetrik, namun pada citra 2D 256×256, U-Net lebih efisien secara komputasi tanpa kehilangan akurasi.

c) Ketahanan terhadap class imbalance

Area tumor umumnya hanya 1–10% dari total piksel. Dice Loss mengoptimalkan overlap spasial secara langsung tanpa terpengaruh dominasi kelas mayoritas [3], berbeda dengan arsitektur klasifikasi konvensional yang cenderung mengabaikan kelas minoritas.

d) Preservasi resolusi penuh

Segmentasi tumor memerlukan mask 256×256 dengan presisi per-piksel untuk perencanaan radioterapi. Sebagai fully convolutional network, U-Net menghasilkan dense prediction beresolusi identik dengan input, berbeda dengan SegNet yang mengorbankan detail spasial atau DeepLab yang memerlukan CRF post-processing komputasional berat.

REFERENSI

- [1] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. In Proceedings of MICCAI, 9351, 234–241. DOI: 10.1007/978-3-319-24574-4_28
- [2] Milletari, F., Navab, N., & Ahmadi, S. A. (2016). V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation. In Proceedings of IEEE 3DV, 565–571. DOI: 10.1109/3DV.2016.79
- [3] Iqbal, T., & Ali, H. (2023). A Deep Learning Approach for Brain Tumor Segmentation in MRI Using U-Net. Biomedical Signal Processing and Control, 80, 104298.
- [4] Bakas, S., et al. (2017). Advancing The Cancer Genome Atlas Glioma MRI Collections with Expert Segmentation Labels and Radiomic Features. Nature Scientific Data, 4, 170117. DOI: 10.1038/sdata.2017.117