

LAPORAN ANALISIS ARSITEKTUR DEEP LEARNING

SEGMENTASI TUMOR OTAK PADA CITRA MRI

Julius Tegar Aji Putra - 24060123130117

I. Deskripsi Tugas

Task ini merupakan segmentasi semantik biner pada citra Magnetic Resonance Imaging (MRI) otak. Tujuannya adalah mengklasifikasikan setiap piksel dalam citra ke dalam dua kategori: piksel tumor (foreground) atau piksel jaringan normal/latar belakang (background). Output akhir berupa pixel-wise binary mask yang menandai lokasi dan batas tumor secara presisi.

II. Ukuran dan Bentuk Data

Atribut Dataset	Detail
Jumlah Sampel	1.000 pasang citra (input + label)
Ukuran Citra Input	256 x 256 piksel (grayscale, 1 channel)
Shape Tensor Input	(N, 1, 256, 256), Batch x Channel x H x W
Shape Mask Output	(N, 1, 256, 256), Binary mask (0 = normal, 1 = tumor)
Split Dataset	700 training / 150 validasi / 150 testing (70/15/15)
Pre-processing	Normalisasi Z-score per citra, resize ke 256x256
Augmentasi	Elastic deformation, rotasi +/-20 derajat, flip horizontal, brightness jitter

III. Arsitektur U-Net


A. Breakdown Layer

Blok/Layer	Operasi	Output Shape	Keterangan
INPUT	Citra MRI Otak	256 × 256 × 1	Grayscale
ENCODER 1	Conv 3x3 (x2) + ReLU + MaxPool 2x2	128 × 128 × 64	64 feature maps
ENCODER 2	Conv 3x3 (x2) + ReLU + MaxPool 2x2	64 × 64 × 128	128 feature maps
ENCODER 3	Conv 3x3 (x2) + ReLU + MaxPool 2x2	32 × 32 × 256	256 feature maps
ENCODER 4	Conv 3x3 (x2) + ReLU + MaxPool 2x2	16 × 16 × 512	512 feature maps
BOTTLENECK	Conv 3x3 (x2) + ReLU + Dropout	8 × 8 × 1024	1024 feature maps
DECODER 4	UpConv 2x2 + Skip + Conv 3x3 (x2)	16 × 16 × 512	Skip dari Enc-4
DECODER 3	UpConv 2x2 + Skip + Conv 3x3 (x2)	32 × 32 × 256	Skip dari Enc-3
DECODER 2	UpConv 2x2 + Skip + Conv 3x3 (x2)	64 × 64 × 128	Skip dari Enc-2

DECODER 1	UpConv 2x2 + Skip + Conv 3x3 (x2)	128 × 128 × 64	Skip dari Enc-1
OUTPUT	Conv 1x1 + Sigmoid	256 × 256 × 1	Mask Segmentasi

B. Diagram Breakdown Arsitektur

Diagram bisa dilihat lebih jelas pada [link ini](#).



C. Penjelasan Fungsi Setiap Komponen

Komponen	Fungsi
Contracting Path (Encoder)	Mengekstrak fitur hierarkis dari citra MRI melalui konvolusi berulang dan max-pooling. Setiap level menangkap fitur semakin abstrak: tepi, tekstur, bentuk, semantik.
Expanding Path (Decoder)	Merekonstruksi resolusi spasial melalui upsampling (up-convolution 2x2). Mengembalikan informasi lokasi yang hilang saat downsampling.
Skip Connections	Menggabungkan (concatenate) feature map dari encoder ke decoder pada resolusi yang sama. Mempertahankan detail spasial halus yang krusial untuk batas tumor.
Bottleneck Layer	Layer terdalam dengan 1024 filter, menangkap representasi semantik paling abstrak. Dropout diterapkan untuk regularisasi dan mencegah overfitting.
Conv 3x3 + ReLU	Kernel 3x3 adalah pilihan standar yang efisien: cukup besar untuk menangkap konteks lokal, namun parameter-efisien. ReLU memperkenalkan non-linearitas.
MaxPool 2x2	Mereduksi dimensi spasial 2x, meningkatkan receptive field, dan menciptakan invariansi translasi parsial.
Up-Conv 2x2	Transposed convolution untuk upsampling terlatih, memungkinkan jaringan belajar cara terbaik merekonstruksi resolusi.
Conv 1x1 + Sigmoid	Layer output mengkonversi 64 feature maps menjadi 1 channel probabilitas (0-1) per piksel; nilai > 0.5 = tumor.
Weighted Loss (BCE + Dice)	Binary cross-entropy dikombinasikan dengan Dice loss untuk menangani ketidakseimbangan kelas antara piksel tumor dan non-tumor.
Data Augmentation	Elastic deformation, rotasi, flip, brightness variation meningkatkan variasi data training dari 1.000 menjadi efektif ribuan sampel.

IV. Alasan Pemilihan U-Net untuk Segmentasi Tumor Otak

- A. **Didesain untuk Data Biomedis Terbatas:** U-Net terbukti mampu menghasilkan segmentasi akurat bahkan dengan jumlah data training yang kecil. Dengan hanya 700 citra training, U-Net mampu belajar melalui augmentasi elastic deformation yang mensimulasikan variasi anatomi nyata. Keunggulan yang secara eksplisit dibuktikan dalam paper aslinya (Ronneberger et al., 2015).
- B. **Lokalisasi Presisi via Skip Connections:** Tumor otak seringkali memiliki batas yang tidak beraturan dan gradasi halus. Skip connections memastikan informasi tepi halus tidak hilang selama downsampling, menghasilkan batas segmentasi yang tajam dan akurat yang merupakan faktor kritis dalam konteks klinis (Isensee et al., 2021).
- C. **Arsitektur Simetris Encoder-Decoder:** Kombinasi contracting path untuk ekstraksi konteks semantik dan expanding path untuk rekonstruksi resolusi spasial memungkinkan jaringan memahami 'apa' (jenis jaringan) sekaligus 'di mana' (lokasi piksel) secara bersamaan.
- D. **Tidak Ada Fully Connected Layer:** Arsitektur fully-convolutional memungkinkan pemrosesan citra dengan berbagai ukuran dan mengurangi risiko overfitting akibat parameter yang terlalu banyak.
- E. **Efisiensi Komputasi:** Segmentasi citra 256x256 dapat dilakukan dalam hitungan milidetik pada GPU modern, menjadikannya layak untuk aplikasi klinis real-time.
- F. **Basis untuk Varian Canggih:** U-Net menjadi fondasi bagi Attention U-Net, ResU-Net, TransUNet, dan Swin-UNet (Chen et al., 2021) untuk membuktikan relevansi arsitekturalnya yang bertahan dalam bidang segmentasi medis.

V. Referensi

1. Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. MICCAI 2015. arXiv:1505.04597.
2. Isensee, F., Jaeger, P. F., Kohl, S. A. A., Petersen, J., & Maier-Hein, K. H. (2021). nnU-Net: A self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, 18(2), 203–211. <https://doi.org/10.1038/s41592-020-01008-z>
3. Chen, J., Lu, Y., Yu, Q., Luo, X., Adeli, E., Wang, Y., ... & Zhou, Y. (2021). TransUNet: Transformers make strong encoders for medical image segmentation. arXiv preprint, arXiv:2102.04306.