

ARSITEKTUR DEEP LEARNING UNTUK SEGMENTASI TUMOR OTAK PADA CITRA MRI MENGGUNAKAN U-NET

Kayis Hilmi Farih
Pattern Recognition, Informatics, Diponegoro University

I. Deskripsi Task

Pada project kali ini, task yang diberikan adalah semantic segmentation biner pada Magnetic Resonance Imaging (MRI) otak. Citra MRI dikirimkan dan diproses oleh model dengan cara menandai tiap piksel sebagai tumor dan non-tumor yang berguna untuk diagnosis radiologis, perencanaan radioterapi, dan pemantauan perkembangan tumor.


II. Ukuran dan Bentuk Data

Komponen	Jumlah	Dimensi	Citra	Keterangan
Citra input	1000	256x256	1	Citra input grayscale dengan dimensi 256x256
Mask tumor	1000	256x256	1	Label segmentasi biner tumor
Data training	700	256x256	1	70% data untuk latihan
Data validation	150	256x256	1	15% data untuk validasi
Data testing	150	256x256	1	15% data untuk testing

III. Arsitektur Deep Learning yang Digunakan

Pada kasus kali ini, arsitektur deep learning yang digunakan adalah U-net. Diperkenalkan pertama kali pada 2015, U-Net adalah jaringan saraf konvolusional penuh (*fully convolutional neural network*) yang dikembangkan untuk segmentasi citra biomedis [1]. U-Net memiliki arsitektur mirip autoencoder konvolusional dengan jalur encoder dan decoder, namun dibedakan oleh adanya *skip connections* yang menghubungkan keduanya untuk memulihkan informasi spasial yang hilang saat *down-sampling*, yang sangat penting dalam tugas segmentasi [2]. Encoder pada U-Net terdiri dari tumpukan lapisan konvolusional rekuren dan *maxpooling* yang secara bertahap mengurangi dimensi citra, di mana setiap blok encoder memiliki dua lapisan konvolusional 3x3 tanpa *padding* diikuti oleh ReLU dan *maxpooling* 2x2, dengan jumlah filter yang berlipat ganda pada setiap blok berikutnya dimulai dari 64 filter [3].

IV. Diagram Breakdown Arsitektur



V. Penjelasan Fungsi Tiap Komponen

Unit dasar U-Net adalah Convolutional Block berisi dua kali Conv 3x3 + ReLU dengan Batch Normalization untuk stabilitas. Encoder terdiri dari empat level downsampling (Conv block + max-pooling 2x2 stride 2) dengan channel yang digandakan setiap level (64-128-256-512), di mana level awal menangkap edge dan tekstur sedangkan level dalam menangkap pola semantik tumor (heterogenitas intensitas, area nekrotik, edema). Bottleneck berukuran 16x16x1024 memiliki receptive field sangat luas sehingga model "memahami" konteks global posisi tumor relatif terhadap struktur otak lain dilengkapi Dropout 0,3 sebagai regularisasi dan *implicit data augmentation*.

Decoder terdiri dari empat level upsampling, masing-masing menjalankan up-convolution 2x2, concatenation dengan skip connection encoder, dan dua Conv 3x3 + ReLU untuk merekonstruksi peta segmentasi pada resolusi asli 256x256. Skip Connection adalah komponen paling khas U-Net, yaitu menyalin feature map encoder ke decoder lalu digabungkan via concatenation, sehingga informasi semantik "ada tumor di sini" dari decoder bertemu informasi spasial "ini posisi tepi tajam" dari encoder, menghasilkan prediksi batas tumor yang presisi. Output layer berupa Conv 1x1 + Sigmoid menghasilkan probability map $P(x,y) = \sigma(z) = 1/(1+e^{-z})$ yang di-threshold 0,5 menjadi mask biner. Fungsi loss menggunakan kombinasi Dice Loss + BCE: $L_{total} = LBCE + (1 - Dice)$ untuk menangani ketidakseimbangan kelas (tumor <5% piksel).

VI. Alasan Pemilihan Arsitektur

Proses dimulai dengan pembacaan citra MRI grayscale 256x256 sebagai tensor $X \in \mathbb{R}^{256 \times 256 \times 1}$, lalu dinormalisasi ke $[0, 1]$ melalui $X' = X / 255$, diikuti skull-stripping bila tersedia agar model fokus pada jaringan otak. Tensor X' kemudian melewati 4 level encoder: E1 mengubah dimensi menjadi 256x256x64 dan mendeteksi edge dan tekstur (disimpan sebagai S1), pooling lalu menurunkan ke 128x128 di mana E2 menghasilkan 128x128x128 (S2, menangkap kontras gray vs white matter), pola berulang E3 menghasilkan 64x64x256 (S3, kontur ventrikel) dan E4 menghasilkan 32x32x512 (S4, pola semantik tumor), serta pool terakhir menghasilkan 16x16x512. Keempat skip S1–S4 disimpan untuk pemulihan informasi spasial di decoder. Pada bottleneck, tensor diproses dengan dua Conv 3x3 + ReLU menjadi 16x16x1024 lalu diberi Dropout 0,3, di mana model "memahami" konteks global, posisi tumor relative terhadap struktur otak lain. Decoder kemudian membalik proses encoder dengan bantuan skip connection. Pada D4: tensor 16x16x1024 di-upsample menjadi 32x32x512, di-concatenate dengan S4 menjadi 32x32x1024, lalu dua Conv 3x3 mengembalikan ke 32x32x512. Pola serupa berulang: D3 menghasilkan 64x64x256 dengan S3, D2 menghasilkan 128x128x128 dengan S2, dan D1 menghasilkan 256x256x64 dengan S1 di sinilah informasi semantik "apa" dari decoder bertemu informasi spasial "di mana" dari skip sehingga model menggambar batas tumor secara presisi. Akhirnya tensor 256x256x64 diproyeksikan ke 1 channel melalui Conv 1x1 + Sigmoid ($P(x,y) = \sigma(z(x,y)) = 1/(1+e^{-z(x,y)})$) menghasilkan probability map 256x256x1 yang di-threshold 0,5 menjadi mask biner, karena resolusi identic dengan input, mask dapat langsung di-overlay di atas citra MRI asli untuk visualisasi klinis.

VII. Alur Pemrosesan Citra MRI Menjadi Mask Segmentasi Tumor

Proses dimulai dengan pembacaan citra MRI grayscale 256x256 sebagai tensor $X \in \mathbb{R}^{256 \times 256 \times 1}$, lalu dinormalisasi ke $[0, 1]$ melalui $X' = X / 255$, diikuti skull-stripping bila tersedia agar model fokus pada jaringan otak. Tensor X' kemudian melewati 4 level encoder: E mengubah dimensi menjadi 256x256x64 dan mendeteksi edge dan tekstur (disimpan sebagai S1), pooling lalu menurunkan ke 128x128 di mana

E2 menghasilkan 128x128x128 (S2, menangkap kontras gray vs white matter), pola berulang E3 menghasilkan 64x64x256 (S3, kontur ventrikel) dan E4 menghasilkan 32x32x512 (S4, pola semantik tumor), serta pool terakhir menghasilkan 16x16x512. Keempat skip S1–S4 disimpan untuk pemulihan informasi spasial di decoder. Pada bottleneck, tensor diproses dengan dua Conv 3x3 + ReLU menjadi 16x16x1024 lalu diberi Dropout 0,3, di mana model "memahami" konteks global posisi tumor relatif terhadap struktur otak lain.

Decoder kemudian membalik proses encoder dengan bantuan skip connection. Pada D4, tensor 16x16x1024 diupsample menjadi 32x32x512, diconcatenate dengan S4 menjadi 32x32x1024, lalu dua Conv 3x3 mengembalikan ke 32x32x512. Pola serupa berulang, D3 menghasilkan 64x64x256 dengan S3, D2 menghasilkan 128x128x128 dengan S2, dan D1 menghasilkan 256x256x64 dengan S1 di sinilah informasi semantik "apa" dari decoder bertemu informasi spasial "di mana" dari skip sehingga model menggambar batas tumor secara presisi. Akhirnya tensor 256x256x64 diproyeksikan ke 1 channel melalui Conv 1x1 + Sigmoid ($P(x,y) = \sigma(z(x,y)) = 1/(1+e^{-z(x,y)})$) menghasilkan probability map 256x256x1 yang di-threshold 0,5 menjadi mask biner; karena resolusi identik dengan input, mask dapat langsung dioverlay di atas citra MRI asli untuk visualisasi klinis.

References

- [1] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," May 2015, [Online]. Available: <http://arxiv.org/abs/1505.04597>
- [2] B. Woo and M. Lee, "Comparison of tissue segmentation performance between 2D U-Net and 3D U-Net on brain MR Images," in *2021 International Conference on Electronics, Information, and Communication, ICEIC 2021*, Institute of Electrical and Electronics Engineers Inc., Jan. 2021. doi: 10.1109/ICEIC51217.2021.9369797.
- [3] A. D. Puspitarini, R. A. H. Winarso, Y. F. Izzaddien, C. Fatichah, and H. T. Ismet, "Brain Tumor Segmentation Using Ensemble Vanilla U-Net and Residual U-Net Models," Institute of Electrical and Electronics Engineers (IEEE), Dec. 2025, pp. 118–123. doi: 10.1109/icitcom66635.2025.11265298.