
1. JUDUL KASUS

Segmentasi Presisi Tumor Otak pada Citra MRI Menggunakan Arsitektur ResUNet (Residual U-Net)

2. DESKRIPSI TASK

Task ini merupakan penyelesaian masalah segmentasi semantik biner pada citra medis dengan fokus pada Magnetic Resonance Imaging (MRI). Tujuan utamanya adalah melatih model *deep learning* untuk mengidentifikasi dan memisahkan *Region of Interest* (ROI) berupa jaringan tumor dari jaringan otak sehat serta latar belakang (Ronneberger et al., 2015). Pendekatan ini memanfaatkan karakteristik arsitektur berbentuk huruf “U” (*u-shaped*) yang membagi proses menjadi jalur kontraksi (*encoder*) untuk menangkap informasi kontekstual anatomi secara luas, dan jalur ekspansi (*decoder*) yang simetris untuk pemulihan resolusi spasial (Ronneberger et al., 2015). Hasil akhir dari task ini adalah sebuah *mask* segmentasi biner berukuran sama dengan input, di mana setiap piksel diklasifikasikan secara individual: nilai 1 merepresentasikan area tumor dan nilai 0 merepresentasikan area non-tumor (Lebani et al., 2025).

3. UKURAN DAN BENTUK DATA

Karakteristik data yang digunakan dalam pengerjaan tugas segmentasi tumor otak ini disesuaikan berdasarkan ketentuan batas tugas dan implementasi citra medis 2D sebagai berikut:


- **Volume Dataset:** Terdiri dari 1.000 citra MRI otak berpasangan (citra input asli dan label target/*ground truth mask*). Volume data ini sudah memadai karena model berbasis konvolusi U-Net dirancang khusus agar dapat dilatih secara *end-to-end* secara efisien meskipun ukuran dataset beranotasi cenderung terbatas (Ronneberger et al., 2015).
 - **Dimensi Citra Input:** Tensor berukuran $256 \times 256 \times 1$ piksel. Penyesuaian ukuran spasial citra menjadi resolusi 256×256 piksel disesuaikan dengan dimensi spasial standar pemrosesan citra medis 2D untuk menjaga detail ROI (Lebani et al., 2025). Sementara itu, jumlah saluran masukan sengaja diatur biner atau saluran tunggal ($C = 1$) dengan asumsi citra menggunakan representasi tingkat keabuan (*grayscale*) sesuai dengan batasan deskripsi tugas kasus tunggal ini.
 - **Dimensi Citra Output (Mask):** Matriks biner berukuran $256 \times 256 \times 1$ piksel. Dimensi spasial luaran ini berkorespondensi penuh (1:1) dengan citra input asli guna memetakan letak serta batas luar tumor secara akurat.
-

4. ARSITEKTUR DEEP LEARNING YANG DIGUNAKAN

Arsitektur *deep learning* yang diterapkan dalam kasus ini adalah **ResUNet (Residual U-Net)**. Pemilihan arsitektur ini didasarkan pada kebutuhan untuk memodifikasi keterbatasan ekstraksi fitur pada arsitektur Vanilla U-Net standar (Ronneberger et al., 2015) ketika diperhadapkan pada citra medis yang kompleks (Cao et al., 2022). ResUNet mengintegrasikan prinsip dasar U-Net dengan konsep koneksi residual (*residual connections*) dengan cara mengganti susunan blok konvolusi konvensional pada jalur *encoder* dan *decoder* menjadi *Residual Block* (Yang et al., 2026). Penambahan koneksi pintas (*shortcut connection*) di dalam blok ini secara teoritis mampu melancarkan aliran informasi dan propagasi gradien pada jaringan yang dalam, sehingga secara efektif dapat mengatasi masalah gradien menghilang (*vanishing gradient*) serta memfasilitasi penggunaan kembali fitur (*feature reuse*) secara optimal sepanjang pelatihan (Darshan et al., 2025).

5. DIAGRAM BREAKDOWN ARSITEKTUR

Struktur ResUNet dalam memproses citra input hingga menghasilkan mask segmentasi tumor otak diuraikan melalui alur blok hierarkis berikut:



6. PENJELASAN SINGKAT FUNGSI SETIAP KOMPONEN

- **Residual Block (Blok Residual):** Unit dasar pemrosesan yang menerapkan jalur pintas penjumlahan elemen-demi-elemen (*element-wise addition*) antara input awal blok dan hasil konvolusinya. Komponen ini berfungsi melancarkan aliran gradien, mempercepat konvergensi waktu pelatihan model, dan mencegah hilangnya identitas fitur penting citra pada lapisan dalam (Cao et al., 2022; Darshan et al., 2025).
- **Max Pooling 2 × 2:** Berfungsi untuk melakukan reduksi dimensi spasial (*downsampling*) peta fitur sebesar setengah ukuran dari lapisan sebelumnya secara berulang (Ronneberger et al., 2015). Tujuannya adalah memperluas bidang penerimaan (*receptive field*) model agar dapat mengekstraksi konteks bentuk global anatomi otak (Lebani et al., 2025).
- **Up-Convolution / Upsampling:** Operasi konvolusi transpos atau upsampling yang berfungsi mengembalikan ukuran dimensi resolusi spasial peta fitur yang mengecil di bagian tengah secara bertahap menuju ukuran resolusi asli citra (Ronneberger et al., 2015).

- **Skip Connections (Concatenation):** Berfungsi menyalin peta fitur beresolusi spasial tinggi secara lateral langsung dari jalur *encoder* untuk digabungkan (*concatenation*) dengan peta fitur di jalur *decoder* sebelum masuk ke blok residual berikutnya (Ronneberger et al., 2015). Komponen ini sangat krusial untuk mengembalikan detail spasial halus yang hilang akibat *pooling*, sehingga batas tepi tumor yang kabur dapat digambar kembali secara presisi (Yang et al., 2026).
- **Konvolusi 1×1 dan Aktivasi Sigmoid:** Lapisan akhir yang mereduksi jumlah keseluruhan *channel* fitur menjadi satu *channel* tunggal (Lebani et al., 2025). Fungsi aktivasi *Sigmoid* kemudian memetakan nilai intensitas piksel menjadi rentang angka probabilitas biner kontinu antara 0 dan 1 (0 untuk non-tumor, 1 untuk tumor) (Cao et al., 2022).

7. ALASAN KESESUAIAN ARSITEKTUR DENGAN TASK

ResUNet dinilai sangat relevan dan sesuai untuk segmentasi tumor otak karena tiga faktor utama. Pertama, struktur batas luar jaringan tumor pada citra medis MRI umumnya memiliki karakteristik tepi yang sangat kabur dan heterogen (Yang et al., 2026). Kombinasi *skip connection* asli dari struktur U-Net (Ronneberger et al., 2015) dan stabilitas pemrosesan mendalam dari *residual block* memastikan model mampu mengenali letak global sekaligus menggambar batas luar tumor dengan tingkat akurasi detail yang tinggi (Yang et al., 2026). Kedua, ukuran dataset sebanyak 1.000 citra merupakan volume sampel yang moderat di lingkup rekayasa citra medis; keandalan ResUNet yang mewarisi efisiensi Vanilla U-Net membuatnya tidak membutuhkan pasokan data berukuran raksasa untuk mencapai tahap konvergensi yang baik (Ronneberger et al., 2015). Ketiga, secara empiris pada berbagai riset validasi pengujian tumor otak menggunakan dataset dasar seperti BraTS, model berbasis ResUNet terbukti stabil dan tangguh, dengan capaian rerata skor *Dice Similarity Coefficient* (DSC) pengujian yang berkisar antara 84% hingga mencapai 95% tergantung pada tingkat kompleksitas varian arsitektur maupun modifikasi prapemrosesan datanya (Darshan et al., 2025; Lebani et al., 2025; Yang et al., 2026).

8. REFERENSI / DAFTAR PUSTAKA

- Cao, T., Wang, G. L., Ren, L., Li, Y., & Wang, H. (2022). Brain tumor magnetic resonance image segmentation by a multiscale contextual attention module combined with a deep residual UNet (MCA-ResUNet). *Physics in Medicine and Biology*, 67(9), 095007. <https://doi.org/10.1088/1361-6560/ac5e5c>
- Darshan, M. S., Langote, S., B, D., & Patil, S. S. (2025). ResUNet in Action: Advancing LGG Brain Tumour Segmentation with Deep Learning. *2025 2nd International Conference on Software, Systems and Information Technology (SSITCON)*, 1-6. <https://doi.org/10.1109/SSITCON66133.2025.11341956>
- Lebani, A. Z., Merati, M., & Mahmoudi, S. (2025). PRA-Unet: Parallel Residual Attention U-Net for Real-Time Segmentation of Brain Tumors. *Information*, 17(1), 14. <https://doi.org/10.3390/info17010014>
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 234-241. https://doi.org/10.1007/978-3-319-24574-4_28
- Yang, D., Yang, B., & Yan, J. (2026). MAEM-ResUNet: Accurate Glioma Segmentation in Brain MRI via Symmetric Multi-Directional Mamba and Dual-Attention Modules. *Symmetry*, 18(1), 1. <https://doi.org/10.3390/sym18010001>
- Zhou, Z., Siddiquee, M. M. R., Tajbakhsh, N., & Liang, J. (2020). UNet++: Redesigning skip connections to exploit multiscale features in image segmentation. *IEEE Transactions on Medical Imaging*, 39(6), 1856-1867. <https://doi.org/10.1109/TMI.2019.2959609>