

Analisis Arsitektur Attention U-Net untuk Segmentasi Tumor Gliomas pada Citra MRI T1-Weighted.

KHAIRIYA FATIH IZZUDIN EMARIN-24060123140166

1) DESKRIPSI TASK

segmentasi semantik biner pixel-wise pada citra MRI otak modalitas T1-Weighted. Setiap piksel diklasifikasikan ke dalam salah satu dari dua kelas: kelas 1 (tumor glioma / foreground) dan kelas 0 (jaringan otak normal + background). Output berupa probability map bernilai kontinu $[0,1]$ yang kemudian ditera (threshold = 0.5) menjadi mask biner. Tantangan utama adalah tumor glioma memiliki intensitas heterogen, batas tidak beraturan, dan sering tumpang-tindih dengan jaringan otak sehat sehingga model harus mampu melakukan selective focus pada region patologis.

2) UKURAN DAN BENTUK DATA

Parameter	Spesifikasi Teknis
Modalitas	MRI T1-Weighted, grayscale
Resolusi Spasial	256×256 piksel, 1 channel (intensitas 0–255)
Jumlah Sampel	1.000 pasang (citra + ground-truth mask)
Tensor Input	$(N, 1, 256, 256)$ — N = batch size, format CHW
Tensor Output	$(N, 1, 256, 256)$ — nilai float probabilitas tumor
Partisi Data	Training 70% (700), Validasi 15% (150), Testing 15% (150)
Normalisasi	Z-score per-volume: $I_{\text{norm}} = (I - \mu I) / \sigma I$
Augmentasi Spasial	Random rotation $[-15^\circ, +15^\circ]$, horizontal flip ($p=0.5$), elastic deformation ($\sigma=10$, $\alpha=100$)
Augmentasi Intensitas	Random brightness shift ($\pm 20\%$), contrast adjustment ($\pm 15\%$), Gaussian noise ($\sigma=0.01$)


3) ARSITEKTUR: ATTENTION U-NET (Layer-by-Layer Breakdown)

Blok	Operasi Detail	Output Shape	Catatan Kritis
INPUT	Citra MRI T1-W	$256 \times 256 \times 1$	Grayscale, telah dinormalisasi Z-score
ENC-1	$[\text{Conv}3 \times 3 \rightarrow \text{BN} \rightarrow \text{ReLU}] \times 2 \rightarrow \text{MaxPool}2 \times 2$	$128 \times 128 \times 64$	64 filter, valid convolution
ENC-2	$[\text{Conv}3 \times 3 \rightarrow \text{BN} \rightarrow \text{ReLU}] \times 2 \rightarrow \text{MaxPool}2 \times 2$	$64 \times 64 \times 128$	128 filter
ENC-3	$[\text{Conv}3 \times 3 \rightarrow \text{BN} \rightarrow \text{ReLU}] \times 2 \rightarrow \text{MaxPool}2 \times 2$	$32 \times 32 \times 256$	256 filter
ENC-4	$[\text{Conv}3 \times 3 \rightarrow \text{BN} \rightarrow \text{ReLU}] \times 2 \rightarrow \text{MaxPool}2 \times 2$	$16 \times 16 \times 512$	512 filter
BOTTL ENECK	$[\text{Conv}3 \times 3 \rightarrow \text{BN} \rightarrow \text{ReLU}] \times 2 \rightarrow \text{Dropout}(0.3)$	$8 \times 8 \times 1024$	Representasi semantik paling abstrak
DEC-4	$\text{UpConv}2 \times 2 \rightarrow \text{AG-4}(\text{xenc4}, \text{gdec4}) \rightarrow \text{Concat} \rightarrow [\text{Conv}3 \times 3 \rightarrow \text{BN} \rightarrow \text{ReLU}] \times 2$	$16 \times 16 \times 512$	AG menyaring 512 ch $\rightarrow$ 512 ch terbobot
DEC-3	$\text{UpConv}2 \times 2 \rightarrow \text{AG-3}(\text{xenc3}, \text{gdec3}) \rightarrow \text{Concat} \rightarrow [\text{Conv}3 \times 3 \rightarrow \text{BN} \rightarrow \text{ReLU}] \times 2$	$32 \times 32 \times 256$	Gating signal dari DEC-4
DEC-2	$\text{UpConv}2 \times 2 \rightarrow \text{AG-2}(\text{xenc2}, \text{gdec2}) \rightarrow \text{Concat} \rightarrow [\text{Conv}3 \times 3 \rightarrow \text{BN} \rightarrow \text{ReLU}] \times 2$	$64 \times 64 \times 128$	Gating signal dari DEC-3

DEC-1	UpConv2×2→AG-1(xenc1,gdec1)→Concat→[Conv3×3→BN→ReLU]×2	128×128×64	Gating signal dari DEC-2
OUTPUT	Conv1×1→Sigmoid	256×256×1	Probabilitas tumor per piksel

3.1) DIAGRAM BREAKDOWN ARSITEKTUR

Gambar dapat dilihat pada:[link](#)



3.2) PENJELASAN FUNGSI SETIAP KOMPONEN

Komponen	Fungsi Teknis dalam Segmentasi Tumor Otak
Contracting Path (Encoder)	Ekstraksi fitur hierarkis. Level dini: tepi & tekstur. Level dalam: morfologi & semantik tumor. MaxPool meningkatkan receptive field 2× per level.
Attention Gate (AG)	Menghitung attention coefficient $\alpha \in [0,1]$: $\alpha = \text{sigmoid}(\psi(\sigma(W_g \cdot g + W_x \cdot x + b)))$. Feature map encoder diredam di region non-tumor dan diperkuat di region tumor. Mengurangi false positive pada background kompleks.
Gating Signal (g)	Feature map dari decoder yang berfungsi query untuk menentukan lokasi region penting. Membantu AG fokus pada area kemungkinan besar tumor.
Expanding Path (Decoder)	Rekonstruksi resolusi spasial via UpConv 2×2. Menerima feature terseleksi dari AG (bukan mentah), sehingga batas tumor lebih tajam.
Skip Connection + AG	U-Net vanilla: skip mentah membawa noise. Dengan AG: hanya detail relevan yang dipropagasikan.
Batch Normalization (BN)	Diterapkan setelah setiap Conv 3×3 (kecuali bottleneck). Menstabilkan distribusi aktivasi selama training, mempercepat konvergensi, dan mengurangi sensitivitas terhadap inisialisasi bobot — sangat penting untuk dataset medis 700 citra yang relatif terbatas.
Bottleneck + Dropout	Layer terdalam (8×8×1024) menangkap konteks global otak. Dropout 0.3 mencegah co-adaptation neuron berlebihan mengingat rasio sample-to-parameter yang kecil pada data medis.

Conv 1×1 + Sigmoid	Layer klasifikasi pixel-wise. Sigmoid menghasilkan probabilitas independen per piksel tanpa asumsi eksklusivitas antar kelas (cocok untuk biner). Threshold 0.5 menghasilkan mask final.
--------------------	--

4) ALASAN PEMILIHAN ATTENTION U-NET

A. Selektivitas Spasial pada Region Patologis: Tumor glioma pada T1-W memiliki kontras rendah dengan materi putih. AG secara otomatis menekan respons jaringan normal dan memperkuat region abnormal. Paper Oktay et al. (2018) membuktikan AG meningkatkan precision pada organ kecil & kontras rendah — identik dengan karakteristik tumor otak.

B. Pengurangan False Positive: Otak memiliki anatomi beragam (sulcus, gyrus, ventrikel) yang membingungkan model. U-Net vanilla menyalurkan seluruh detail encoder ke decoder termasuk noise. AG bertindak sebagai filter adaptif: hanya informasi relevan yang diforward. False positive rate turun signifikan.

C. Efisiensi Dataset Terbatas: Hanya 700 citra training. AG menambah kapasitas representasional tanpa ledakan parameter (~+2–3% vs U-Net biasa). Kombinasi BN + Dropout + AG memberikan triple regularisasi ideal untuk skala medis.

D. Presisi Batas Infiltratif: Batas tumor glioma tidak beraturan. AG memastikan detail tepi relevan tidak hilang, sementara tepi non-target (tengkorak, kulit kepala) diredam. Hasil: Dice score lebih tinggi pada boundary region.

E. Kompatibilitas & Skalabilitas: Attention U-Net adalah fondasi Attention ResU-Net dan TransAttnUNet. Inference 256×256 pada GPU mid-range <80 ms — feasible untuk CAD klinis real-time.

4) REFERENSI

Oktay, O., et al. (2018). *Attention U-Net: Learning Where to Look for the Pancreas*. *MIDL*. *arXiv:1804.03999*.

Ronneberger, O., Fischer, P., & Brox, T. (2015). *U-Net: Convolutional Networks for Biomedical Image Segmentation*. *MICCAI*. *arXiv:1505.04597*.

Menze, B. H., et al. (2015). *The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS)*. *IEEE TMI*, 34(10).

Bakas, S., et al. (2017). *Advancing The Cancer Genome Atlas Glioma MRI Collections*. *Nature Scientific Data*, 4.

He, K., et al. (2016). *Deep Residual Learning for Image Recognition*. *CVPR*.