

SEGMENTASI TUMOR OTAK PADA CITRA MRI

Menggunakan Arsitektur Deep Learning U-Net

Lulu Nikita Sitanggang

Department of Informatics, Diponegoro University, Indonesia

lulunikitasitanggang@students.undip.ac.id

I. Deskripsi Task

Tugas ini merupakan permasalahan *semantic segmentation* pada citra medis, di mana setiap piksel dalam citra MRI otak diklasifikasikan ke dalam dua kelas, yaitu tumor dan non-tumor. Berbeda dengan klasifikasi citra konvensional yang hanya menghasilkan satu label untuk keseluruhan gambar, pendekatan ini menghasilkan *mask* dengan dimensi yang sama seperti citra input, sehingga lokasi serta batas tumor dapat diidentifikasi secara detail pada tingkat piksel. Pendekatan ini sangat penting dalam konteks klinis karena memungkinkan analisis yang lebih presisi, seperti pengukuran volume tumor, pemantauan perkembangan penyakit, serta perencanaan terapi yang lebih akurat.


II. Spesifikasi Data

Dataset yang digunakan terdiri dari 1.000 citra MRI otak dalam format grayscale berukuran 256×256 piksel. Setiap sampel terdiri dari sepasang data: citra input MRI (tensor berukuran $256 \times 256 \times 1$) dan ground truth mask segmentasi biner (tensor $256 \times 256 \times 1$, dengan nilai 1 menandakan piksel tumor dan 0 menandakan jaringan normal). Dataset dibagi menjadi 800 sampel untuk pelatihan, 100 sampel untuk validasi, dan 100 sampel untuk pengujian.

III. Arsitektur Deep Learning: U-Net

Arsitektur yang digunakan adalah U-Net, yang diperkenalkan oleh Ronneberger et al. (2015) untuk segmentasi citra biomedis. Arsitektur ini berbentuk simetris menyerupai huruf U, yang terdiri dari tiga bagian utama: *encoder* (contracting path), *bottleneck*, dan *decoder* (expanding path), yang dihubungkan melalui *skip connections*. U-Net dirancang untuk menggabungkan informasi konteks global dan detail spasial lokal secara efektif, sehingga sangat sesuai untuk tugas segmentasi dengan batas objek yang kompleks.

IV. Diagram dan Alur Arsitektur



Gambar 1

Diagram pada Gambar 1 menunjukkan alur pemrosesan citra MRI melalui arsitektur U-Net. Proses dimulai dari citra input berukuran $256 \times 256 \times 1$ yang masuk ke bagian encoder untuk dilakukan ekstraksi fitur dan penurunan resolusi secara bertahap. *Skip connections* menghubungkan encoder dan decoder pada level yang sama untuk mempertahankan informasi spasial resolusi tinggi, sehingga menghasilkan segmentasi yang lebih presisi.

V. Breakdown Arsitektur

Komponen	Ukuran Feature Map	Fungsi
Input Layer	$256 \times 256 \times 1$	Menerima citra MRI grayscale sebagai tensor input
Encoder L1 (Conv+ReLU $\times 2$, MaxPool)	$256 \rightarrow 254 \rightarrow 252 \rightarrow 126$ px, 64 ch	Ekstraksi fitur tepi dan tekstur skala kasar; downsampling $2\times$
Encoder L2 (Conv+ReLU $\times 2$, MaxPool)	$126 \rightarrow \dots \rightarrow 63$ px, 128 ch	Ekstraksi fitur lebih abstrak; konteks diperluas
Encoder L3 (Conv+ReLU $\times 2$, MaxPool)	$63 \rightarrow \dots \rightarrow 32$ px, 256 ch	Representasi semantik menengah; ruang piksel berkurang
Encoder L4 (Conv+ReLU $\times 2$, MaxPool)	$32 \rightarrow \dots \rightarrow 16$ px, 512 ch	Fitur tingkat tinggi; informasi konteks global
Bottleneck (Conv+ReLU $\times 2$)	$16 \times 16 \times 1024$	Representasi laten paling abstrak;

×2)		penggabungan konteks global
Decoder L1 (Up-conv, Concat, Conv+ReLU ×2)	$32 \times 32 \times 512$	Upsampling + penggabungan skip connection dari Encoder L4
Decoder L2 (Up-conv, Concat, Conv+ReLU ×2)	$64 \times 64 \times 256$	Pemulihan resolusi + detail spasial dari Encoder L3
Decoder L3 (Up-conv, Concat, Conv+ReLU ×2)	$128 \times 128 \times 128$	Refinement batas tumor dari Encoder L2
Decoder L4 (Up-conv, Concat, Conv+ReLU ×2)	$256 \times 256 \times 64$	Resolusi penuh dipulihkan; detail piksel dari Encoder L1
Output Layer (Conv 1×1 + Sigmoid)	$256 \times 256 \times 1$	Menghasilkan probability map; nilai $\geq 0,5 \rightarrow$ piksel tumor

VI. Penjelasan Fungsi Tiap Komponen

Operasi konvolusi 3×3 yang diikuti oleh fungsi aktivasi ReLU berperan dalam mengekstraksi fitur lokal seperti tepi, tekstur, dan pola bentuk, sekaligus menambahkan non-linearitas agar model mampu mempelajari representasi kompleks. Max pooling 2×2 digunakan untuk mengurangi dimensi spasial dan memperluas *receptive field*, sehingga jaringan dapat menangkap konteks yang lebih luas.

Pada bagian decoder, *up-convolution* (transposed convolution) digunakan untuk meningkatkan resolusi feature map. Proses ini dikombinasikan dengan *skip connections* yang menggabungkan fitur dari encoder untuk mempertahankan detail spasial yang hilang selama proses downsampling. Lapisan akhir berupa konvolusi 1×1 dengan aktivasi sigmoid menghasilkan *probability map* untuk setiap piksel, yang kemudian diubah menjadi mask biner menggunakan threshold tertentu.

VII. Fungsi Loss dan Metrik Evaluasi

Mengingat ketidakseimbangan kelas yang umum terjadi pada citra MRI (piksel tumor jauh lebih sedikit dibandingkan piksel non-tumor), direkomendasikan penggunaan Dice Loss sebagai fungsi objektif utama, yang secara langsung mengoptimalkan Dice Coefficient. Sebagai alternatif, kombinasi Binary Cross-Entropy dan Dice Loss dapat digunakan untuk kestabilan pelatihan yang lebih baik. Metrik evaluasi yang relevan meliputi Dice Score (F1 Score segmentasi) dan Intersection over Union (IoU), keduanya mengukur tumpang tindih antara prediksi dan ground truth. Pada tantangan ISBI 2015, U-Net mencapai rata-rata IoU sebesar 92% untuk dataset PhC-U373 dan 77,5% untuk DIC-HeLa, secara signifikan melampaui metode terbaik kedua (Ronneberger et al., 2015).

VIII. Alasan Pemilihan U-Net

U-Net dipilih karena mampu menghasilkan segmentasi presisi tinggi melalui kombinasi konteks global dan detail lokal, serta efektif digunakan pada dataset terbatas dan tugas segmentasi citra biomedis.