

Nama : MOHAMMAD IMRON ROSYADI

NIM : 24060123140204

Segmentasi Tumor Otak pada Citra MRI

Menggunakan Arsitektur Attention U-Net

1. Deskripsi Task

Task yang dikerjakan adalah segmentasi semantik biner pada citra MRI otak untuk mendeteksi dan melokalisasi area tumor. Model menerima citra MRI otak 256x256 piksel (grayscale, 1 channel) sebagai input, lalu menghasilkan segmentation mask berukuran sama. Setiap piksel diklasifikasikan sebagai tumor (1) atau bukan tumor (0), sehingga ini tergolong dense prediction. Tantangan utama meliputi variasi bentuk tumor, batas yang tidak jelas, serta kemiripan intensitas antara jaringan tumor dan jaringan sehat.

2. Ukuran dan Bentuk Data


Dataset terdiri dari 1.000 pasang citra MRI otak beserta label segmentasinya. Shape tensor input adalah (N, 1, 256, 256) dan label/mask memiliki shape yang sama dengan nilai piksel 0 atau 1. Dataset dibagi dengan proporsi 70% pelatihan (700 citra), 15% validasi (150 citra), dan 15% pengujian (150 citra). Data augmentation berupa random flip, rotasi, dan elastic deformation diterapkan saat pelatihan untuk mengatasi keterbatasan jumlah data dan ketidakseimbangan kelas.

3. Arsitektur: Attention U-Net

Arsitektur yang dipilih adalah Attention U-Net (Oktay et al., 2018), ekstensi dari U-Net standar (Ronneberger et al., 2015) yang menambahkan Attention Gate (AG) pada setiap skip connection. AG secara selektif membobot fitur dari encoder sehingga hanya fitur yang relevan dengan lokasi tumor yang diteruskan ke decoder, tanpa supervisi tambahan. Arsitektur ini terdiri dari empat encoder block, satu bottleneck, empat AG, empat decoder block, dan satu output layer.

4. Diagram Breakdown Arsitektur

Alur pemrosesan: Input 256x256x1 masuk ke encoder yang secara bertahap mereduksi dimensi spasial (256 ke 16) sambil menambah jumlah filter (64 ke 1024). Setiap encoder block menghasilkan fitur yang disimpan sebagai skip connection. Bottleneck pada resolusi 16x16x1024 menangkap representasi global. Decoder kemudian menaikkan resolusi secara bertahap (16 ke 256) sambil menerima fitur skip yang telah dibobot oleh Attention Gate di setiap level, hingga menghasilkan mask 256x256x1, seperti yang diilustrasikan pada *Gambar 1 Diagram Arsitektur* (versi resolusi tinggi dapat diakses melalui tautan s.id/DiagramArsitektur).



Gambar 1 Diagram Arsitektur

5. Penjelasan Komponen

Komponen	Fungsi
Encoder Block (x4)	Terdiri dari dua lapis konvolusi 3x3 yang masing-masing diikuti Batch Normalization dan ReLU. Setiap blok mengekstraksi representasi fitur secara hierarkis dari citra MRI, mulai dari fitur sederhana seperti tepi dan tekstur di level awal hingga fitur semantik tingkat tinggi seperti bentuk dan pola tumor di level dalam. Jumlah filter berlipat di setiap level: 64, 128, 256, 512. Setelah setiap blok, MaxPool 2x2 mereduksi dimensi spasial menjadi setengahnya untuk menangkap konteks yang lebih luas.
Bottleneck	Lapisan terdalam dengan 1024 filter pada resolusi 16x16 piksel. Berfungsi sebagai jembatan antara encoder dan decoder, merepresentasikan konteks global keseluruhan citra tanpa informasi spasial yang detail. Dropout diterapkan di sini untuk mencegah overfitting mengingat kapasitas model yang besar pada lapisan ini.
Skip Connection	Menghubungkan setiap level encoder langsung ke level decoder yang setara. Memungkinkan informasi lokasi spasial resolusi tinggi yang hilang akibat downsampling pada encoder untuk digunakan kembali oleh decoder. Tanpa skip connection, decoder hanya mengandalkan informasi dari bottleneck yang sudah kehilangan detail spasial, sehingga batas tumor pada output mask menjadi tidak presisi.
Attention Gate (x4)	Komponen inti pembeda Attention U-Net dari U-Net standar. Setiap Attention Gate menerima dua input: sinyal query dari decoder (informasi tentang apa yang sedang dicari) dan sinyal key dari skip connection encoder (fitur spasial resolusi tinggi). Keduanya digabungkan dan dilewatkan fungsi sigmoid untuk menghasilkan koefisien attention bernilai 0 hingga 1 per piksel. Koefisien ini mengalikan fitur skip sehingga hanya fitur yang relevan dengan lokasi tumor yang diteruskan ke decoder, sementara fitur latar belakang yang tidak relevan ditekan secara otomatis.
Decoder Block (x4)	Setiap blok decoder dimulai dengan UpConv 2x2 yang menggandakan dimensi spasial (upsampling). Hasil UpConv kemudian di-concatenate dengan fitur skip connection yang telah dibobot oleh Attention Gate dari level encoder yang setara, sehingga channel berlipat dua sebelum masuk konvolusi. Dua lapis konvolusi 3x3 diikuti Batch Normalization dan ReLU kemudian memproses hasil concatenation tersebut. Jumlah filter turun secara bertahap: 512, 256, 128, 64, seiring resolusi spasial yang naik kembali ke 256x256.

Batch Normalization	Diterapkan setelah setiap lapis konvolusi sebelum aktivasi ReLU. Menormalisasi distribusi aktivasi pada setiap mini-batch sehingga pelatihan lebih stabil dan konvergensi lebih cepat. Mengurangi sensitivitas terhadap inisialisasi bobot dan berperan sebagai regularisasi implisit yang membantu mencegah overfitting (Ioffe dan Szegedy, 2015).
Dropout	Diterapkan pada bottleneck selama pelatihan untuk secara acak menonaktifkan sebagian neuron sehingga model tidak bergantung pada neuron tertentu dan belajar representasi yang lebih robust. Membantu mencegah overfitting, khususnya pada dataset dengan jumlah citra pelatihan yang terbatas.
Output Layer	Konvolusi 1x1 mereduksi jumlah channel dari 64 menjadi 1, diikuti fungsi aktivasi Sigmoid yang menghasilkan nilai probabilitas antara 0 dan 1 untuk setiap piksel. Probabilitas ini merepresentasikan seberapa besar kemungkinan piksel tersebut adalah bagian dari tumor. Dengan menerapkan threshold tertentu, output akhir berupa binary segmentation mask berukuran 256x256x1 di mana nilai 1 menandai area tumor dan nilai 0 menandai area non-tumor.

6. Kesesuaian Arsitektur

- **Efisien pada data terbatas.** U-Net dirancang untuk skenario data berlabel sedikit dan terbukti bekerja baik pada puluhan hingga ratusan citra (Ronneberger et al., 2015).
- **Preservasi lokasi spasial.** Skip connection mempertahankan informasi resolusi tinggi dari encoder sehingga batas tumor tergambar dengan presisi di output mask.
- **Selektivitas fitur via Attention Gate.** Attention Gate menekan fitur latar belakang yang tidak relevan dan menguatkan fitur area tumor, meningkatkan akurasi tanpa overhead komputasi signifikan (Oktay et al., 2018).
- **Batch Normalization mempercepat konvergensi.** Batch Normalization pada setiap blok konvolusi menstabilkan distribusi aktivasi dan bertindak sebagai regularisasi implisit (Ioffe dan Szegedy, 2015), cocok untuk dataset berukuran sedang.

Referensi

- Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, PMLR 37, 448-456. arXiv:1502.03167.
- Oktay, O., Schlemper, J., Le Folgoc, L., Lee, M., Heinrich, M., Misawa, K., Mori, K., McDonagh, S., Hammerla, N. Y., Kainz, B., Glocker, B., & Rueckert, D. (2018). Attention U-Net: Learning Where to Look for the Pancreas. *Medical Imaging with Deep Learning (MIDL)*. arXiv:1804.03999.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 234-241. arXiv:1505.04597.