

SEGMENTASI TUMOR OTAK PADA CITRA MRI MENGGUNAKAN ARSITEKTUR U-NET

Deskripsi

Salah satu penyakit yang paling mematikan adalah tumor otak dengan tingkat kematian mencapai 3.7% per 100.000 pasien. Untuk menganalisa tumor otak dapat dilakukan melalui segmentasi citra Magnetic Resonance Imaging (MRI). Metode saat ini yang mengandalkan analisis manual pada citra MRI dapat menyebabkan hasil yang bervariasi antar dokter (inter-observer error). Untuk mengatasi permasalahan tersebut dibutuhkan segmentasi citra secara otomatis dengan menggunakan bantuan komputer untuk mempersingkat waktu yang dibutuhkan dalam diagnosa penyakit.

Tugas segmentasi pada citra medis memiliki dua karakteristik khusus yang membedakannya dari segmentasi citra alam. Pertama, ukuran dataset yang tersedia umumnya sangat terbatas karena proses anotasi memerlukan keahlian klinis. Kedua, presisi batas (boundary) objek sangat kritis karena berimplikasi langsung pada diagnosis dan perencanaan terapi. Segmentasi tumor otak merupakan tugas computer vision tingkat tinggi yang bertujuan mengidentifikasi dan mendelineasi wilayah abnormal (tumor) dari jaringan otak sehat pada citra MRI. Setiap piksel diklasifikasikan secara independen ke dalam dua kelas: tumor atau non-tumor. Karakteristik utama yang menjadi tantangan adalah variasi bentuk, ukuran, dan intensitas tumor antar pasien, serta keterbatasan jumlah data berlabel karena proses anotasi membutuhkan keahlian medis khusus.

Ukuran dan Bentuk Data

Input	Citra MRI otak grayscale, ukuran 256×256 piksel, 1 channel
Output	Binary mask 256×256 piksel - nilai 1 = region tumor, nilai 0 = jaringan normal
Dataset	1.000 citra MRI beserta label/mask anotasi tumor
Bentuk Tensor	Input: (1000, 256, 256, 1) Output/Mask: (1000, 256, 256, 1)


Tabel 1. Spesifikasi Dataset

Sebelum dimasukkan ke model, setiap citra dinormalisasi menggunakan metode Z-score normalization per citra untuk mengatasi variasi intensitas antar pemindai MRI yang berbeda.

U-Net Convolutional Neural Network

Arsitektur U-Net dibangun di atas Fully Convolutional Network (FCN) dan dimodifikasi sedemikian rupa sehingga menghasilkan segmentasi yang lebih baik dalam pencitraan medis.

Dibandingkan dengan FCN, dua perbedaan utamanya adalah U-Net simetris dan koneksi lompatan (skip connection) antara jalur downsampling dan jalur upsampling yang menerapkan operator gabungan daripada penjumlahan.



Gambar 1. Diagram arsitektur U-Net

Sumber: Diambil dari [1]

Diagram arsitektur U-Net pada Gambar 1 memperlihatkan struktur simetris berbentuk huruf U yang dibagi menjadi 3 bagian:

1. Jalur contracting/downsamlng

Secara berulang menerapkan dua konvolusi 3×3 diikuti ReLU dan max pooling 2×2 untuk menurunkan resolusi spasial dari 572×572 hingga 28×28 piksel sekaligus meningkatkan jumlah channel fitur dari 64 hingga 1024. Proses downsampling ini berlangsung dalam empat tahap, di mana setiap tahap menggandakan kedalaman representasi fitur.

2. Jalur expanding/upsampling

Expanding atau Upsampling memiliki tujuan untuk memungkinkan lokalisasi yang tepat dikombinasikan dengan informasi kontekstual dari jalur contracting. Secara bertahap melalui up-convolution 2×2, diikuti dua konvolusi 3×3 dengan ReLU pada setiap levelnya.

3. Bottleneck

Bagian yang terdapat di antara jalur upsampling dan downsampling. Bottleneck dibangun dari hanya 2 convolutional layer (dengan batch normalization).

Sebelum citra MRI dimasukkan ke dalam model U-Net, terdapat serangkaian tahapan pra-pemrosesan yang perlu dilalui. Tahap pertama adalah koreksi bias menggunakan metode N4ITK yang bertujuan mengurangi ketidakseragaman intensitas akibat artefak medan magnet, sehingga kualitas citra meningkat dan proses klasifikasi piksel dapat berjalan lebih akurat.

Selanjutnya dilakukan augmentasi data berupa pencerminan citra secara vertikal dan horizontal untuk memperluas jumlah sampel pelatihan. Model U-Net kemudian mempelajari pola fitur melalui fase training dan validation secara bergantian hingga menghasilkan model terlatih yang menyimpan representasi pembelajaran dalam bentuk kumpulan array numerik. Model terlatih inilah yang digunakan untuk melakukan inferensi, yakni mensegmentasi citra MRI baru dan mengidentifikasi wilayah yang terindikasi sebagai tumor otak secara otomatis.

Alasan Pemilihan U-Net

1. Ketersediaan data

U-Net secara eksplisit dirancang untuk berfungsi optimal dengan jumlah sampel yang sangat terbatas. Dataset sebesar 1.000 citra tergolong kecil untuk kebanyakan arsitektur deep learning, namun teknik elastic deformation dan augmentasi agresif lainnya yang dipopulerkan U-Net mampu secara efektif memperbesar variasi data secara artifisial tanpa memerlukan citra berlabel baru.

2. Sifat fully convolutional tanpa fully connected layer

Ini berarti jumlah parameter relatif lebih kecil, risiko overfitting lebih rendah, dan arsitektur dapat menerima input dari berbagai ukuran. Pada kasus ini, input 256×256 piksel dapat diproses secara langsung tanpa penyesuaian ukuran yang berpotensi menghilangkan detail medis penting

3. Mekanisme skip connection

Tumor otak memiliki batas yang irregular dan seringkali gradual terhadap jaringan sekitarnya, skip connection memastikan bahwa gradient spasial halus ini tidak hilang selama encoding.

Referensi

- [1] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *arXiv preprint arXiv:1505.04597*. <https://arxiv.org/abs/1505.04597>
- [2] I. B. L. M. Suta, M. Sudarma, dan I. N. S. Kumara, "Segmentasi Tumor Otak Berdasarkan Citra Magnetic Resonance Imaging Dengan Menggunakan Metode U-NET," *Majalah Ilmiah Teknologi Elektro*, vol. 19, no. 2, pp. 151, Jul.–Des. 2020. DOI: <https://doi.org/10.24843/MITE.2020.v19i02.P05>
- [3] Sudre, C. H., et al. (2017). Generalised Dice overlap as a deep learning loss function for highly unbalanced segmentations. *Deep Learning in Medical Image Analysis, LNCS 10553*, 240–248.