

Arsitektur U-Net untuk Segmentasi Tumor Otak pada Citra MRI FLAIR BraTS2020

Deskripsi Task

Task pada penelitian ini merupakan *binary semantic segmentation*, yaitu proses mengklasifikasikan setiap piksel pada citra MRI ke dalam dua kelas, yaitu tumor dan non-tumor (*background*). Hal ini berbeda dengan klasifikasi citra yang hanya menghasilkan satu label untuk satu gambar, sedangkan segmentasi menghasilkan keluaran berupa *mask* segmentasi dengan ukuran spasial yang sama seperti citra input.

Pada penelitian ini, model menerima citra MRI otak sebagai *input*, kemudian mempelajari pola intensitas, tekstur, bentuk, dan batas area tumor. Output yang dihasilkan adalah *mask* tumor, yaitu citra biner yang menunjukkan lokasi tumor pada setiap piksel. Area tumor direpresentasikan dengan nilai 1 atau putih, sedangkan area non-tumor direpresentasikan dengan nilai 0 atau hitam.

Segmentasi tumor otak merupakan salah satu *task* penting dalam pemrosesan citra medis karena dapat membantu proses identifikasi area abnormal pada otak. Dataset BraTS banyak digunakan sebagai *benchmark* segmentasi tumor otak karena menyediakan citra MRI dan label segmentasi tumor yang dapat digunakan untuk mengevaluasi performa model *deep learning* (Menze et al., 2015).

Ukuran dan Bentuk Data

Dataset yang digunakan berupa citra MRI otak modalitas FLAIR dan label berupa *mask* tumor yang telah dikonversi ke format PNG. Data awal berasal dari volume MRI 3D yang dikonversi menjadi citra 2D. Citra awal berukuran 240×240 piksel, kemudian pada tahap *preprocessing* diubah menjadi 256×256 piksel agar sesuai dengan *input* model.

Tabel 1 Ukuran dan Bentuk Data

Komponen	Keterangan
Jenis data	Citra MRI otak dan mask tumor
Format data	PNG
Modalitas MRI	FLAIR
Jumlah data yang digunakan	1.000 citra
Ukuran citra awal	240×240 piksel
Ukuran setelah preprocessing	256×256 piksel
Bentuk <i>input</i> model	$256 \times 256 \times 1$
Bentuk <i>output</i> model	$256 \times 256 \times 1$
Jenis label	Binary mask
Kelas segmentasi	Tumor dan non-tumor (<i>background</i>)
Data latih	800 citra
Data validasi	100 citra
Data uji	100 citra

Citra MRI dinormalisasi ke rentang nilai 0–1 agar proses pelatihan model menjadi lebih stabil. *Mask* tumor juga diubah menjadi bentuk biner, yaitu nilai 1 untuk area tumor dan nilai 0 untuk area non-tumor. Dengan demikian, model dapat mempelajari hubungan antara citra MRI sebagai *input* dan *mask* tumor sebagai target *output*.


Arsitektur Deep Learning yang Digunakan

Arsitektur *deep learning* yang digunakan adalah U-Net. Arsitektur ini dipilih karena memang dirancang untuk tugas segmentasi citra biomedis. U-Net memiliki struktur berbentuk huruf U yang terdiri atas *encoder*, *bottleneck*, dan *decoder*. *Encoder* berfungsi mengekstraksi fitur dari citra *input*, *bottleneck* mempelajari representasi fitur yang lebih kompleks, sedangkan *decoder* mengembalikan ukuran *feature map* agar menghasilkan *mask* segmentasi.

U-Net memiliki komponen penting berupa *skip connection*, yaitu jalur penghubung antara *encoder* dan *decoder* pada tingkat resolusi yang sama. *Skip connection* berfungsi mempertahankan informasi spasial dari citra *input* agar detail lokasi dan batas objek tidak hilang selama proses *downsampling*. Hal ini penting pada segmentasi tumor otak karena area tumor dapat memiliki bentuk tidak beraturan dan batas yang sulit dibedakan dari jaringan normal. U-Net terdiri atas *contracting path* untuk menangkap konteks citra dan *expanding path* untuk menghasilkan lokalisasi segmentasi yang lebih presisi (Ronneberger et al., 2015).

Diagram Breakdown Arsitektur U-Net

Arsitektur U-Net pada penelitian ini menerima *input* citra MRI *grayscale* berukuran $256 \times 256 \times 1$. Jumlah filter pada *encoder* meningkat secara bertahap dari 16, 32, 64, 128, hingga 256 pada *bottleneck*. Pada *decoder*, jumlah filter menurun kembali menjadi 128, 64, 32, dan 16 agar resolusi *output* kembali sama seperti ukuran *input*.



Gambar 1 Diagram Breakdown Arsitektur U-Net

Gambar 1 menunjukkan arsitektur U-Net yang digunakan untuk segmentasi tumor otak pada citra MRI FLAIR. *Input* model berupa citra *grayscale* berukuran $256 \times 256 \times 1$, sedangkan *output* model berupa *mask* tumor berukuran $256 \times 256 \times 1$. Pada bagian *encoder*, ukuran *feature map* berkurang secara bertahap melalui proses *max pooling*, sedangkan jumlah filter meningkat dari 16, 32, 64, hingga 128. Bagian *bottleneck* memiliki ukuran *feature map* paling kecil, yaitu $16 \times 16 \times 256$, dan berfungsi menyimpan fitur tingkat tinggi dari citra MRI. Selanjutnya, bagian decoder melakukan *upsampling* menggunakan UpConv untuk mengembalikan ukuran *feature map* hingga sama dengan input. Panah horizontal pada diagram menunjukkan jalur *skip connection* dari *encoder* ke *decoder*. Pada jalur tersebut dilakukan operasi *concatenation*, yaitu penggabungan *feature map* *encoder* dan *decoder* pada resolusi yang sama agar informasi spasial dan batas tumor tetap dipertahankan.

Tabel 2 Breakdown Arsitektur U-Net

Bagian	Operasi	Output
<i>Input</i>	Citra MRI FLAIR	$256 \times 256 \times 1$
<i>Encoder 1</i>	$2 \times \text{Conv2D } 3 \times 3 + \text{ReLU}$	$256 \times 256 \times 16$
<i>Pooling 1</i>	MaxPooling2D 2×2	$128 \times 128 \times 16$
<i>Encoder 2</i>	$2 \times \text{Conv2D } 3 \times 3 + \text{ReLU}$	$128 \times 128 \times 32$
<i>Pooling 2</i>	MaxPooling2D 2×2	$64 \times 64 \times 32$
<i>Encoder 3</i>	$2 \times \text{Conv2D } 3 \times 3 + \text{ReLU}$	$64 \times 64 \times 64$
<i>Pooling 3</i>	MaxPooling2D 2×2	$32 \times 32 \times 64$
<i>Encoder 4</i>	$2 \times \text{Conv2D } 3 \times 3 + \text{ReLU}$	$32 \times 32 \times 128$
<i>Pooling 4</i>	MaxPooling2D 2×2	$16 \times 16 \times 128$
<i>Bottleneck</i>	$2 \times \text{Conv2D } 3 \times 3 + \text{ReLU}$	$16 \times 16 \times 256$

<i>Decoder 1</i>	Conv2DTranspose + Concatenate + Conv2D	$32 \times 32 \times 128$
<i>Decoder 2</i>	Conv2DTranspose + Concatenate + Conv2D	$64 \times 64 \times 64$
<i>Decoder 3</i>	Conv2DTranspose + Concatenate + Conv2D	$128 \times 128 \times 32$
<i>Decoder 4</i>	Conv2DTranspose + Concatenate + Conv2D	$256 \times 256 \times 16$
<i>Output</i>	Conv2D 1×1 + Sigmoid	$256 \times 256 \times 1$

Komponen Arsitektur

Tabel 3 Komponen Arsitektur

Komponen	Fungsi
<i>Input layer</i>	Menerima citra MRI FLAIR berukuran $256 \times 256 \times 1$ sebagai masukan model.
Conv2D 3×3	Mengekstraksi fitur visual dari citra MRI, seperti tepi, tekstur, intensitas, dan pola area tumor.
ReLU	Memberikan kemampuan non-linear agar model dapat mempelajari pola tumor yang kompleks.
MaxPooling2D 2×2	Mengurangi ukuran <i>feature map</i> sehingga model dapat menangkap konteks citra yang lebih luas.
<i>Encoder</i>	Bagian <i>downsampling</i> yang bertugas mengambil fitur penting dari citra MRI.
<i>Bottleneck</i>	Bagian terdalam U-Net yang menyimpan fitur paling kompleks dengan ukuran spasial kecil dan jumlah channel besar.
Conv2DTranspose	Melakukan <i>upsampling</i> untuk memperbesar kembali ukuran <i>feature map</i> pada <i>decoder</i> .
Concatenate	Menggabungkan <i>feature map</i> dari <i>decoder</i> dengan <i>feature map</i> dari <i>encoder</i> pada resolusi yang sama.
<i>Skip connection</i>	Mempertahankan informasi spasial dari <i>encoder</i> agar detail batas tumor tidak hilang.
Decoder	Mengembalikan resolusi <i>feature map</i> secara bertahap hingga sama dengan ukuran citra input.
Conv2D 1×1	Mengubah <i>feature map</i> akhir menjadi satu channel output sesuai kebutuhan segmentasi biner.
Sigmoid	Menghasilkan probabilitas setiap piksel berada pada kelas tumor dengan nilai antara 0 dan 1.
<i>Output mask</i>	Hasil akhir segmentasi berupa <i>mask</i> tumor berukuran $256 \times 256 \times 1$.

Alasan U-Net Sesuai untuk Segmentasi Tumor Otak

U-Net sesuai untuk segmentasi tumor otak karena arsitektur ini dikembangkan untuk segmentasi citra biomedis. Segmentasi tumor otak membutuhkan prediksi berbasis piksel, sehingga U-Net lebih sesuai dibandingkan model klasifikasi biasa yang hanya menghasilkan satu label untuk satu citra. Struktur *encoder-decoder* pada U-Net memungkinkan model menangkap konteks global citra MRI sekaligus mengembalikan informasi spasial untuk membentuk *mask* segmentasi ([Ronneberger et al., 2015](#)).

Selain itu, *skip connection* pada U-Net sangat penting untuk mempertahankan detail lokasi dan batas tumor. Tumor otak pada MRI dapat memiliki bentuk yang tidak beraturan, ukuran yang bervariasi, dan batas yang sulit dibedakan dari jaringan otak normal. Dengan adanya *skip connection*, fitur detail dari *encoder* dapat digabungkan kembali dengan fitur *decoder* sehingga hasil segmentasi menjadi lebih presisi. Penggunaan dataset BraTS juga relevan karena dataset tersebut banyak digunakan sebagai *benchmark* untuk mengevaluasi metode segmentasi tumor otak berbasis MRI ([Menze et al., 2015](#)).