

Nama: Parisya Lituhayu Chandrawati Gunawaman

NIM: 24060123140142

Kelas: Pengenalan Pola A

Segmentasi Tumor Otak pada Citra MRI Menggunakan Arsitektur ResU-Net dengan Residual Blocks dan Attention Gates

1. Deskripsi Task

Task yang diselesaikan adalah segmentasi semantik biner (binary semantic segmentation) pada citra MRI otak, yakni mendeteksi dan melokalisasi piksel yang termasuk area tumor dari piksel latar belakang jaringan otak normal. Model menerima citra MRI otak grayscale sebagai input dan menghasilkan binary mask berukuran sama sebagai output, dimana nilai 1 merepresentasikan piksel tumor dan nilai 0 merepresentasikan area non tumor. Task ini tergolong kategori pixel-wise classification yang memerlukan pemahaman konteks global (posisi dan bentuk tumor) sekaligus presisi local (batas tepi tumor yang akurat). Tantangan utama meliputi variasi ukuran tumor, ketidakseimbangan kelas (piksel tumor jauh lebih sedikit dibanding non tumor), serta kemiripan intensitas antara jaringan tumor dan jaringan sehat.

2. Ukuran dan Bentuk Data


Parameter	Spesifikasi
Jumlah Total Citra	1.000 pasang (input + mask ground truth)
Pembagian Dataset	Train: 700, Validasi: 150, Test: 150
Dimensi Input	$256 \times 256 \times 1$ piksel (grayscale, 1 channel)
Dimensi Label/Mask	$256 \times 256 \times 1$ piksel (binary: 0 atau 1)
Tensor Input per Batch	(B, 1, 256, 256) — B = batch size
Tensor Output per Batch	(B, 1, 256, 256) — nilai [0,1] via Sigmoid
Normalisasi Input	Min-max scaling ke rentang [0, 1] per citra
Augmentasi Data	Rotasi $\pm 20^\circ$, horizontal flip, elastic deformation, brig

3. Arsitektur Deep Learning yang Digunakan

Arsitektur yang dipilih adalah RestU-Net (Zhang et al., 2018), yakni integrasi antara Residual Network (ResNet) dan arsitektur U-Net klasik. RestU-Net menggantikan blok konvolusi standar pada U-Net dengan Residual Blocks yang dilengkapi shortcut connection, serta menambahkan Attention Gate (AG) pada setiap skip connection untuk memfokuskan perhatian decoder pada area tumor. Arsitektur ini terdiri dari 4 komponen utama yaitu Encoder (contracting path berbasis residual blocks), Bottleneck (representasi paling abstrak), Decoder (expansive path dengan upsampling), dan Residual Skip Connections dengan AG yang menghubungkan encoder-decoder. Total kedalaman 4 level resolusi dengan 30+ lapisan konvolusi.

4. Diagram Breakdown Arsitektur

<https://drive.google.com/file/d/1xgjh1PwP7VxR5lQpZwNoniKnPqKgEPGs/view?usp=sharing>



5. Penjelasan Singkat Fungsi Setiap Komponen

- Input MRI ($1 \times 256 \times 256$): Citra MRI otak grayscale dinormalisasi ke $[0,1]$ dan diumpukan sebagai tensor $1 \times 256 \times 256$ ke encoder pertama.
- Residual Block ($\times 8$ total): Setiap blok terdiri dari Conv $3 \times 3 \rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ Conv $3 \times 3 \rightarrow$ BN, dengan shortcut connection yang menjumlahkan input ke output. Shortcut memungkinkan gradient mengalir langsung sehingga mengatasi degradasi akurasi pada jaringan dalam dan mempercepat konvergensi.
- Encoder – Contracting Path (Enc-1 s.d. Enc-4): Empat level residual block diikuti MaxPool 2×2 . Filter digandakan tiap level ($64 \rightarrow 128 \rightarrow 256 \rightarrow 512$ ch) untuk mengekstrak fitur hierarkis dari tepi piksel hingga bentuk tumor yang abstrak.
- MaxPool 2×2 ($\times 4$): Mereduksi dimensi spasial menjadi setengahnya setelah tiap encoder block, memperluas receptive field dan menekan biaya komputasi
- Bottleneck (1024ch, 16×16): Lapisan terdalam yang menangkap representasi paling abstrak dan kompak. Dropout 0.3 ditambahkan sebagai regularisasi untuk mencegah overfitting pada dataset terbatas (1.000 sampel).
- Attention Gates – AG-1 s.d. AG-4: Setiap gate menerima sinyal encoder (x) dan sinyal gating dari decoder (g), lalu menghitung bobot perhatian $\alpha \in [0,1]$ melalui $\sigma(W_g \cdot g + W_x \cdot x)$. Bobot α menekan fitur jaringan sehat dan mempertajam area tumor sebelum masuk ke decoder.
- UpConv 2×2 ($\times 4$): Transposed convolution yang menggandakan resolusi spasial secara bertahap dari 16×16 kembali ke 256×256 , memulihkan detail spasial yang hilang akibat MaxPool.

- Decoder – Expansive Path (Dec-4 s.d. Dec-1): Empat level UpConv $2 \times 2 \rightarrow$ Concat (fitur AG) $\rightarrow$ Residual Block. Filter dikurangi tiap level ($512 \rightarrow 256 \rightarrow 128 \rightarrow 64$ ch), memadukan konteks semantik decoder dengan detail spasial encoder.
- Output Layer (Conv 1×1 + Sigmoid): Memetakan 64 channel ke satu channel probabilitas per piksel. Sigmoid mengubah nilai ke $[0,1]$; piksel dengan nilai >0.5 diklasifikasikan sebagai tumor.
- Output Mask ($1 \times 256 \times 256$): Binary mask akhir di mana nilai 1 menunjukkan piksel tumor dan 0 menunjukkan jaringan normal, dievaluasi menggunakan metrik Dice Score, IoU, dan Precision/Recall.

6. Alasan Pemilihan Arsitektur

- Mengatasi vanishing gradient pada jaringan dalam: Residual blocks menggunakan shortcut connection sehingga gradient dapat mengalir langsung melewati beberapa lapisan tanpa degradasi, memungkinkan training jaringan 30+ lapisan secara stabil.
- Efektif untuk dataset medis terbatas: Kombinasi U-Net encoder-decoder dengan residual learning terbukti mencapai performa tinggi bahkan dengan data pelatihan yang terbatas, karena skip connection meminimalkan kehilangan informasi special.
- Attention Gate meningkatkan presisi segmentasi: Tumor otak memiliki batas difus dan ukuran bervariasi. AG secara adaptif menekan fitur skip connection yang tidak relevan sehingga decoder fokus pada area tumor dan mengurangi false positif.
- Preservasi resolusi special melalui skip connection: Encoder-decoder dengan residual skip connection mempertahankan informasi Lokasi resolusi tinggi yang hilang akibat MaxPool, menghasilkan segmentasi presisi piksel tanpa perlu mempelajari ulang detail spesial.
- Lebih unggul dibanding arsitektur sejenisnya: Dibandingkan vanilla U-Net (tanpa residual, rentan vanishing gradient), SegNet (tanpa skip connection langsung), dan DeepLab (tidak optimal untuk dataset kecil), ResU-Net menawarkan keseimbangan terbaik antara akurasi, stabilitas training, dan efisiensi komputasi untuk citra medis berskala kecil.

7. Referensi

- Zhang, Z., Liu, Q., & Wang, Y. (2018). Road extraction by deep residual U-Net. *IEEE Geoscience and Remote Sensing Letters*, 15(5), 749–753.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. *MICCAI*, 234–241.
<https://arxiv.org/pdf/1505.04597>
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *CVPR*, 770–778.
- Oktay, O., et al. (2018). Attention U-Net: Learning where to look for the pancreas. *MIDL Workshop*.