

LAPORAN
BREAKDOWN ARSITEKTUR DEEP LEARNING
UNTUK SEGMENTASI TUMOR OTAK PADA CITRA MRI

SEGMENTASI TUMOR OTAK PADA CITRA MRI 2D MENGGUNAKAN
ARSITEKTUR ATTENTION U-NET



Disusun Oleh:

Shopia Mudjahidah

NIM. 24060123120010

Disusun untuk memenuhi tugas mata kuliah Pengenalan Pola A

DEPARTEMEN INFORMATIKA
PROGRAM STUDI INFORMATIKA
FAKULTAS SAINS DAN MATEMATIKA
UNIVERSITAS DIPONEGORO
2026

1.1. Judul Kasus

Segmentasi Tumor Otak pada Citra MRI 2D Menggunakan Arsitektur Attention U-Net

1.2. Deskripsi Task

Model deep learning memetakan setiap citra input berukuran 256×256 piksel menjadi mask tumor dengan resolusi yang identik. Setiap piksel pada mask diklasifikasikan ke dalam dua kelas, yaitu 1 (area tumor) atau 0 (non-tumor). Proses pembelajaran dilakukan secara end-to-end menggunakan pasangan data citra MRI dan label mask yang telah dianotasi oleh ahli radiologi. Segmentasi otomatis ini berperan penting dalam mempercepat diagnosis klinis, perencanaan terapi radiasi, pemantauan perkembangan tumor, serta evaluasi respons pasien terhadap pengobatan. Tumor otak, khususnya glioma, memiliki karakteristik yang sangat heterogen dalam hal bentuk, ukuran, lokasi, dan intensitas sinyal pada MRI [5], sehingga diperlukan arsitektur yang adaptif dan presisi tinggi.

1.3. Ukuran dan Bentuk Data

Dataset yang digunakan terdiri dari 1.000 pasang citra MRI otak beserta label/mask tumor, dengan spesifikasi sebagai berikut.

1.3.1. Dimensi Input

Berukuran 256×256 piksel, format grayscale (1 saluran), merepresentasikan citra MRI potongan aksial otak.

1.3.2. Dimensi Output

Berukuran 256×256 piksel, mask biner (1 saluran), di mana piksel bernilai 1 menunjukkan tumor dan 0 menunjukkan non-tumor.

1.3.3. Jumlah Data

Total 1.000 pasang citra, dibagi menjadi 700 data latih (70%), 200 data validasi (20%), dan 100 data uji (10%).

1.3.4. Format Data


Citra input berupa hasil pemindaian MRI yang telah melalui pra-pemrosesan dasar (normalisasi intensitas dan resize ke 256×256), sedangkan label merupakan anotasi manual berbasis piksel yang dihasilkan oleh tenaga medis ahli.

1.4. Arsitektur Deep Learning

Arsitektur yang dipilih adalah Attention U-Net, yang dikembangkan oleh Oktay et al. (2018) [1] sebagai penyempurnaan dari U-Net klasik yang diperkenalkan Ronneberger et al. (2015) [2]. Arsitektur ini mempertahankan struktur encoder-decoder simetris dengan skip connection, namun menyisipkan modul Attention Gate (AG) pada setiap jalur pintas. Modul AG menerima dua masukan: fitur dari encoder yang kaya detail spasial dan sinyal gating dari decoder yang mengandung konteks global. Kedua sinyal diproses melalui konvolusi 1×1 , penjumlahan, aktivasi ReLU, dan fungsi sigmoid untuk menghasilkan peta koefisien atensi (α) bernilai 0–1. Peta ini dikalikan secara elemen dengan fitur encoder asli, sehingga area latar belakang yang tidak relevan ditekan dan hanya fitur yang diduga berkaitan dengan tumor yang diteruskan ke decoder. Mekanisme ini membuat model secara adaptif belajar memfokuskan perhatian pada wilayah paling informatif tanpa memerlukan anotasi tambahan. Keunggulan lainnya, penambahan parameter sangat minimal karena hanya berupa beberapa

konvolusi 1×1 , sehingga arsitektur tetap ringkas dan mempertahankan sifat data-efisien U-Net pada dataset biomedis berukuran kecil.

1.5. Diagram Breakdown Arsitektur



1.6. Fungsi Setiap Komponen

1.6.1. Encoder

Mengekstrak fitur secara hierarkis melalui 4 blok konvolusi ganda (Conv3x3, BN, ReLU) dan MaxPooling, menurunkan resolusi dari 256x256 ke 16x16 serta menaikkan saluran dari 64 ke 512. Proses ini menangkap pola dari tepi sederhana hingga bentuk global tumor.

1.6.2. Bottleneck

Titik terdalam dengan 1024 saluran dan resolusi 16x16. Merepresentasikan konteks global paling abstrak mengenai posisi tumor terhadap seluruh anatomi otak.

1.6.3. Decoder

Memulihkan resolusi spasial melalui Up-Conv 2x2, menggabungkan fitur dari encoder yang telah difilter Attention Gate, lalu memprosesnya dengan konvolusi ganda. Jumlah saluran diturunkan bertahap dari 512 ke 64 untuk merekonstruksi detail lokasi tumor.

1.6.4. Attention Gate

Menyaring fitur encoder sebelum diteruskan ke decoder. Menerima fitur encoder (x) dan sinyal gating (g) dari decoder, memprosesnya melalui Conv1x1, penjumlahan, ReLU, lalu Sigmoid untuk menghasilkan koefisien atensi α (0–1). Koefisien α dikalikan dengan x sehingga area non-tumor ditekan dan fitur tumor dipertahankan.

1.6.5. Skip Connection & AG

Menyalurkan fitur yang sudah difilter, bukan salinan mentah. Mengurangi false positive dan mempertajam batas tumor, terutama pada tumor kecil atau dekat jaringan sehat.

1.6.6. Output Layer

Conv 1×1 + aktivasi Sigmoid menghasilkan probabilitas per piksel (0–1). Ambang batas (threshold) 0,5 digunakan untuk memperoleh mask biner $256\times 256\times 1$.

1.7. Alasan Mengapa Arsitektur Sesuai

Attention U-Net dipilih karena desainnya selaras dengan tantangan utama segmentasi tumor otak. Tumor otak sangat bervariasi dalam bentuk, ukuran, dan lokasi [5], sehingga model harus mampu mengenali objek kecil maupun lesi yang meluas. Mekanisme attention gate secara adaptif memfokuskan komputasi pada area yang relevan dan menekan latar belakang [1], memungkinkan model menangani variabilitas tersebut tanpa pemotongan manual. AG juga menyaring fitur encoder sebelum masuk decoder, mengurangi false positive dan mempertajam batas tumor, aspek kritis dalam perencanaan klinis. Dengan hanya 1.000 citra, dataset tergolong terbatas; arsitektur ini hanya menambah sedikit parameter konvolusi 1×1 sehingga tetap mempertahankan sifat data-efisien U-Net asli [2]. Struktur encoder-decoder simetris dengan skip connection memberi keseimbangan antara konteks global dan detail lokal. Studi terbaru menunjukkan bahwa integrasi mekanisme attention pada U-Net secara konsisten meningkatkan performa segmentasi tumor otak [3][4][5], sehingga secara konseptual arsitektur ini memberikan fondasi yang kuat untuk diuji pada dataset 1.000 citra MRI 2D milik tugas ini. Perlu dicatat, performa aktual harus divalidasi melalui eksperimen langsung.

REFERENSI

- [1] Oktay, O., et al. (2018). Attention U-Net: Learning Where to Look for the Pancreas. MIDL 2018. arXiv:1804.03999.
- [2] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. MICCAI 2015. arXiv:1505.04597.
- [3] Mulani, B. M. (2024). Multi-Modal Brain Tumor Segmentation with Attention Mechanisms. Masters thesis, National College of Ireland.
- [4] Ahmad, I., et al. (2025). Implementation of biomedical segmentation for brain tumor utilizing an adapted U-Net model. Computers in Biology and Medicine.
- [5] Kaur, R., et al. (2025). Current trends in glioma tumor segmentation: A survey of deep learning modules. Physica Medica, 135, 104988.