




**Pengenalan Pola**



# **KLASIFIKASI AUDIO BURUNG**

Anggota Kelompok :

- George Imanuel Surya - 24060123120028
- Indah Nurul Jannah - 24060123120009
- Gabriel Prakosa Ardhi - 24060123130094
- Mohammad Izza Hakiki - 24060123140139
- Dhimas Luthfi Arnanda - 24060123120040



# Definisi Masalah & Tujuan


## Masalah

Mengklasifikasikan 110 audio burung ke dalam 5 kelas berdasarkan karakteristik suara.

Dataset mengalami class imbalance, kelas 1 punya 45 sampel, sedangkan kelas 3 hanya 5 sampel.

## Tujuan

Membuat pipeline klasifikasi audio dari ekstraksi fitur, visualisasi feature space, training model, sampai evaluasi.





# Distribusi & Statistik Data



Dataset berupa file audio .ogg dalam bentuk sinyal kontinu atau waveform.  
Total data: 110 audio.  
Label kelas: 0, 1, 2, 3, dan 4.  
Distribusi durasi audio bervariasi dari 2.72 detik hingga 276.69 detik.

|       | count | mean  |
|-------|-------|-------|
| label |       |       |
| 0_tr  | 18.0  | 17.48 |
| 1_tr  | 46.0  | 27.78 |
| 2_tr  | 10.0  | 46.44 |
| 3_tr  | 5.0   | 25.25 |
| 4_tr  | 32.0  | 30.32 |










# Distribusi Frekuensi



Banyak Overlapping  
sehingga sulit untuk  
memisahkan antar  
kelas



# Pattern Recognition Design Cycle



# Fitur Awal

Kita gunakan **40 fitur** yang mencakup dimensi berbeda dari sinyal audio:

| Kelompok | Fitur                        | Jumlah | Alasan                                                         |
|----------|------------------------------|--------|----------------------------------------------------------------|
| MFCC     | Mean per koefisien           | 13     | Timbre / warna suara — paling diskriminatif untuk bioacoustics |
| MFCC     | Std per koefisien            | 13     | Variabilitas temporal dalam rekaman                            |
| Spektral | Centroid, Bandwidth, Rolloff | 3      | Karakteristik frekuensi dominan                                |
| Temporal | ZCR, RMS Energy              | 2      | Tekstur dan intensitas suara                                   |
| Chroma   | Mean 12 nada                 | 12     | Konten harmonik / nada burung                                  |

**Total: 43 fitur**

```
le = LabelEncoder()
y_encoded = le.fit_transform(y_raw)

# Normalisasi
scaler_vis = StandardScaler()
X_scaled = scaler_vis.fit_transform(X_raw)
```

# Pemilihan Tepat 3 Fitur Relevan

Pada eksplorasi awal, beberapa fitur audio dianalisis menggunakan Random Forest Feature Importance.


Dari hasil analisis, dipilih tepat 3 fitur paling informatif:

- MFCC\_std\_2
- MFCC\_std\_5
- MFCC\_std\_9

Ketiga fitur ini dipakai sebagai fitur final untuk visualisasi, training, dan evaluasi.

MFCC\_std menunjukkan variasi koefisien MFCC sepanjang waktu. Fitur ini dipilih karena berdasarkan analisis Random Forest Importance, ketiga fitur tersebut memiliki kontribusi paling besar dalam membedakan kelas audio.

Analisis Fitur



=== Top 10 Fitur Paling Penting ===

|                |                     |
|----------------|---------------------|
| 1. MFCC_std_5  | importance = 0.0737 |
| 2. MFCC_std_2  | importance = 0.0643 |
| 3. MFCC_std_9  | importance = 0.0548 |
| 4. MFCC_std_7  | importance = 0.0500 |
| 5. MFCC_std_3  | importance = 0.0389 |
| 6. MFCC_std_6  | importance = 0.0377 |
| 7. MFCC_std_4  | importance = 0.0359 |
| 8. MFCC_mean_4 | importance = 0.0329 |
| 9. MFCC_std_12 | importance = 0.0309 |
| 10. MFCC_std_0 | importance = 0.0302 |



# Justifikasi Fitur Pilihan


Fitur tidak dipilih acak, tetapi berdasarkan kontribusi terhadap pemisahan kelas.

MFCC merepresentasikan karakteristik spektral yang berkaitan dengan warna suara atau timbre.

Nilai std pada MFCC menunjukkan variasi pola frekuensi sepanjang waktu.

Audio burung memiliki perubahan suara yang dinamis, sehingga variasi MFCC relevan untuk klasifikasi.

Boxplot 3 Fitur Audio per Kelas





# Proses Ekstraksi Fitur

Audio mentah dibaca menggunakan librosa.

Dari setiap audio diekstraksi 13 koefisien MFCC.

Kemudian diambil standar deviasi dari koefisien ke-2, ke-5, dan ke-9.

Hasil akhir adalah representasi numerik berukuran  $110 \times 3$ .

```
# Ekstraksi 13 koefisien MFCC
mfcc = librosa.feature.mfcc(
    y=audio,
    sr=sr,
    n_mfcc=13
)
```

```
mfcc_std_2 = np.std(mfcc[2])
mfcc_std_5 = np.std(mfcc[5])
mfcc_std_9 = np.std(mfcc[9])
```

```
Shape fitur: (110, 3)
Jumlah sampel: 110
Jumlah fitur : 3
```

```
return np.array([
    mfcc_std_2,
    mfcc_std_5,
    mfcc_std_9
])
```

# Representasi Numerik Data



Setelah ekstraksi, setiap audio tidak lagi diproses sebagai suara mentah, tetapi sebagai tiga angka fitur.



Contoh bentuk tabel:

Nama file

Label kelas

MFCC\_std\_2

MFCC\_std\_5

MFCC\_std\_9

Representasi numerik ini menjadi input utama model klasifikasi



```
Mengekstrak 3 fitur MFCC terpenting dari semua audio...
```

```
20/110 selesai...
```

```
40/110 selesai...
```

```
60/110 selesai...
```

```
80/110 selesai...
```

```
100/110 selesai...
```

```
Shape fitur: (110, 3)
```

```
Jumlah sampel: 110
```

```
Jumlah fitur : 3
```


```
Nama fitur:
```

```
[0] MFCC_std_2
```

```
[1] MFCC_std_5
```


```
[2] MFCC_std_9
```

# TAHAPAN NORMALISASI FITUR



```
# Normalisasi – fit hanya di train
scaler = StandardScaler()
X_tr_sc = scaler.fit_transform(X_train)
X_te_sc = scaler.transform(X_test)
```

# Visualisasi Feature Space 3D




**Karena pipeline memakai tepat 3 fitur, feature space dapat divisualisasikan langsung dalam 3 dimensi.**



Sumbu X = MFCC\_std\_2  
Sumbu Y = MFCC\_std\_5  
Sumbu Z = MFCC\_std\_9  
Warna titik menunjukkan kelas audio

Feature Space 3D Menggunakan 3 Fitur MFCC Terbaik






# Interpretasi Feature Space 3D

- 1 Visualisasi 3D menunjukkan beberapa kelas mulai membentuk kelompok. Namun, masih terdapat titik antar kelas yang saling overlap.
- 2 Overlap ini menunjukkan bahwa tiga fitur sudah menangkap sebagian pola audio, tetapi belum cukup sempurna untuk memisahkan semua kelas.

## Linear SVMs vs Non-linear SVMs



# Pemilihan Model Klasifikasi

Model yang digunakan adalah Support Vector Machine dengan kernel RBF



SVM cocok untuk dataset kecil karena mampu mencari batas pemisah antar kelas




Kernel RBF dipilih karena sebaran data audio tidak selalu linear. Model juga menggunakan `class_weight='balanced'` untuk membantu menghadapi data tidak seimbang.




# Strategi Training & Validasi

- 1 Evaluasi menggunakan Stratified 5-Fold Cross Validation
- 2 Stratified dipakai agar proporsi kelas tetap terjaga pada setiap fold
- 3 Setiap fold terdiri dari data training dan testing yang berbeda
- 4 Hasil evaluasi kemudian digabung untuk memperoleh performa agregat



# Penanganan Class Imbalance dengan SMOTE


Dataset tidak seimbang, terutama kelas 3 yang hanya memiliki 5 sampel  
SMOTE digunakan untuk menambah data sintetis pada kelas minoritas  
SMOTE hanya diterapkan pada data training di setiap fold  
Data testing tidak disentuh agar evaluasi tetap adil






# Region Kelas & Decision Boundary


- 1 Pada feature space, setiap kelas menempati area tertentu.
- 2 Karena beberapa kelas overlap, batas keputusan tidak bisa hanya berupa garis lurus sederhana.
- 3 SVM RBF membentuk decision boundary non-linear untuk memisahkan kelas sebaik mungkin.
- 4 Namun, overlap fitur tetap menyebabkan beberapa kesalahan prediksi.



Feature Space 3D Menggunakan 3 Fitur MFCC Terbaik



# Evaluasi Performa — Confusion Matrix



Confusion matrix menunjukkan prediksi benar dan salah pada setiap kelas.

- Kelas 4 paling stabil dikenali dengan recall sekitar 0.84.
- Kelas 1 masih banyak salah prediksi, recall sekitar 0.36, meskipun jumlah datanya paling besar.

Ini menunjukkan bahwa jumlah data besar tidak selalu menjamin kelas mudah dipisahkan.


# Evaluasi Performa — F1-Score

Karena dataset tidak seimbang, F1-score lebih tepat dibanding accuracy saja.

Hasil evaluasi:



- Micro F1 = 0.5545
- Macro F1 = 0.5371
- Weighted F1 = 0.5602

Macro F1 menjadi metrik penting karena memperlakukan semua kelas secara setara.





# Evaluasi Performa — ROC-AUC



ROC-AUC mengukur kemampuan model membedakan satu kelas terhadap kelas lainnya. Hasil AUC per kelas:

- Kelas 0 = 0.7289
- Kelas 1 = 0.7193
- Kelas 2 = 0.7540
- Kelas 3 = 0.9619
- Kelas 4 = 0.9383
- Macro AUC = 0.8205

menunjukkan kemampuan diskriminasi model cukup baik.



# Insight Kritis Pipeline

- 1 Pipeline sudah memenuhi konsep pattern recognition: data - fitur - model - evaluasi.
- 2 Penggunaan 3 fitur MFCC membuat pipeline sederhana dan sesuai instruksi.
- 3 Performa model masih sedang berdasarkan Macro F1 0.5371.
- 4 AUC cukup baik, tetapi F1 menunjukkan masih ada kesalahan klasifikasi antar kelas.
- 5 Masalah utama berasal dari class imbalance, overlap fitur, dan jumlah fitur yang dibatasi hanya 3.