




Universitas Diponegoro

DETEKSI PENYAKIT JANTUNG DENGAN PATTERN RECOGNITION

Dataset: UCI Heart Disease Data (Kaggle)

Pengenalan Pola - A

Anggota Kelompok

- 01 Kaila Talitha Putri (24060123140179)
- 02 Tsuraya Olivia (24060123130114)
- 03 Lulu Nikita Sitanggang (24060123120032)
- 04 Parisya Lituhayu Chandrawati G (24060123140142)
- 05 Gusti Ayu Genta Bhuana Paramitha (24060123130110)





Latar Belakang

Penyakit jantung merupakan salah satu masalah kesehatan serius yang membutuhkan deteksi dini agar risiko komplikasi dapat dikurangi. Penyakit jantung dapat dianalisis melalui data klinis pasien seperti usia, detak jantung maksimum, dan indikator EKG. Karena data medis memiliki banyak fitur dan pola yang tidak selalu terlihat langsung, diperlukan metode Pattern Recognition untuk membantu proses klasifikasi.

Proyek ini menggunakan dataset Heart Disease UCI untuk mengklasifikasikan pasien menjadi dua kelas, yaitu Sehat (0) dan Sakit Jantung (1). Pipeline dibangun melalui tahapan preprocessing, pemilihan 3 fitur utama, standardisasi data, visualisasi feature space, training model Support Vector Machine (SVM), dan evaluasi menggunakan confusion matrix, F1-score, serta ROC-AUC.

Tujuan utama proyek ini adalah membangun sistem klasifikasi sederhana namun terukur untuk memahami bagaimana fitur medis dapat digunakan dalam membedakan pasien sehat dan pasien dengan indikasi penyakit jantung.






Definisi Masalah

Pada proyek ini, masalah yang diselesaikan adalah klasifikasi kondisi pasien berdasarkan data medis. Dataset berisi data klinis pasien, seperti usia, detak jantung maksimum, tekanan darah, kolesterol, dan indikator pemeriksaan jantung lainnya. Dari data tersebut, sistem akan mempelajari pola untuk menentukan apakah seorang pasien termasuk kelas sehat atau sakit jantung.

Jenis masalah yang digunakan adalah Supervised Binary Classification, yaitu model belajar dari data berlabel untuk membedakan pasien ke dalam dua kelas:

- Sehat (0): pasien tidak terindikasi penyakit jantung.
- Sakit Jantung (1): pasien terindikasi memiliki penyakit jantung.

Pada dataset asli, label penyakit jantung terdapat pada kolom num. Nilai num = 0 menunjukkan pasien sehat, sedangkan nilai num > 0 menunjukkan pasien memiliki indikasi penyakit jantung. Oleh karena itu, kolom num dikonversi menjadi target biner agar sesuai dengan tujuan klasifikasi.



Pattern Recognition Design Cycle

1. Data Collection

Menggunakan dataset Heart Disease UCI berisi 920 data klinis pasien.

2. Feature Choice

Memilih 3 fitur utama: thalch, oldpeak, dan age berdasarkan korelasi dan domain knowledge medis.

3. Preprocessing

Menangani missing value, menghapus fitur dengan missing value besar, mengubah target num menjadi biner, dan melakukan standardisasi fitur.

4. Model Choice


Menggunakan Support Vector Machine (SVM) kernel linear karena cocok untuk jumlah fitur yang sedikit dan jumlah data training yang terbatas.

5. Training

Model dilatih menggunakan 110 data training untuk mempelajari pola pasien sehat dan sakit jantung.

6. Evaluation

Performa model dievaluasi menggunakan confusion matrix, F1-score, ROC curve, dan ROC-AUC. Hasilnya menunjukkan accuracy 86% dan ROC-AUC 0.818.



Dataset

Dataset yang digunakan adalah Heart Disease UCI dari Kaggle yang berisi 920 sampel dengan 16 kolom awal yang merepresentasikan informasi klinis pasien. Dataset ini terdiri dari data numerik dan data kategorikal. Fitur numerik yang digunakan antara lain age, trestbps, chol, thalch, dan oldpeak, sedangkan fitur kategorikal meliputi sex, dataset, cp, fbs, restecg, exang, dan slope.

Berdasarkan statistik deskriptif, rata-rata usia pasien = 53,51 tahun, rata-rata thalch = 137,55, dan rata-rata oldpeak = 0,88. Statistik ini digunakan untuk memahami gambaran awal data, termasuk skala, rentang, dan kecenderungan distribusi fitur.

```
df.describe()
```

	id	age	trestbps	chol	thalch	oldpeak	ca	num
count	920.000000	920.000000	861.000000	890.000000	865.000000	858.000000	309.000000	920.000000
mean	460.500000	53.510870	132.132404	199.130337	137.545665	0.878788	0.676375	0.995652
std	265.725422	9.424685	19.066070	110.780810	25.926276	1.091226	0.935653	1.142693
min	1.000000	28.000000	0.000000	0.000000	60.000000	-2.600000	0.000000	0.000000
25%	230.750000	47.000000	120.000000	175.000000	120.000000	0.000000	0.000000	0.000000
50%	460.500000	54.000000	130.000000	223.000000	140.000000	0.500000	0.000000	1.000000
75%	690.250000	60.000000	140.000000	268.000000	157.000000	1.500000	1.000000	2.000000
max	920.000000	77.000000	200.000000	603.000000	202.000000	6.200000	3.000000	4.000000

EDA

Pada tahap Exploratory Data Analysis (EDA), diketahui bahwa dataset memiliki 920 baris dan tidak terdapat data duplikat. Namun, masih terdapat beberapa fitur yang memiliki missing value, yaitu trestbps (59), chol (30), fbs (90), restecg (2), thalch (55), exang (55), oldpeak (62), slope (309), ca (611), dan thal (486).

Karena fitur ca dan thal memiliki jumlah missing value yang sangat besar, kedua fitur tersebut dihapus dari dataset. Untuk fitur numerik lainnya, missing value diisi menggunakan median, sedangkan fitur kategorikal diisi menggunakan modus. Hasil EDA ini menjadi dasar untuk tahap preprocessing agar data lebih bersih dan siap digunakan pada proses klasifikasi.

```
df.isnull().sum()
```

	0
id	0
age	0
sex	0
dataset	0
cp	0
trestbps	59
chol	30
fbs	90
restecg	2
thalch	55
exang	55
oldpeak	62
slope	309
ca	611
thal	486
num	0

dtype: int64

Preprocessing Data

Preprocessing dilakukan untuk membersihkan data sebelum digunakan dalam model klasifikasi.

Langkah-langkah preprocessing pada proyek ini adalah:

1. Mengecek missing value pada setiap kolom.
2. Menghapus fitur dengan missing value besar, yaitu ca dan thal.
3. Mengisi missing value numerik menggunakan median.
4. Mengisi missing value kategorikal menggunakan modus.
5. Mengubah target dari kolom num menjadi biner: $\text{num} = 0 \rightarrow \text{Sehat}$, $\text{num} > 0 \rightarrow \text{Sakit Jantung}$.
6. Memilih tiga fitur utama: thalch, oldpeak, dan age.
7. Melakukan standardisasi fitur menggunakan Z-score agar skala data menjadi seimbang.

Setelah preprocessing selesai, data diambil menjadi subset 138 sampel, kemudian dibagi menjadi 110 data training dan 28 data testing. Tahap ini membuat data lebih bersih, konsisten, dan siap digunakan untuk training model SVM Linear.

Pemilihan Fitur

Berdasarkan korelasi dan domain knowledge medis, dipilih 3 fitur berikut:


1. thalch (Max Heart Rate): Memiliki korelasi negatif tertinggi (-0.382). Pasien jantung seringkali memiliki keterbatasan detak jantung maksimal saat beraktivitas.
2. oldpeak (ST Depression): Korelasi positif tinggi (+0.366). Depresi segmen ST pada EKG setelah olahraga merupakan indikator kuat iskemia miokard.
3. age (Usia): Korelasi +0.283. Risiko degradasi fungsi kardiovaskular meningkat seiring bertambahnya usia.

Ketiga fitur ini memberikan dimensi yang berbeda (fisiologis, elektrik jantung, dan demografis) untuk membentuk feature space yang informatif.

Ekstraksi Fitur

Ekstraksi fitur dilakukan dengan mengubah data pasien menjadi representasi numerik yang siap digunakan oleh model klasifikasi. Pada proyek ini, fitur yang digunakan adalah thalch, oldpeak, dan age karena ketiganya memiliki korelasi yang cukup kuat terhadap target serta relevan secara medis. Karena ketiga fitur memiliki skala nilai yang berbeda, dilakukan Z-score Standardization agar setiap fitur berada pada skala yang seimbang.

Rumus:

$$z = \frac{x - \mu}{\sigma}$$


Transformasi ini membuat setiap fitur memiliki rata-rata 0 dan standar deviasi 1. Dengan demikian, fitur seperti thalch yang memiliki rentang nilai besar tidak mendominasi fitur lain seperti oldpeak yang memiliki rentang lebih kecil.



Pembagian Data

Setelah preprocessing dan ekstraksi fitur, data dibagi menjadi data training dan data testing. Pada proyek ini digunakan subset sebanyak 138 data, kemudian dibagi menjadi:

- 110 data training
- 28 data testing

Pembagian dilakukan dengan rasio sekitar 80:20, menggunakan `train_test_split`. Data training digunakan untuk melatih model Support Vector Machine (SVM) agar dapat mempelajari pola dari fitur `thalch`, `oldpeak`, dan `age`. Sementara itu, data testing digunakan untuk mengevaluasi performa model pada data baru yang belum pernah dilihat sebelumnya.

Pembagian ini bertujuan agar evaluasi model lebih objektif, karena model tidak hanya diuji pada data yang digunakan saat training, tetapi juga pada data terpisah sebagai simulasi kasus baru.



Visualisasi Feature Space 3D

Setelah tiga fitur utama dipilih dan distandarisasi, data divisualisasikan ke dalam feature space 3 dimensi menggunakan fitur thalach, oldpeak, dan age. Visualisasi ini bertujuan untuk melihat pola distribusi pasien Sehat dan Sakit Jantung pada 110 data training.


Tigas sumbu pada visualisasi merepresentasikan:

- thalach = detak jantung maksimum
- oldpeak = depresi segmen ST
- age = usia pasien

Setiap titik pada plot merepresentasikan satu pasien dari 110 data training, sedangkan warna titik menunjukkan kelas pasien:

- Biru = Sehat
- Merah = Sakit Jantung

Dari plot terlihat bahwa pasien Sehat cenderung berada pada area thalach tinggi dan oldpeak rendah, sedangkan pasien Sakit Jantung cenderung berada pada area thalach rendah dan oldpeak tinggi. Namun, masih terdapat overlap di area tengah, yang menunjukkan adanya data borderline sehingga model masih berpotensi melakukan misklasifikasi pada beberapa sampel. hingga model tetap berpotensi melakukan misklasifikasi pada beberapa data borderline.



Visual Feature Space 2D


Selain divisualisasikan dalam ruang 3 dimensi, feature space juga diproyeksikan ke dalam 2 dimensi untuk melihat hubungan antar pasangan fitur secara lebih jelas. Visualisasi ini membantu memahami pola distribusi data dan melihat pasangan fitur mana yang paling informatif dalam membedakan kelas Sehat dan Sakit Jantung.

Pada proyek ini, visualisasi 2D dilakukan pada tiga pasangan fitur, yaitu:

1. thalch vs oldpeak
2. thalch vs age
3. oldpeak vs age

Setiap titik pada scatter plot merepresentasikan satu pasien dari 110 data training, dengan pewarnaan:

- Biru = Sehat
- Merah = Sakit Jantung



Dari ketiga plot tersebut, pasangan thalch dan oldpeak terlihat paling informatif dalam membedakan kelas. Pasien sakit jantung cenderung memiliki thalch lebih rendah dan oldpeak lebih tinggi, sedangkan pasien sehat cenderung berada pada area thalch lebih tinggi dan oldpeak lebih rendah.

Sementara itu, fitur age tetap membantu sebagai fitur pendukung, tetapi pemisahan kelasnya tidak sejelas kombinasi thalch dan oldpeak. Adanya overlap antar titik menunjukkan bahwa beberapa pasien memiliki karakteristik yang mirip, sehingga model masih berpotensi mengalami misklasifikasi pada data borderline.

Modelling

Model yang digunakan adalah Support Vector Machine (SVM), yang termasuk dalam keluarga Machine Learning berbasis margin. Model ini dipilih karena:

1. SVM efektif pada data berdimensi kecil (3 fitur) dengan jumlah sampel terbatas (110)
2. Kernel linear terbukti optimal berdasarkan hasil GridSearchCV
3. SVM memaksimalkan margin antar kelas sehingga lebih robust terhadap outlier
4. Dengan probability=True, SVM dapat menghasilkan probabilitas untuk ROC-AUC

```
*** Best params: {'C': 100, 'class_weight': None, 'gamma': 0.1, 'kernel': 'rbf'}  
Best CV AUC: 0.747
```

Dengan pendekatan ini, model tidak hanya menghasilkan prediksi kelas, tetapi juga probabilitas sebagai tingkat keyakinan terhadap hasil prediksi.

Proses Training

Model SVM hasil tuning (GridSearchCV) digunakan sebagai model terbaik, lalu dikalibrasi dengan CalibratedClassifierCV (metode isotonic, 5-fold) agar probabilitas lebih akurat, dan dilatih menggunakan data training.

Pada tahap inferensi (sesuai gambar), ditampilkan beberapa sampel data uji yang sudah di-scaling, beserta probabilitas untuk kelas Sehat dan Sakit.

- Sample 1: diprediksi Sehat, namun label aktual Sakit
- Sample 2 & 3: diprediksi Sakit dan sesuai dengan label aktual

Prediksi ditentukan dari probabilitas terbesar, sehingga model tidak hanya memberi kelas, tapi juga tingkat keyakinannya.


```
--- Sample 1 (index 0) ---  
Data Sample (scaled): [ 0.60435469 -0.63260536 -1.7241808 ]  
Probabilitas [Sehat, Sakit]: [0.51956378 0.48043622]  
Prediksi: Sehat  
Label Aktual: Sakit  
  
--- Sample 2 (index 1) ---  
Data Sample (scaled): [-1.46771853  0.19000514  1.84534314]  
Probabilitas [Sehat, Sakit]: [0.26907069 0.73092931]  
Prediksi: Sakit  
Label Aktual: Sakit  
  
--- Sample 3 (index 2) ---  
Data Sample (scaled): [-1.94588927  0.19000514  0.62419021]  
Probabilitas [Sehat, Sakit]: [0.15666667 0.84333333]  
Prediksi: Sakit  
Label Aktual: Sakit
```


Visualisasi Decision Boundary

Decision boundary divisualisasikan menggunakan proyeksi 2D dari dua fitur paling informatif, yaitu thalach dan oldpeak. Visualisasi ini menunjukkan bagaimana model SVM Linear memisahkan kelas Sehat dan Sakit Jantung.

Pada plot, area biru menunjukkan region Sehat, sedangkan area merah menunjukkan region Sakit Jantung. Boundary yang terbentuk berupa garis pemisah linear sesuai dengan kernel yang digunakan.


Namun, masih terdapat beberapa titik di sekitar batas keputusan, sehingga data borderline berpotensi mengalami misklasifikasi.



Evaluasi - Confusion Matrix

Evaluasi pada 28 data testing menghasilkan confusion matrix dengan 10 true negative, 2 false positive, 2 false negative, dan 14 true positive. Hasil ini menunjukkan bahwa model mampu mengklasifikasikan sebagian besar data dengan benar.

Secara keseluruhan, model memperoleh accuracy 0,86. Untuk kelas sehat, diperoleh precision, recall, dan F1-score = 0,83, sedangkan untuk kelas sakit jantung diperoleh precision, recall, dan F1-score = 0,88. Nilai macro average F1-score yang dihasilkan adalah 0,85.



```
--- Classification Report ---
              precision    recall  f1-score   support

     0       0.83         0.83         0.83         12
     1       0.88         0.88         0.88         16


   accuracy          0.86
  macro avg          0.85
 weighted avg          0.86
```


Evaluasi - ROC Curve

ROC Curve digunakan untuk menilai kemampuan model dalam membedakan kelas Sehat dan Sakit Jantung pada berbagai threshold probabilitas. Pada grafik ROC, sumbu X menunjukkan False Positive Rate, sedangkan sumbu Y menunjukkan True Positive Rate.

Hasil evaluasi menunjukkan nilai ROC-AUC sekitar 0,870, yang menandakan bahwa model memiliki kemampuan diskriminasi yang cukup baik. Selain itu, berdasarkan classification report, model juga memperoleh weighted average precision, recall, dan F1-score sebesar 0,86.

Secara keseluruhan, hasil ini menunjukkan bahwa performa model cukup stabil pada data testing.



--- Classification Report ---


	precision	recall	f1-score	support
0	0.83	0.83	0.83	12
1	0.88	0.88	0.88	16
accuracy			0.86	28
macro avg	0.85	0.85	0.85	28
weighted avg	0.86	0.86	0.86	28

Insight & Keterbatasan Pipeline

Insight utama dari pipeline ini adalah bahwa fitur thalch dan oldpeak paling membantu dalam membedakan pasien Sehat dan Sakit Jantung. Pasien dengan thalch rendah dan oldpeak tinggi cenderung lebih dekat dengan kelas Sakit Jantung, sedangkan pasien dengan thalch tinggi dan oldpeak rendah cenderung berada pada kelas Sehat.

Namun, masih terdapat overlap antar kelas pada feature space, terutama di area tengah. Hal ini menyebabkan beberapa data borderline sulit dipisahkan secara jelas dan berpotensi mengalami misklasifikasi.

Keterbatasan lain adalah model SVM Linear mengasumsikan pemisahan kelas dapat dilakukan dengan batas keputusan linear. Padahal, pola data medis bisa lebih kompleks dan tidak selalu terpisah secara linear. Selain itu, jumlah data training yang digunakan hanya 110 sampel, sehingga performa model masih dapat ditingkatkan dengan data yang lebih banyak atau fitur tambahan yang lebih informatif.



Kesimpulan

Pipeline klasifikasi penyakit jantung menggunakan SVM Linear yang telah melalui proses tuning dan kalibrasi probabilitas mampu mengklasifikasikan pasien ke dalam kelas Sehat dan Sakit Jantung dengan performa yang cukup baik. Model memperoleh accuracy sebesar 86%, macro F1-score sebesar 0,86, dan ROC-AUC sekitar 0,870.

Model tidak hanya menghasilkan prediksi kelas, tetapi juga probabilitas sebagai tingkat keyakinan. Pada pengujian sampel, model mampu memprediksi dengan benar 2 dari 3 data uji, meskipun masih terdapat kesalahan pada satu sampel.

Hal ini menunjukkan bahwa model sudah cukup efektif, namun masih memiliki keterbatasan seperti kemungkinan overlap antar kelas dan jumlah data yang terbatas. Oleh karena itu, pengembangan lebih lanjut diperlukan untuk meningkatkan performa model.

