

Pattern Recognition Design Cycle



KLASIFIKASI
SPESIES BURUNG

Presented by Kelompok 7
Pengenalan Pola A



Anggota Kelompok

1. Gibran Ahmad Maulana - 24060123130112
 2. Kayis Hilmi Farih - 24060123140152
 3. Nazla Azzahra - 24060123120038
 4. Kevin Adi Santoso - 24060123130081
- 




Table of Content

- 01** Problem Definition
- 02** Feature Selection (Pilih 3 Fitur)
- 03** Feature Extraction
- 04** Visualisasi Feature Space
- 05** Model Training
- 06** Visualisasi Decision Boundary
- 07** Evaluasi Model

Problem Definition

DEFINISI


Dataset yang digunakan terdiri dari 110 file audio berformat .ogg yang merupakan rekaman suara burung liar dari 5 spesies berbeda, dilabeli sebagai kelas 0 hingga 4. Setiap file audio di-load dengan sample rate 22.050 Hz dan dipotong menjadi segmen-segmen berdurasi 5 detik. Segmen dengan durasi kurang dari 2 detik di-skip untuk menjaga kualitas fitur yang diekstraksi. Proses chunking ini menghasilkan lebih banyak sampel daripada jumlah file asli, namun juga menimbulkan tantangan karena chunk dari file yang sama tidak sepenuhnya independen satu sama lain



TUJUAN

Tujuan klasifikasi dalam proyek ini adalah mengidentifikasi spesies burung secara otomatis berdasarkan karakteristik akustik suaranya, sebuah masalah multi-class classification dengan 5 kelas target. Tantangan utama pipeline ini adalah distribusi kelas yang sangat tidak seimbang (imbalanced): kelas 1 mendominasi dengan 52 sampel pada test set, sementara kelas 3 hanya memiliki 5 sampel. Kondisi ini membuat accuracy bukan metrik yang tepat, sehingga pipeline dirancang sejak awal dengan ADASYN untuk oversampling adaptif dan Macro F1-Score sebagai metrik evaluasi utama agar setiap kelas diperlakukan secara setara. Pipeline dirancang khusus untuk mengatasi class imbalance sejak awal, bukan ditangani setelah split.

DISTRIBUSI KELAS



Feature Selection



Dari hasil seleksi, diperoleh tiga fitur terbaik yaitu mfcc_mean_1, mfcc_mean_2, dan zcr_mean. Ini menunjukkan bahwa karakteristik frekuensi dan tingkat noise merupakan faktor paling penting dalam membedakan spesies burung.

```
def get_feature_names(n_mfcc=N_MFCC):
    names = []
    names += [f"mfcc_mean_{i}" for i in range(n_mfcc)]
    names += [f"mfcc_std_{i}" for i in range(n_mfcc)]
    names += [f"mfcc_delta_mean_{i}" for i in range(n_mfcc)]
    names += [f"mfcc_delta2_mean_{i}" for i in range(n_mfcc)]
    names += [
        "chroma_mean",
        "spec_contrast_mean",
        "spec_centroid_mean",
        "spec_bandwidth_mean",
        "spec_rolloff_mean",
        "spec_flatness_mean",
        "zcr_mean",
        "rms_mean",
    ]
    return names
```

MFCC_MEAN_1

Rata-rata koefisien MFCC ke-2 (index 1) di satu chunk audio. MFCC menangkap “bentuk spektrum” yang terkait timbre (karakter warna suara). Koefisien rendah seperti ini biasanya mewakili struktur spektral global (mis. kecenderungan energi frekuensi rendah-menengah) yang sering kuat untuk membedakan jenis kicauan.

```
def select_top_k_features(X_train: pd.DataFrame, y_train: pd.Series, k: int = 3, random_state: int = 42) -> list[str]:
    mi = mutual_info_classif(
        X_train.to_numpy(dtype=np.float32, copy=False),
        y_train.to_numpy(),
        random_state=int(random_state),
    )
    order = np.argsort(-mi)
    top = [X_train.columns[i] for i in order[:k]]
    return top
```

MFCC_MEAN_2

Rata-rata koefisien MFCC ke-3 (index 2). Mirip fungsi mfcc_mean_1, tapi sedikit lebih “detail” dalam menangkap variasi bentuk spektrum. Kadang koefisien ini membantu membedakan kelas yang mirip secara loudness tetapi berbeda pola spektrumnya.

ZCR_MEAN

Rata-rata Zero Crossing Rate pada chunk (berapa sering sinyal melintasi nol). Ini lebih menggambarkan “kekasaran/noisiness” dan kandungan frekuensi tinggi: suara yang tajam/noisy cenderung ZCR lebih tinggi, suara yang lebih tonal/halus cenderung lebih rendah.



Feature Extraction

DARI FILE AUDIO MENTAH → REPRESENTASI NUMERIK 3 DIMENSI


Flow	Code
Load Audio	<pre>librosa.load(file, sr=22050) Load file .ogg sebagai array numpy float32</pre>
Chunking 5 Detik	<pre>chunk_samples = 5 × 22050 = 110.250 sample Skip chunk < 2 detik (< 44.100 sample)</pre>
MFCC Mean 1	<pre>mfcc_mean[1]</pre>
MFCC Mean 2	<pre>mfcc_mean[2]</pre>
ZCR Mean	<pre>librosa.feature.rms(y) np.mean() → scalar per chunk</pre>

Hasil akhir: menghilangkan silence & noise, meningkatkan kualitas fitur




NORMALISASI & TRANSFORMASI DATA

Sebelum Normalisasi		
Fitur	Skala	Contoh Nilai
Spectral Rolloff	~Hz	3500 - 8000
ZCR	ratio	0.02 - 0.25
RMS Energy	amplitude	0.001 - 0.15
<i>Skala berbeda ribuan kali → SVM bias ke fitur bernilai besar</i>		



Sesudah StandardScaler		
Fitur	Skala	Contoh Nilai
Spectral Rolloff	z-score	-2.5 - +3.1
ZCR	z-score	-1.8 - +2.4
RMS Energy	z-score	-1.2 - +5.0
<i>Semua fitur berskala sama → SVM dapat bekerja optimal</i>		

StandardScaler: $z = (x - \mu) / \sigma \rightarrow \mu = \text{mean fitur}, \sigma = \text{std fitur}$



Sumbu X: MFCC Mean 1
Sumbu Y: MFCC Mean 2
Sumbu Z: ZCR Mean

VISUALISASI FEATURE SPACE 3D

KELAS 2 - TERPISAH JELAS

Cluster kelas 2 (hijau) relatif membentuk cluster yang lebih kompak dibanding kelas lain di area tengah → lebih mudah dipisahkan model karena kombinasi timbre (MFCC) dan noisiness (ZCR) cukup konsisten.

KELAS 3 - ISOLATED TAPI KECIL

Cluster kelas 3 (kuning) jumlahnya kecil (minoritas) dan terlihat hanya sedikit titik → performa kelas ini bisa sensitif terhadap oversampling dan pembagian data (itulah alasan kita pakai Macro F1 dan ADASYN).


KELAS 0, 1, 4 - TERPISAH JELAS

Ketiga kelas ini terlihat overlap (tumpang tindih) di pusat ruang fitur → ini biasanya sumber error terbesar, karena 3 fitur ini belum cukup untuk memisahkan ketiganya secara tegas.

INTERPRETASI UMUM

Kombinasi (mfcc_mean_1, mfcc_mean_2) menjelaskan “warna suara”, sedangkan zcr_mean menjelaskan “tekstur/noise”. Ketika kelas-kelas punya timbre mirip, ZCR menjadi pembeda tambahan; namun jika masih overlap, berarti perlu fitur lain atau tuning model.

PAIRPLOT DISTRIBUSI PAIRWISE FITUR



MFCC MEAN 1 × ZCR

Sebagian kelas mulai terpisah, tapi beberapa kelas masih overlap di pusat.

MFCC MEAN 1 × MFCC MEAN 2

Banyak tumpang tindih → MFCC saja belum cukup memisahkan semua kelas.

DIAGONAL (KDE)

zcr_mean paling terlihat membedakan beberapa kelas (puncak distribusi berbeda).

ZCR × MFCC MEAN 2

Pemisahan lebih baik daripada MFCC-MFCC karena ZCR menambah info “tekstur/noise”, tapi overlap masih ada.

Model Training



HYPERPARAMETER TUNING MENGGUNAKAN:

- GridSearchCV
- Stratified K-Fold Cross Validation


PARAMETER YANG DITUNING:

- SVM: C, gamma, class_weight
- ADASYN: n_neighbors

OBJECTIVE:

Memaksimalkan Macro F1-score

Visualisasi Decision Boundary



- Decision boundary 2D menunjukkan data tidak separable secara linear , sehingga SVM RBF membentuk batas keputusan yang kompleks dan berkelok .
- Kombinasi MFCC + ZCR memberi pemisahan kelas yang lebih jelas dibanding MFCC vs MFCC saja, jadi ZCR adalah fitur pembeda penting .
- Overlap di area tengah masih besar, sehingga sebagian error klasifikasi tetap terjadi meskipun performa keseluruhan sudah tinggi.

Evaluasi Model

Model yang dikembangkan menunjukkan performa yang cukup baik dengan Macro F1-score sebesar 0.76 sebagai metrik utama, yang menandakan bahwa model mampu menangani data yang tidak seimbang secara relatif adil di setiap kelas. Nilai ROC-AUC yang tinggi, yaitu 0.94, juga mengindikasikan kemampuan model yang sangat baik dalam membedakan antar kelas secara keseluruhan. Secara per kelas, model bekerja sangat optimal pada kelas dengan karakteristik fitur yang jelas seperti kelas 3, namun masih mengalami kesulitan pada kelas yang memiliki distribusi fitur yang saling tumpang tindih, khususnya kelas 0 dan 1. Hal ini menunjukkan bahwa keterbatasan utama model terletak pada separasi fitur, bukan pada algoritma yang digunakan, sehingga peningkatan performa ke depan dapat difokuskan pada pengembangan fitur yang lebih diskriminatif.

Classification Report (termasuk F1-Score):

	precision	recall	f1-score	support
0	0.53	0.77	0.62	13
1	0.88	0.71	0.79	52
2	0.65	0.89	0.76	19
3	0.71	1.00	0.83	5
4	0.88	0.76	0.82	38
accuracy			0.77	127
macro avg	0.73	0.83	0.76	127
weighted avg	0.80	0.77	0.78	127

=== Ringkasan Metrik Utama ===

Macro F1-Score : 0.7636 <-- metrik utama

Weighted F1 : 0.7766

ROC-AUC (OvR) : 0.9448

Best CV params : {'adasyn__n_neighbors': 3, 'svm__C': 1000, 'svm__class_weight': 'balanced', 'svm__gamma': 'scale'}

Thank You



LINK COLLAB:

[HTTPS://COLAB.RESEARCH.GOOGLE.COM/DRIVE/1GK_QLN2
LTGYALNUGLMJ1QISFX1PGZS S?USP=SHARING](https://COLAB.RESEARCH.GOOGLE.COM/DRIVE/1GK_QLN2LTGYALNUGLMJ1QISFX1PGZS_S?USP=SHARING)

